

Multi-Domain Vision Transformer Fusion for Intersectional Demographic Classification from Facial Images

RICKY EKA PUTRA¹, REZKY ARISANTI PUTRI¹, YUNI YAMASARI¹, AND RAFY AULIA AKBAR¹

Department of Informatics, Faculty of Informatics, Universitas Negeri Surabaya, Surabaya 60231, Indonesia

Corresponding author: Ricky Eka Putra (e-mail: rickyeka@unesa.ac.id).

This research was supported in part by the Department of Informatics, Faculty of Informatics, Universitas Negeri Surabaya.

ABSTRACT Pengenalan atribut demografis wajah seperti ras dan gender secara simultan menghadapi tantangan variasi ekspresi, penuaan biologis, phenotypic overlap, serta keterbatasan representasi single-domain. Penelitian ini mengusulkan kerangka kerja fusi fitur laten multi-domain yang mengintegrasikan representasi visual dari tiga model Vision Transformer (ViT) pre-trained spesifik tugas untuk biometrik wajah, ekspresi afektif, dan estimasi usia, yang dipadukan dengan optimasi pipeline machine learning klasik untuk klasifikasi enam intersectional demographic subgroups pada dataset DemogPairs. Representasi laten diekstraksi secara offline dari setiap model untuk menghasilkan representasi visual terpadu yang memadukan informasi komplementer lintas-domain. Tujuh konfigurasi fitur dievaluasi melalui 5-Fold Stratified Cross-Validation pada empat classifier: Random Forest (RF), Gaussian Naive Bayes (GNB), Logistic Regression (LR), dan Support Vector Machine (SVM) dengan hyperparameter tuning via Grid Search Cross-Validation (GridSearchCV). Hasil eksperimen menunjukkan bahwa fusi tri-domain meraih performa terbaik pada tiga dari empat classifier yang dievaluasi, dengan model SVM menghasilkan performa tertinggi, mencatat Accuracy 93.70%, Precision 93.72%, Recall 93.70%, dan F1-Score 93.69% pada data uji independen. Evaluasi mendalam pada keenam subkelompok mencatat rentang F1-Score antara 91.74% dan 96.14%, yang membuktikan efektivitas fusi representasi laten multi-domain dalam mengenali atribut demografis interseksional.

INDEX TERMS Race and gender classification, intersectional demographic recognition, multi-domain feature fusion, algorithmic fairness, Vision Transformer.

I. INTRODUCTION

Pengenalan otomatis atribut demografis wajah memegang peranan penting dalam berbagai domain aplikasi cerdas, termasuk sistem forensik digital, kontrol akses biometrik, interaksi manusia-komputer, dan personalisasi layanan interaktif [1], [2]. Namun, sejumlah studi melaporkan adanya disparitas performa pada subkelompok demografis tertentu, termasuk perempuan dan individu dengan warna kulit lebih gelap [3], [4]. Ketimpangan tersebut dapat dipengaruhi oleh berbagai faktor, termasuk ketidakseimbangan distribusi data dan keterbatasan representasi fitur terhadap variasi visual [5]. Keterbatasan sistem konvensional dalam menangani variasi visual tersebut memperlihatkan bahwa pengenalan demografis yang adil dan akurat masih menghadapi kendala nyata di lapangan, sehingga diperlukan pendekatan representasi baru yang mampu memodelkan interaksi atribut demografis ras dan gender secara terpadu serta komprehensif.

Sebagian pendekatan pengenalan atribut wajah memodelkan atribut secara terpisah, sedangkan multi-task learning memungkinkan beberapa atribut dipelajari secara simultan [6]. Pemodelan atribut secara terpisah dapat membatasi analisis terhadap kelompok yang terbentuk dari kombinasi atribut, seperti ras dan gender [7], [8]. Akibatnya, metrik agregat berpotensi tidak menangkap disparitas performa pada subkelompok tertentu [9]. Evaluasi pada subkelompok demografis dengan representasi yang seimbang secara terkontrol dapat menyediakan landasan komparatif yang lebih konsisten dan objektif untuk mengukur variasi performa antarkelompok [9]. Pemodelan interseksional juga menghadapi tantangan representasi karena karakteristik wajah dan ekspresi dapat bervariasi antar kelompok demografis, sehingga diperlukan representasi visual yang mampu mempertahankan informasi diskriminatif sekaligus robust terhadap variasi tersebut [10].

Perkembangan metodologi pengenalan atribut wajah telah bergeser dari fitur buatan tangan menuju deep learning, termasuk CNN dan ViT. Pada era arsitektur Convolutional Neural Networks (CNN), berbagai penelitian mengeksplorasi ekstraksi ciri demografis melalui pemanfaatan region spesifik wajah seperti area wajah bagian tengah, kerangka kerja multi-tugas berbasis multi-skala untuk estimasi usia dan gender secara simultan, serta model CNN mendalam untuk pengenalan etnisitas [11], [12], [13]. ViT mampu memodelkan hubungan global antarpatch melalui Multi-Head Self-Attention (MHSA), sehingga berpotensi menghasilkan representasi visual yang lebih kontekstual, sementara pemanfaatan representasi generatif sintetis turut dikembangkan untuk memitigasi disparitas demografis [14], [15]. Di samping itu, integrasi mekanisme atensi paralel, pemanfaatan ViT untuk klasifikasi gender wajah, serta eksplorasi arsitektur transformer multi-aksis semakin memperkaya variasi pemodelan representasi visual [16], [17], [18]. Lebih lanjut, eksplorasi penggabungan representasi ViT lintas domain mulai dikembangkan melalui integrasi fitur ganda wajah dan emosi untuk meningkatkan diskriminasi atribut ras dan gender [19], [20]. Meskipun demikian, fusi representasi biometrik, ekspresi, dan penuaan dalam satu representasi terpadu masih relatif terbatas.

Meskipun perkembangan ViT terus berlangsung, masih terdapat beberapa kesenjangan yang relevan dengan klasifikasi demografis interseksional. Pertama, sebagian besar studi terdahulu bertumpu pada representasi biometrik wajah domain tunggal, namun integrasi informasi afektif secara simultan untuk klasifikasi demografis interseksional masih terbatas [11], [17], [18]. Kedua, pengenalan demografis sering kali menunjukkan sensitivitas tinggi terhadap perubahan morfologi wajah seiring pertambahan usia karena ekstraksi fitur yang digunakan tidak mengikutsertakan representasi penuaan biologis [12], [17]. Ketiga, studi komparatif mengenai pengaruh classifier, penskalaan fitur, dan reduksi dimensionalitas pada representasi transformer masih terbatas [13], [19], [20]. Untuk menjembatani keterbatasan representasi domain tunggal serta mengevaluasi batas keputusan classifier hilir tersebut, penelitian ini mengusulkan integrasi tiga domain representasi ViT yang dipadukan dengan optimasi pipeline classical classifier terstruktur.

Untuk menjawab kesenjangan riset tersebut, penelitian ini mengusulkan kerangka kerja fusi fitur Tri-Domain ViT yang memadukan tiga representasi laten spesifik tugas untuk klasifikasi demografis interseksional pada citra wajah. Kerangka kerja yang diusulkan mengintegrasikan tiga domain representasi komplementer, meliputi representasi biometrik wajah, ekspresi afektif, dan karakteristik penuaan, ke dalam satu representasi terpadu melalui fusi fitur [21], [22]. Ekstraksi fitur laten dilakukan secara offline dari model backbone ViT pre-trained yang dibekukan, sehingga klasifikasi hilir dapat dilakukan tanpa fine-tuning ulang backbone [23]. Vektor fitur yang dihasilkan kemudian dievaluasi melalui skema ablasi single-domain, dual-domain, dan tri-domain menggunakan empat classical machine learning classifiers, yaitu RF, GNB,

LR, dan SVM. Seluruh classifier hilir dievaluasi menggunakan Stratified Cross-Validation dalam pipeline yang mengintegrasikan penskalaan fitur dan reduksi dimensionalitas PCA, dengan setiap transformasi dipelajari hanya pada data pelatihan di setiap fold untuk mencegah data leakage [24].

Kontribusi ilmiah utama dari penelitian ini dirangkum ke dalam empat poin utama sebagai berikut:

- 1) A Tri-Domain ViT feature fusion framework integrating face-associated biometric representations, expression-related representations, and age-associated facial representations into a unified latent feature vector for intersectional demographic classification (Kerangka kerja fusi fitur Tri-Domain ViT yang mengintegrasikan representasi terkait biometrik wajah, representasi terkait ekspresi, dan representasi terkait usia wajah ke dalam vektor fitur laten terpadu untuk klasifikasi demografis interseksional).
- 2) An empirical comparative benchmark across multiple feature ablation schemes and classical machine learning classifiers optimized via Stratified Cross-Validation hyperparameter tuning, examining decision boundary behavior across linear, probabilistic, ensemble, and kernel-based models (Tolok ukur komparatif empiris melintasi berbagai skema ablasi fitur dan pengklasifikasi machine learning klasik yang dioptimalkan melalui penyetelan hyperparameter validasi silang berstrata, mengkaji perilaku batas keputusan antarmodel linier, probabilistic, ensemble, dan berbasis kernel).
- 3) Competitive classification performance on the Demog-Pairs dataset, with the proposed tri-domain representation outperforming the evaluated single-domain and dual-domain configurations for the majority of classifiers (Capaian performa klasifikasi kompetitif pada dataset DemogPairs, dengan representasi tri-domain yang diusulkan mengungguli konfigurasi domain tunggal dan domain ganda yang dievaluasi pada mayoritas pengklasifikasi).
- 4) A granular intersectional subgroup performance analysis, evaluating subgroup-level classification performance across six demographic subgroups, providing an in-depth characterization of model behaviors across racial and gender intersections while systematically revealing the consistency of multi-domain feature representations on independent evaluation cohorts (Analisis performa subkelompok interseksional granular yang mengevaluasi performa klasifikasi di keenam subkelompok demografis, memberikan karakterisasi mendalam mengenai perilaku model melintasi persilangan ras dan gender sekaligus mengungkap secara sistematis konsistensi representasi fitur multi-domain pada kohort evaluasi independen).

Sistematika penulisan artikel ini disusun sebagai berikut: Section II membahas penelitian terdahulu mengenai pengenalan demografis wajah dan arsitektur transformer. Sec-

tion III menjabarkan spesifikasi dataset DemogPairs, ekstraksi representasi multi-domain ViT, dan pipeline klasifikasi teroptimasi. Section IV memaparkan hasil evaluasi eksperimental, studi ablasi fitur, serta analisis performa subkelompok interseksional. Terakhir, Section V merangkum kesimpulan utama penelitian, keterbatasan metodologis, dan rekomendasi arah riset mendatang.

II. RELATED WORKS

Perkembangan pengenalan atribut demografis wajah beralih dari deskriptor berbasis region dan ciri buatan tangan menuju representasi mendalam. Pendekatan berbasis region lokal memanfaatkan geometri bagian tengah wajah untuk mengenali etnisitas dan mengurangi interferensi latar belakang [11]. Namun, pendekatan CNN masih menghadapi tantangan dalam mempertahankan performa terhadap variasi pencahayaan dan perbedaan karakteristik wajah antarkelompok ras, termasuk fenomena Other-Race Effect. Peningkatan kedalaman jaringan konvolusi dapat memperkaya representasi fitur visual untuk membedakan populasi yang beragam [13]. Selain itu, mekanisme berbagi fitur paralel dengan atensi visual dikembangkan untuk menangkap keterkaitan antaratribut wajah sekaligus mengurangi keterbatasan representasi lokal. Pendekatan ini menunjukkan pergeseran dari rekayasa fitur menuju pembelajaran representasi yang lebih adaptif terhadap keragaman wajah [16].

Penerapan ViT dalam biometrik wajah memberikan kemampuan pemodelan visual yang berbeda dari pendekatan konvolusional. Melalui mekanisme Multi-Head Self-Attention (MHSA), transformer dapat memodelkan hubungan antarpatch secara global sehingga menangkap dependensi spasial yang lebih luas dibandingkan operasi konvolusi lokal [14]. Karakteristik tersebut menunjukkan potensi transformer dalam memodelkan atribut demografis, termasuk gender, pada citra wajah beresolusi terstandarisasi [17]. Selain ViT standar, arsitektur hibrida seperti MaxViT menggabungkan perhatian berbasis jendela dan kisi untuk membangun representasi spasial secara bertingkat [18]. Meskipun transformer memiliki kemampuan representasi global yang kuat, performanya tetap dipengaruhi oleh kualitas, ukuran, dan karakteristik distribusi data latih yang digunakan dalam proses pembelajaran.

Investigasi terhadap disparitas performa dalam sistem visi komputer mendorong penggunaan protokol evaluasi yang mempertimbangkan keseimbangan distribusi kelas dan subkelompok demografis. Pengujian pada dataset yang seimbang dapat menyediakan kondisi eksperimen yang lebih terkontrol untuk membandingkan performa antarsubkelompok dengan mengurangi pengaruh ketimpangan jumlah sampel. Namun, keseimbangan distribusi tidak serta-merta menghilangkan bias sosial yang melekat pada data. Analisis representasi laten juga menunjukkan bahwa model transformer dapat mereproduksi bias sosial yang berasal dari korpus pra-latih berskala besar [14]. Untuk mengurangi disparitas performa antarkelompok ras dan gender, augmentasi generatif berbasis StyleGAN2 digunakan untuk menghasilkan variasi sintesis

yang dapat membantu mengurangi kesalahan klasifikasi [15]. Temuan tersebut menegaskan pentingnya evaluasi lintas subkelompok demografis secara sistematis.

Keterbatasan representasi berbasis satu domain dalam menangkap keragaman karakteristik wajah mendorong eksplorasi pembelajaran multi-tugas dan fusi representasi dari berbagai sumber informasi. Pendekatan multi-tugas digunakan untuk mempelajari keterkaitan antara atribut usia dan gender melalui representasi wajah yang diproses secara bersama [12]. Mekanisme berbagi representasi paralel juga dikembangkan untuk mengombinasikan berbagai atribut afektif secara simultan, sedangkan pendekatan generatif dapat memperkaya variasi fitur antarkelompok demografis [16], [15]. Lebih lanjut, integrasi fitur laten berbasis ViT yang memadukan representasi biometrik wajah dan ekspresi emosi menunjukkan potensi untuk meningkatkan klasifikasi atribut interseksional [19]. Penggabungan representasi biometrik dengan informasi usia juga memperlihatkan kontribusi informasi yang saling melengkapi, sehingga fusi lintas domain menjadi pendekatan yang relevan [20].

Setelah representasi fitur diperoleh, pemilihan classifier hilir memengaruhi cara fitur berdimensi tinggi dipetakan ke ruang keputusan. Pendekatan end-to-end umumnya menggunakan lapisan SoftMax untuk memetakan representasi fitur ke probabilitas kelas secara langsung [11], [18]. Sebagai alternatif, Support Vector Machine (SVM) dapat mempelajari batas keputusan nonlinier pada ruang fitur tanpa memperbarui parameter backbone yang telah dibekukan [13]. Model ensemble berbasis pohon seperti RF dan pendekatan probabilistik seperti GNB juga dapat digunakan sebagai classifier dengan karakteristik kompleksitas dan pemisahan kelas yang berbeda [12]. Perbedaan tersebut menunjukkan bahwa pemilihan classifier dapat memengaruhi efektivitas pemanfaatan representasi laten, khususnya ketika fitur berasal dari beberapa domain dan memiliki dimensi yang tinggi.

Berdasarkan literatur tersebut, masih terdapat ruang untuk mengeksplorasi pemodelan atribut demografis wajah melalui integrasi representasi dari beberapa domain. Berbeda dari studi terdahulu yang umumnya menggunakan representasi domain tunggal atau menggabungkan sebagian domain, penelitian ini mengusulkan fusi tri-domain yang memadukan representasi geometri biometrik wajah, isyarat afektif ekspresi, dan karakteristik morfologi penuaan biologis menggunakan model ViT pra-latih dengan backbone yang dibekukan. Representasi laten dari ketiga domain kemudian dikonkatenasi dan digunakan sebagai masukan bagi SVM untuk mempelajari batas keputusan nonlinier. Evaluasi dilakukan pada dataset DemogPairs yang seimbang untuk membandingkan klasifikasi ras dan gender secara interseksional serta menganalisis disparitas performa antarsubkelompok secara sistematis pada setiap kelompok yang dievaluasi.

III. MATERIALS AND METHODS

Kerangka kerja yang diusulkan memadukan representasi visual multi-domain dan optimasi model pembelajaran mesin untuk klasifikasi ras dan gender interseksional, sebagaimana




FIGURE 1. End-to-End Framework of the Proposed Multi-Domain Vision Transformer Feature Fusion and Classical Classifier Optimization for Intersectional Race and Gender Classification.

diilustrasikan pada Figure 1. Metodologi diawali pemisahan citra wajah 224×224 piksel pada dataset DemogPairs menjadi partisi latih dan uji via stratified split. Tiga model ViT-Base pre-trained yang dibekukan mengekstraksi representasi laten berdimensi 768 dari token [CLS] secara offline. Ketiga vektor digabungkan melalui fusi konkatenasi $z_{tri} = f_{face} \oplus f_{emotion} \oplus f_{age}$, di mana z_{tri} menyatakan vektor tri-domain berdimensi 2,304, $\oplus$ adalah operator konkatenasi, serta f_{face} , $f_{emotion}$, dan f_{age} merepresentasikan fitur biometrik wajah, ekspresi, dan usia. Vektor representasi diproses dalam pipeline modular Scaler dan PCA sebelum diklasifikasikan ke enam kelas interseksional oleh RF, GNB, LR, dan SVM. Penalaan hyperparameter dijalankan melalui 5-Fold Stratified Cross-Validation dengan skema GridSearchCV terisolasi untuk mencegah kebocoran informasi sebelum evaluasi data uji.

A. DATASET

Dataset yang digunakan dalam penelitian ini adalah DemogPairs [25], sebuah dataset yang dirancang khusus untuk pengenalan wajah lintas kelompok demografis. Dataset ini memuat total 10,800 citra wajah yang terdistribusi secara seimbang ke dalam enam kelas interseksional. Keenam subkelompok tersebut mencakup kombinasi persilangan dari tiga kelompok ras makro dan dua kelompok gender, yaitu Asian Females, Asian Males, Black Females, Black Males, White Females, dan White Males, dengan kuota tepat 1,800 citra per kelas. Distribusi yang seimbang ini menyediakan kondisi evaluasi yang lebih terkontrol untuk membandingkan performa antarsubkelompok dengan mengurangi pengaruh ketimpangan jumlah sampel [20]. Sampel visual dari keenam subkelompok demografis diilustrasikan pada Figure 2.

Untuk memastikan integritas pengujian empiris, dataset

TABLE 1. Dataset Partition and Demographic Subgroup Distribution.

Subgroup	Train Set (80%)	Test Set (20%)	Total
Black_Males	1,440	360	1,800
White_Females	1,440	360	1,800
Asian_Males	1,440	360	1,800
White_Males	1,440	360	1,800
Black_Females	1,440	360	1,800
Asian_Females	1,440	360	1,800
Total	8,640	2,160	10,800

dibagi menggunakan prosedur stratified split 80/20 (80% data latih dan 20% data uji). Pembagian tersebut menghasilkan 8,640 citra latih dengan 1,440 sampel per kelas serta 2,160 citra uji independen dengan 360 sampel per kelas, sebagaimana dirinci pada Table 1. Subset uji tersebut diisolasi secara ketat, tidak pernah dilibatkan selama proses pencarian hyperparameter, dan hanya digunakan untuk evaluasi akhir. Pada tahapan standarisasi citra, setiap citra wajah dikonversi ke dalam format 3-channel Red, Green, Blue (RGB), diubah ukurannya ke resolusi 224×224 piksel, dan diskalakan intensitas pikselnya dari rentang $[0, 255]$ menjadi $[0, 1]$ agar selaras dengan masukan model transformer.

B. VISION TRANSFORMER

Arsitektur ekstraksi representasi visual penelitian ini mengadopsi ViT-Base sebagaimana diilustrasikan pada Figure 3 [26]. Citra wajah masukan berukuran 224×224 piksel dengan 3 saluran warna dibagi menjadi 196 patch spasial non-overlapping x_p^i berukuran 16×16 piksel [27]. Setiap patch diproyeksikan secara linier melalui matriks E ke ruang laten berdimensi $D = 768$, lalu dirangkaikan dengan token ke-



FIGURE 2. Sample Images of the DemogPairs Dataset across Six Intersectional Demographic Subgroups: (a) Asian Females, (b) Asian Males, (c) Black Females, (d) Black Males, (e) White Females, and (f) White Males.




FIGURE 3. Architecture of the ViT Backbone and Patch Projection.

las $\mathbf{x}_{\text{class}}$ dan embedding posisi $\mathbf{E}_{\text{pos}}$ sesuai (1) [27]. Vektor sekuen token awal $\mathbf{z}_0$ dialirkan ke tumpukan 12 layer transformer encoder identik. Setiap layer encoder ℓ memproses masukan $\mathbf{z}_{\ell-1}$ menjadi representasi antara $\mathbf{z}'_{\ell}$ melalui mekanisme MHSA setelah operasi Layer Normalization (LN) sesuai (2), yang dilanjutkan menuju representasi luaran $\mathbf{z}_{\ell}$ melalui blok Multi-Layer Perceptron (MLP) dua lapis beraktivasi GeLU berdasarkan (3) [28]. Mekanisme self-attention memungkinkan pemodelan hubungan global antarpatch wajah tanpa ketergantungan pada receptive field lokal seperti pada operasi konvolusi [29].

$$\mathbf{z}_0 = [\mathbf{x}_{\text{class}}; \mathbf{x}_p^1 \mathbf{E}; \dots; \mathbf{x}_p^{196} \mathbf{E}] + \mathbf{E}_{\text{pos}} \quad (1)$$

$$\mathbf{z}'_{\ell} = \text{MHSA}(\text{LN}(\mathbf{z}_{\ell-1})) + \mathbf{z}_{\ell-1} \quad (2)$$

$$\mathbf{z}_{\ell} = \text{MLP}(\text{LN}(\mathbf{z}'_{\ell})) + \mathbf{z}'_{\ell} \quad (3)$$

TABLE 2. Multi-Domain Feature Fusion and Ablation Configurations.

#	Configuration	Domain Category	Dimension
1	Face	Single-Domain	768
2	Emotion	Single-Domain	768
3	Age	Single-Domain	768
4	Emotion $\oplus$ Face	Dual-Domain	1,536
5	Face $\oplus$ Age	Dual-Domain	1,536
6	Emotion $\oplus$ Age	Dual-Domain	1,536
7	Face $\oplus$ Emotion $\oplus$ Age	Tri-Domain (Proposed)	2,304

Untuk mempertahankan efisiensi komputasi dan mencegah variabilitas pelatihan ulang, ketiga model backbone

ViT dibekukan (frozen) sebagai penyedia task-associated representations secara offline. Model ViT-Face (skutaada/VIT-VGGFace) menangkap representasi terkait geometri biometrik wajah, ViT-Emotion (dima806/facial_emotions_image_detection) menghasilkan representasi terkait ekspresi wajah, dan ViT-Age (dima806/facial_age_image_detection) mengekstraksi representasi terkait estimasi usia wajah. Dari setiap model domain, vektor fitur $\mathbf{f}_{\text{domain}} \in \mathbb{R}^{768}$ diekstraksi dari representasi token [CLS] pada layer encoder terakhir L ($\mathbf{z}_L^0$) setelah operasi LN sesuai (4). Ketiga representasi laten domain tunggal tersebut digabungkan menjadi vektor fusi tri-domain $\mathbf{z}_{\text{tri}} \in \mathbb{R}^{2304}$ melalui operasi konkatenasi fitur ($\oplus$) dari vektor $\mathbf{f}_{\text{face}}$, $\mathbf{f}_{\text{emotion}}$, dan $\mathbf{f}_{\text{age}}$ sebagaimana dirumuskan pada (5). Eksplorasi sistematis mencakup tujuh skema ablasi fitur, yang meliputi tiga konfigurasi domain tunggal berdimensi 768, tiga konfigurasi domain ganda berdimensi 1,536, serta satu konfigurasi tri-domain berdimensi 2,304 seperti dirangkum pada Table 2.

$$\mathbf{f}_{\text{domain}} = \text{LN}(\mathbf{z}_L^0) \in \mathbb{R}^{768} \quad (4)$$

$$\mathbf{z}_{\text{tri}} = \mathbf{f}_{\text{face}} \oplus \mathbf{f}_{\text{emotion}} \oplus \mathbf{f}_{\text{age}} \in \mathbb{R}^{2304} \quad (5)$$

C. RANDOM FOREST

Model ensemble RF mengagregasikan prediksi sekumpulan pohon keputusan independen untuk mengklasifikasikan fitur wajah berdasarkan prinsip bootstrap aggregating (bagging) dan random subspace method [30]. Pendekatan ini mereduksi varians prediksi dengan membangun sebanyak B pohon klasifikasi dari sampel acak data latih [31]. Setiap percabangan node membatasi pemilihan fitur pada subset acak berukuran $\text{max_features} \in \{\text{'sqrt'}, \text{'log2'}\}$ untuk menekan korelasi antarpohon [32]. Kriteria pemisahan cabang mengoptimalkan indeks Gini impurity hingga memenuhi ambang batas minimum pemisahan node min_samples_split , batas kedalaman max_depth , atau batas minimum daun min_samples_leaf [33]. Mekanisme majority voting menentukan keputusan akhir sampel citra melintasi seluruh pohon keputusan [34]. Prosedur penalaan hyperparameter mengevaluasi kombinasi penskalaan fitur, reduksi dimensionalitas PCA, variasi jumlah pohon $n_{\text{estimators}}$, serta batasan pertumbuhan pohon, menghasilkan 288 konfigurasi grid dengan 1,440 total fits

TABLE 3. Hyperparameter Search Space for Random Forest Classifier.

Component / Hyperparameter	Evaluated Values	Count
Feature Scaler	None, MinMaxScaler	2
Dimensionality Reduction (PCA)	None, 0.50, 0.75	3
Number of Estimators	100, 200	2
Maximum Tree Depth	None, 20, 30	3
Feature Subspace	'sqrt', 'log2'	2
Minimum Samples Split	2, 5	2
Minimum Samples Leaf	1, 2	2
Total Grid Combinations		288 (1,440 fits)

melalui 5-Fold Stratified Cross-Validation sebagaimana dirangkum pada Table 3.

D. GAUSSIAN NAIVE BAYES

Berdasarkan Teorema Bayes, pengklasifikasi GNB mengestimasi probabilitas posterior kelas demografis interseksional dengan asumsi bahwa seluruh dimensi fitur kontinu bersifat independen secara bersyarat [35]. Fungsi kerapatan probabilitas distribusi normal memodelkan likelihood fitur kontinu terhadap kelas target sesuai formulasi pada (6), di mana x_i menyatakan nilai fitur kontinu ke- i , y adalah variabel label kelas, c merupakan kategori kelas target, serta $\mu_{c,i}$ dan $\sigma_{c,i}^2$ masing-masing merepresentasikan rata-rata (mean) dan varians fitur ke- i pada kelas c [35]:

$$P(x_i | y = c) = \frac{1}{\sqrt{2\pi\sigma_{c,i}^2}} \exp\left(-\frac{(x_i - \mu_{c,i})^2}{2\sigma_{c,i}^2}\right) \quad (6)$$

Penambahan parameter penghalusan `var_smoothing` menjaga stabilitas komputasi terhadap risiko varians mendekati nol pada ruang representasi laten berdimensi tinggi [36]. Prosedur penalaan hyperparameter melalui 5-Fold Stratified Cross-Validation mengevaluasi kombinasi penskalaan data, reduksi dimensionalitas PCA, serta 40 interval `var_smoothing` yang dieksplorasi secara logaritmik dari 1.0×10^{-9} hingga 1.0×10^2 , menghasilkan 240 kombinasi grid dengan total 1,200 proses fitting sebagaimana dipaparkan pada Table 4.

E. LOGISTIC REGRESSION

Pendekatan regresi multinomial (Softmax regression) pada LR memetakan representasi fitur laten ke dalam enam kategori demografis interseksional melalui estimasi probabilitas linier terpadu [37]. Fungsi probabilitas Softmax menghitung peluang bersyarat sampel terhadap kategori target sebagaimana didefinisikan pada (7), di mana $\mathbf{x}$ merepresentasikan vektor fitur masukan, y adalah variabel label kelas, c menyatakan kategori kelas target, $\mathbf{w}_c$ dan b_c masing-masing merupakan vektor bobot serta bias kelas c , sedangkan konstanta $K = 6$ menunjukkan jumlah total kelas interseksional [38]:

$$P(y = c | \mathbf{x}) = \frac{e^{\mathbf{w}_c^T \mathbf{x} + b_c}}{\sum_{j=1}^K e^{\mathbf{w}_j^T \mathbf{x} + b_j}} \quad (7)$$

Proses pembelajaran model meminimalkan fungsi kerugian cross-entropy dengan menyertakan penalti regularisasi L_2 untuk mengendalikan kompleksitas bobot pada ruang representasi berdimensi tinggi [39]. Pencarian hyperparameter terstruktur mengevaluasi variasi kekuatan regularisasi C , algoritma solver optimasi (lbfgs, saga, newton-cg), batas iterasi `max_iter`, serta integrasi penskalaan dan PCA, menghasilkan 270 kombinasi evaluasi atau 1,350 total fits pada protokol 5-Fold Stratified Cross-Validation yang disajikan pada Table 5.

F. SUPPORT VECTOR MACHINE

Pengklasifikasi SVM mengonstruksikan bidang pemisah berjarak terjauh (maximum margin hyperplane) untuk memisahkan enam kelas interseksional pada ruang representasi laten berdimensi tinggi [40]. Fungsi kernel memproyeksikan distribusi data nonlinier dari fusi multi-domain ke ruang fitur berdimensi lebih tinggi, mencakup opsi kernel linear, Radial Basis Function (RBF), dan polinomial [41]. Formulasi kernel polinomial derajat dua pada (8) menghitung produk titik $\langle \mathbf{x}_i, \mathbf{x}_j \rangle$ antara pasangan vektor fitur $\mathbf{x}_i$ dan $\mathbf{x}_j$, di mana γ menyatakan parameter penskalaan kernel, $d = 2$ menentukan derajat pemetaan, dan konstanta intercept `coef0 = 0.0` mengikuti nilai bawaan scikit-learn [42]:

$$K(\mathbf{x}_i, \mathbf{x}_j) = (\gamma \langle \mathbf{x}_i, \mathbf{x}_j \rangle + \text{coef0})^d, \quad d = 2 \quad (8)$$

Pemetaan kuadratik ini memfasilitasi penangkapan interaksi nonlinier antardimensi visual secara efisien [43].

Optimasi hyperparameter menelusuri rentang parameter penalti $C \in \{0.01, 0.1, 1, 10\}$, ragam fungsi kernel, koefisien γ , derajat polinomial, serta opsi penskalaan dan PCA, menghasilkan 288 kombinasi konfigurasi atau 1,440 total fits pada prosedur 5-Fold Stratified Cross-Validation sesuai Table 6.

G. CLASSIFICATION PIPELINE

Kerangka kerja pipeline modular menyatukan penskalaan fitur, reduksi dimensi representasi, dan estimasi model hilir ke dalam rantai transformasi terpadu. Rantai pemrosesan tersebut dirumuskan pada (9), di mana vektor fitur input $\mathbf{x}$ ditransformasikan oleh modul penskalaan menjadi $\tilde{\mathbf{x}}$, direduksi dimensinya melalui PCA menjadi $\hat{\mathbf{x}}$, dan dipetakan oleh pengklasifikasi menuju prediksi label $\hat{y} \in \{0, 1, 2, 3, 4, 5\}$ untuk enam subkelompok demografis:

$$\mathbf{x} \xrightarrow{\text{Scaler}} \tilde{\mathbf{x}} \xrightarrow{\text{PCA}} \hat{\mathbf{x}} \xrightarrow{\text{Classifier}} \hat{y} \in \{0, 1, 2, 3, 4, 5\} \quad (9)$$

TABLE 4. Hyperparameter Search Space for Gaussian Naive Bayes Classifier.

Component / Hyperparameter	Evaluated Values	Count
Feature Scaler	None, MinMaxScaler	2
Dimensionality Reduction (PCA)	None, 0.50, 0.75	3
Variance Smoothing	logspace($-9, 2, 40$) (1.0×10^{-9} to 1.0×10^2)	40
Total Grid Combinations		240 (1,200 fits)

TABLE 5. Hyperparameter Search Space for Logistic Regression Classifier.

Component / Hyperparameter	Evaluated Values	Count
Feature Scaler	None, MinMaxScaler	2
Dimensionality Reduction (PCA)	None, 0.50, 0.75	3
Regularization Strength	0.01, 0.1, 1, 10, 100	5
Optimization Solver	'lbfgs', 'saga', 'newton-cg'	3
Maximum Iterations	500, 1000, 2000	3
Total Grid Combinations		270 (1,350 fits)

TABLE 6. Hyperparameter Search Space for Support Vector Machine.

Component / Hyperparameter	Evaluated Values	Count
Feature Scaler	None, MinMaxScaler	2
Dimensionality Reduction (PCA)	None, 0.50, 0.75	3
Regularization Parameter	0.01, 0.1, 1, 10	4
Kernel Function	'linear', 'rbf', 'poly'	3
Polynomial Degree	2, 3	2
Kernel Coefficient	'scale', 'auto'	2
Total Grid Combinations		288 (1,440 fits)

Protokol validasi silang menerapkan skema 5-Fold Stratified Cross-Validation dengan pengacakan terkontrol untuk mempertahankan proporsi seimbang $\sim 16.67\%$ per kelas di setiap fold. Untuk mencegah kebocoran informasi, Scaler dan PCA di-fit secara eksklusif hanya pada data latih di dalam GridSearchCV sebelum diterapkan ke data validasi. Penelusuran terhadap 1,086 kombinasi hyperparameter menghasilkan 5,430 fits per skema fitur atau 38,010 total fits untuk tujuh konfigurasi representasi, serta 28 refit final sebelum pengujian pada data uji held-out independen.

H. EVALUATION METRICS

Evaluasi performa klasifikasi multi-kelas enam subkelompok demografis pada tingkat subkelompok dilakukan melalui skema biner One-vs-Rest (OvR) [44]. Skema ini memanfaatkan empat komponen matriks konfusi per kelas untuk menghitung Akurasi OvR, Presisi, Recall, dan F1-Score pada setiap kelas $c \in \{1, \dots, K\}$ [45]. Keempat komponen tersebut mencakup TP_c (True Positive), TN_c (True Negative), FP_c (False Positive), dan FN_c (False Negative) [46]. Akurasi OvR pada (10) mengukur rasio total prediksi benar terhadap seluruh data uji, sedangkan Presisi pada (11) dan Recall pada (12) memetakan ketepatan positif serta sensitivitas deteksi sistem per subkelompok [47]. F1-Score pada (13) dirumuskan sebagai rata-rata harmonik antara Presisi dan Recall untuk merepresentasikan keseimbangan evaluasi performa deteksi

per subkelompok [47].

$$\text{Accuracy}_c = \frac{TP_c + TN_c}{TP_c + TN_c + FP_c + FN_c} \quad (10)$$

$$\text{Precision}_c = \frac{TP_c}{TP_c + FP_c} \quad (11)$$

$$\text{Recall}_c = \frac{TP_c}{TP_c + FN_c} \quad (12)$$

$$\text{F1-Score}_c = \frac{2 \cdot \text{Precision}_c \cdot \text{Recall}_c}{\text{Precision}_c + \text{Recall}_c} \quad (13)$$

Untuk mengevaluasi efektivitas sistem klasifikasi secara menyeluruh pada data uji independen, metrik performa per subkelompok diagregasikan menjadi metrik evaluasi global. Pada formulasi ini, simbol N menyatakan total sampel data uji ($N = 2,160$), sedangkan K menyatakan jumlah total subkelompok demografis ($K = 6$). Akurasi Global (Overall Accuracy) pada (14) dihitung sebagai rasio total prediksi benar, yaitu penjumlahan elemen diagonal utama matriks konfusi $\sum_{c=1}^K TP_c$, terhadap total sampel data uji N .

$$\text{Accuracy}_{\text{Global}} = \frac{\sum_{c=1}^K TP_c}{N} \quad (14)$$

Selanjutnya, Presisi global (Macro Precision) pada (15), Recall global (Macro Recall) pada (16), dan F1-Score global (Macro F1-Score) pada (17) dihitung melalui perataan makro tanpa bobot (unweighted macro average) melintasi $K = 6$

subkelompok untuk memberikan bobot evaluasi yang setara pada setiap kelas demografis.

$$\text{Precision}_{\text{Global}} = \frac{1}{K} \sum_{c=1}^K \text{Precision}_c \quad (15)$$

$$\text{Recall}_{\text{Global}} = \frac{1}{K} \sum_{c=1}^K \text{Recall}_c \quad (16)$$

$$\text{F1-Score}_{\text{Global}} = \frac{1}{K} \sum_{c=1}^K \text{F1-Score}_c \quad (17)$$

IV. RESULTS AND DISCUSSION

A. GLOBAL PERFORMANCE ANALYSIS

Evaluasi performa RF melintasi tujuh konfigurasi fitur pada data uji DemogPairs disajikan pada Table 7. Hasil eksperimen empiris menunjukkan bahwa skema dual-domain Emotion $\oplus$ Face mencapai capaian tertinggi dengan Akurasi 86.85% dan F1-Score 86.82%. Sebaliknya, penggabungan tri-domain Face $\oplus$ Emotion $\oplus$ Age mengalami sedikit penurunan performa menjadi Akurasi 86.20% dan F1-Score 86.13%. Penurunan ini diinterpretasikan sebagai kemungkinan tantangan partisi ruang fitur berdimensi 2,304 melalui pemotongan pohon acak (random splits) [48]. Seluruh konfigurasi GridSearchCV secara konsisten memilih reduksi dimensionalitas PCA 0.75 untuk menyeimbangkan varians data. Pada kategori domain tunggal, fitur Face mencatatkan performa terbaik dengan Akurasi 85.46%, melampaui fitur domain Emotion sebesar 80.60% serta domain Age sebesar 73.66%.

Evaluasi performa klasifikasi probabilistik GNB pada tujuh variasi konfigurasi fitur dirangkum pada Table 8. Model GNB menunjukkan tren peningkatan performa yang konsisten dari kategori domain tunggal ke multi-domain. Pada domain tunggal, konfigurasi Age menghasilkan capaian terendah dengan Akurasi 69.63% dan F1-Score 69.52%, sedangkan fitur Face mencapai Akurasi 82.69%. Integrasi fitur pada kategori dual-domain meningkatkan akurasi secara konsisten, dipimpin oleh kombinasi Emotion $\oplus$ Face sebesar 84.86%. Puncak performa klasifikasi GNB tercapai pada konfigurasi tri-domain Face $\oplus$ Emotion $\oplus$ Age dengan Akurasi 85.05% dan F1-Score 85.05%. Seluruh konfigurasi fitur GNB secara seragam memilih reduksi dimensionalitas PCA 0.75 berdasarkan hasil GridSearchCV.

Hasil benchmark performa multinomial LR pada seluruh konfigurasi fitur dipaparkan pada Table 9. Karakteristik utama dari model LR adalah retensi representasi fitur penuh, di mana seluruh skema (tujuh dari tujuh konfigurasi) memilih tanpa reduksi PCA (pca=None) [49]. Evaluasi empiris menunjukkan bahwa konfigurasi tri-domain Face $\oplus$ Emotion $\oplus$ Age mencatatkan performa tertinggi dengan Akurasi 92.73% dan F1-Score 92.73% melalui parameter penalti $C = 0.1$ serta solver newton-cg. Capaian tri-domain ini melampaui konfigurasi dual-domain terbaik Emotion $\oplus$ Face yang meraih Akurasi 92.41% dan F1-Score 92.40%, serta mengungguli konfigurasi single-domain terbaik Face

dengan Akurasi 90.60%. Temuan ini mengindikasikan efektivitas regularisasi L_2 dalam menangani ruang fitur berdimensi tinggi tanpa kompresi komponen utama [50].

(Catatan: Parameter degree hanya aktif dan dilaporkan pada kernel poly; pada kernel rbf, parameter degree tidak aktif dan tidak dicantumkan pada naskah publikasi).

Perkembangan performa SVM melintasi seluruh tahapan ablasi fitur dirangkum pada Table 10. Serupa dengan model linier, seluruh konfigurasi SVM secara konsisten mempertahankan ruang representasi penuh tanpa reduksi PCA (pca=None). Evaluasi empiris memperlihatkan peningkatan performa berjenjang, dimulai dari konfigurasi domain tunggal terbaik Face dengan Akurasi 90.83% dan F1-Score 90.83%. Integrasi representasi pada skema dual-domain Emotion $\oplus$ Face meningkatkan performa dengan Akurasi 93.29% dan F1-Score 93.29%, sebelum akhirnya mencapai titik tertinggi pada konfigurasi tri-domain Face $\oplus$ Emotion $\oplus$ Age dengan Akurasi 93.70% dan F1-Score 93.69%. Pada hyperparameter, parameter degree bernilai 2 hanya aktif pada fungsi kernel poly, sedangkan model berbasis kernel RBF tidak mengaktifkan parameter tersebut [51].

Hasil 28 eksperimen pada Table 7, Table 8, Table 9, dan Table 10 menunjukkan bahwa SVM dengan fusi tri-domain Face $\oplus$ Emotion $\oplus$ Age memberikan performa tertinggi dalam seluruh konfigurasi yang diuji. Model tersebut mencapai Akurasi 93.70% dan F1-Score 93.69%. Jika dirata-ratakan pada tujuh konfigurasi fitur, SVM memperoleh Akurasi 91.47%, diikuti oleh LR 90.40%, RF 82.81%, dan GNB 79.37%. Pada konfigurasi SVM tri-domain, GridSearchCV memilih kernel polinomial derajat 2 sebagai konfigurasi terbaik. Temuan ini berlaku pada data dan ruang pencarian yang digunakan, sehingga tidak dapat diartikan sebagai keunggulan universal kernel polinomial. Perbandingan tersebut bersifat deskriptif dan tidak membuktikan superioritas statistik suatu classifier karena penelitian ini tidak melakukan pengujian hipotesis formal.

B. FEATURE ABLATION STUDY

Kuantifikasi perubahan akurasi klasifikasi dari skema domain tunggal menuju konfigurasi ganda dan tiga domain dirangkum pada Table 7, Table 8, Table 9, dan Table 10. Pada model SVM, transisi representasi dari Face (90.83%) ke Emotion $\oplus$ Face (93.29%) meningkatkan akurasi sebesar 2.46%. Penambahan domain ketiga pada konfigurasi tri-domain Face $\oplus$ Emotion $\oplus$ Age menghasilkan peningkatan performa lebih lanjut menjadi 93.70%, yang mencerminkan peningkatan kumulatif sebesar 2.87% di atas fitur tunggal Face. Pola peningkatan progresif ini mengindikasikan kehadiran informasi diskriminatif tambahan dari setiap domain representasi visual yang digabungkan, meskipun mekanisme interaksi antardimensi fitur laten tidak dapat dipastikan hanya dari hasil pengujian empiris.

Analisis kontribusi representasi domain usia (Age) membedah peranan informasi laten penuaan dalam sistem klasifikasi demografis. Pada seluruh pengklasifikasi yang dievaluasi, Age merupakan konfigurasi single-domain dengan ca-

TABLE 7. Performance Benchmark of Random Forest across Seven Feature Configurations.

Configuration	Accuracy	Precision	Recall	F1-Score	Best Parameters
Face	85.46%	85.43%	85.46%	85.39%	$n_est=200$, $depth=30$, $max_feat=log2$, $min_split=2$, $min_leaf=1$, $pca=PCA(0.75)$, $scaler=MinMaxScaler$
Emotion	80.60%	80.63%	80.60%	80.57%	$n_est=200$, $depth=None$, $max_feat=log2$, $min_split=5$, $min_leaf=1$, $pca=PCA(0.75)$, $scaler=None$
Age	73.66%	73.63%	73.66%	73.54%	$n_est=200$, $depth=30$, $max_feat=log2$, $min_split=2$, $min_leaf=1$, $pca=PCA(0.75)$, $scaler=None$
Emotion $\oplus$ Face	86.85%	86.89%	86.85%	86.82%	$n_est=200$, $depth=None$, $max_feat=sqrt$, $min_split=5$, $min_leaf=1$, $pca=PCA(0.75)$, $scaler=None$
Face $\oplus$ Age	85.79%	85.78%	85.79%	85.73%	$n_est=200$, $depth=None$, $max_feat=sqrt$, $min_split=2$, $min_leaf=1$, $pca=PCA(0.75)$, $scaler=None$
Emotion $\oplus$ Age	81.11%	81.11%	81.11%	81.08%	$n_est=200$, $depth=None$, $max_feat=log2$, $min_split=5$, $min_leaf=2$, $pca=PCA(0.75)$, $scaler=None$
Face $\oplus$ Emotion $\oplus$ Age	86.20%	86.20%	86.20%	86.13%	$n_est=200$, $depth=30$, $max_feat=sqrt$, $min_split=5$, $min_leaf=1$, $pca=PCA(0.75)$, $scaler=None$

TABLE 8. Performance Benchmark of Gaussian Naive Bayes across Seven Feature Configurations.

Configuration	Accuracy	Precision	Recall	F1-Score	Best Parameters
Face	82.69%	82.71%	82.69%	82.58%	$var_smoothing=4.1246e-02$, $pca=PCA(0.75)$, $scaler=MinMaxScaler$
Emotion	73.38%	73.87%	73.38%	73.29%	$var_smoothing=3.0703e-03$, $pca=PCA(0.75)$, $scaler=None$
Age	69.63%	69.79%	69.63%	69.52%	$var_smoothing=4.3755e-04$, $pca=PCA(0.75)$, $scaler=MinMaxScaler$
Emotion $\oplus$ Face	84.86%	84.90%	84.86%	84.81%	$var_smoothing=5.8780e-03$, $pca=PCA(0.75)$, $scaler=MinMaxScaler$
Face $\oplus$ Age	83.15%	83.43%	83.15%	83.17%	$var_smoothing=1.1253e-02$, $pca=PCA(0.75)$, $scaler=MinMaxScaler$
Emotion $\oplus$ Age	76.81%	76.86%	76.81%	76.81%	$var_smoothing=1.6037e-03$, $pca=PCA(0.75)$, $scaler=MinMaxScaler$
Face $\oplus$ Emotion $\oplus$ Age	85.05%	85.12%	85.05%	85.05%	$var_smoothing=5.8780e-03$, $pca=PCA(0.75)$, $scaler=None$

paian akurasi terendah, seperti tercatat sebesar 87.64% pada SVM dan 69.63% pada GNB. Namun demikian, penggabungan fitur Age dengan fitur biometrik wajah pada skema dual-domain Face $\oplus$ Age menghasilkan akurasi 92.55%, yang memberikan peningkatan sebesar 1.72% di atas performa fitur Face murni (90.83%) pada model SVM. Hasil empiris tersebut menunjukkan kemungkinan adanya informasi diskriminatif tambahan dari age-associated representations yang melengkapi profil morfologi wajah, tanpa mengklaim bahwa kontribusi informasi tersebut bersifat ortogonal atau komplementer mutlak secara teoretis.

C. INTERSECTIONAL SUBGROUP PERFORMANCE

Profil kinerja klasifikasi granular pada model terbaik SVM berbasis fusi tri-domain Face $\oplus$ Emotion $\oplus$ Age dievaluasi secara mendalam berdasarkan metrik OvR sebagaimana disajikan pada Table 11. Seluruh subkelompok demografis berhasil mencapai F1-Score melampaui 91.00%, dengan rentang capaian bergerak dari 91.74% pada Black Females hingga 96.14% pada White Males, sehingga menghasilkan selisih disparitas rentang sebesar 4.40%. Sementara itu, nilai Akurasi OvR berada pada rentang 97.31% hingga 98.70% dengan disparitas sebesar 1.39 pp. Perlu dicatat secara metodologis bahwa tingginya nilai Akurasi OvR tersebut turut dipengaruhi oleh rasio dominansi sampel negatif sebesar

5:1 pada evaluasi biner OvR, sehingga metrik ini tidak diposisikan sebagai indikator tunggal disparitas kinerja.

Perbandingan profil kinerja subkelompok antara model SVM dan pengklasifikasi linier LR pada konfigurasi tri-domain disajikan pada Table 11. Model LR tri-domain turut memperlihatkan konsistensi performa yang tinggi dengan capaian F1-Score melampaui 91.00% pada seluruh kelas demografis, yang merentang dari 91.36% pada Asian Females hingga 95.58% pada White Males dengan selisih disparitas rentang sebesar 4.22%. Subkelompok White Males secara konsisten mencatatkan performa klasifikasi tertinggi pada kedua pengklasifikasi tersebut. Temuan empiris ini membuktikan bahwa fusi representasi tri-domain menghasilkan representasi visual yang tangguh dan terdistribusi stabil melintasi seluruh subkelompok demografis, baik pada model linier maupun model non-linier. Meskipun demikian, evaluasi subkelompok ini mencerminkan kinerja granular per kelas dan bukan audit keadilan algoritmik komprehensif.

D. ERROR PATTERN ASSESSMENT

Pergeseran distribusi kesalahan klasifikasi dari skema domain tunggal menuju konfigurasi ganda dan tiga domain dianalisis melalui diagram matriks konfusi pada Figure 4, yang mencakup Figure 4(a), Figure 4(b), dan Figure 4(c). Evaluasi empiris menunjukkan bahwa total misklasifikasi pada 2,160

TABLE 9. Performance Benchmark of Logistic Regression across Seven Feature Configurations.

Configuration	Accuracy	Precision	Recall	F1-Score	Best Parameters
Face	90.60%	90.60%	90.60%	90.59%	$C = 1$, solver=newton-cg, max_iter=500, pca=None, scaler=MinMaxScaler
Emotion	88.47%	88.50%	88.47%	88.46%	$C = 1$, solver=saga, max_iter=500, pca=None, scaler=MinMaxScaler
Age	86.48%	86.49%	86.48%	86.48%	$C = 0.1$, solver=lbfgs, max_iter=500, pca=None, scaler=None
Emotion $\oplus$ Face	92.41%	92.41%	92.41%	92.40%	$C = 0.1$, solver=lbfgs, max_iter=500, pca=None, scaler=None
Face $\oplus$ Age	91.62%	91.62%	91.62%	91.62%	$C = 0.1$, solver=newton-cg, max_iter=500, pca=None, scaler=None
Emotion $\oplus$ Age	90.51%	90.52%	90.51%	90.51%	$C = 0.1$, solver=lbfgs, max_iter=500, pca=None, scaler=None
Face $\oplus$ Emotion $\oplus$ Age	92.73%	92.75%	92.73%	92.73%	$C = 0.1$, solver=newton-cg, max_iter=500, pca=None, scaler=None

TABLE 10. Performance Benchmark of Support Vector Machine across Seven Feature Configurations.

Configuration	Accuracy	Precision	Recall	F1-Score	Best Parameters
Face	90.83%	90.84%	90.83%	90.83%	$C = 10$, rbf, γ =scale, pca=None, scaler=None
Emotion	90.19%	90.20%	90.19%	90.17%	$C = 10$, rbf, γ =scale, pca=None, scaler=None
Age	87.64%	87.67%	87.64%	87.65%	$C = 10$, rbf, γ =scale, pca=None, scaler=None
Emotion $\oplus$ Face	93.29%	93.33%	93.29%	93.29%	$C = 10$, rbf, γ =scale, pca=None, scaler=MinMaxScaler
Face $\oplus$ Age	92.55%	92.54%	92.55%	92.54%	$C = 10$, poly, γ =scale, deg=2, pca=None, scaler=None
Emotion $\oplus$ Age	92.08%	92.10%	92.08%	92.09%	$C = 10$, rbf, γ =scale, pca=None, scaler=None
Face $\oplus$ Emotion $\oplus$ Age	93.70%	93.72%	93.70%	93.69%	$C = 10$, poly, γ =scale, deg=2, pca=None, scaler=None

TABLE 11. Subgroup-Level Performance for Tri-Domain Models.

Classifier	Subgroup	Recall	Precision	F1-Score	OvR Accuracy
SVM (Tri)	White Males	96.94%	95.36%	96.14%	98.70%
	Black Males	94.17%	95.49%	94.83%	98.29%
	White Females	94.72%	92.41%	93.55%	97.82%
	Asian Males	94.44%	92.39%	93.41%	97.78%
	Asian Females	92.50%	92.50%	92.50%	97.50%
	Black Females	89.44%	94.15%	91.74%	97.31%
LR (Tri)	White Males	96.11%	95.05%	95.58%	98.52%
	Black Males	93.06%	95.71%	94.37%	98.15%
	White Females	92.22%	91.21%	91.71%	97.22%
	Asian Males	92.78%	90.76%	91.76%	97.22%
	Asian Females	91.11%	91.62%	91.36%	97.13%
	Black Females	91.11%	92.13%	91.62%	97.22%

data uji held-out menurun secara konsisten seiring perluasan domain representasi laten. Model SVM domain tunggal Face menghasilkan 198 kesalahan prediksi, yang kemudian berkurang menjadi 145 sampel pada skema dual-domain Emotion $\oplus$ Face. Konfigurasi tri-domain Face $\oplus$ Emotion $\oplus$ Age menekan kesalahan klasifikasi hingga mencapai titik terendah sebesar 136 sampel. Penurunan kesalahan yang konsisten ini mengindikasikan bahwa fusi representasi multi-domain mempertegas batas pemisahan antar-subkelompok demografis di ruang fitur laten.

Pemeriksaan mendalam terhadap matriks konfusi model domain tunggal Face pada Figure 4(a) mengungkap bahwa kesalahan klasifikasi terkonsentrasi secara dominan pada subkelompok antarras dalam gender yang sama. Kecenderungan tersebut terlihat sangat menonjol pada kohort wanita, di mana subkelompok Asian Females mengalami 46 misklasifikasi, yang mencakup 16 sampel terprediksi sebagai White Females dan 16 sampel sebagai Black Females. Sebaliknya, subkelompok White Females mencatatkan 20 kesalahan prediksi yang terdistribusi ke Asian Females. Pola empiris ini kon-




FIGURE 4. Confusion Matrices across Feature Fusion Schemes on the Held-Out Test Set: (a) Single-Domain (Face), (b) Dual-Domain (Emotion $\oplus$ Face), and (c) Tri-Domain (Face $\oplus$ Emotion $\oplus$ Age).

sisten dengan kemungkinan adanya tumpang tindih fenotipe (phenotypic overlap) antarras pada representasi geometri biometrik wajah tunggal [18]. Meskipun demikian, bukti matriks konfusi tersebut tidak membuktikan bahwa faktor tumpang tindih visual merupakan penyebab tunggal dari seluruh misklasifikasi yang teramati.

Perubahan distribusi kesalahan klasifikasi pada model dual-domain Emotion $\oplus$ Face dianalisis lebih lanjut berdasarkan matriks konfusi pada Figure 4(b). Penambahan representasi laten ekspresi afektif secara efektif mereduksi pola misklasifikasi antarras pada subkelompok bergender sama, terutama pada kelompok wanita. Kesalahan prediksi dari Asian Females ke White Females berhasil ditekan secara nyata dari 16 kasus menjadi 9 kasus. Pada saat yang bersamaan, jumlah sampel prediksi benar (true positive) pada subkelompok White Females meningkat dari 325 citra menjadi 334 citra. Integrasi sinyal dinamis ekspresi wajah tersebut memperkuat batas pembeda visual antarras dalam ruang representasi laten, sehingga pengklasifikasi mampu membedakan fitur morfologi yang serupa dengan tingkat kepastian yang lebih kokoh dan stabil.

Pola misklasifikasi pada konfigurasi tri-domain Face $\oplus$ Emotion $\oplus$ Age dievaluasi secara komprehensif berdasarkan matriks konfusi pada Figure 4(c). Integrasi representasi domain usia meningkatkan jumlah prediksi benar secara konsisten pada subkelompok Asian Females menjadi 333 sampel dan White Females menjadi 341 sampel. Selain itu, kesalahan klasifikasi lintas gender, yaitu kondisi ketika subjek wanita tertukar menjadi pria atau sebaliknya, hanya berjumlah 51 kasus dari total 2,160 data uji held-out (2.36%). Temuan empiris ini mengindikasikan bahwa batas antargender terpisah dengan sangat tegas di dalam ruang representasi laten multi-domain, sehingga kesalahan klasifikasi yang tersisa pada model tri-domain hampir seluruhnya didominasi oleh misklasifikasi antarras di dalam kelompok gender yang sama.

E. COMPARISON WITH PRIOR STUDIES

Perbandingan empiris secara langsung antara kerangka kerja yang diusulkan dan studi terdahulu yang dievaluasi pada

TABLE 12. Comparative Performance of Proposed Framework against Prior Studies on the DemogPairs Dataset.

Model	Accuracy	Precision	Recall	F1-Score
MD-ViT [20]	89.07%	89.12%	89.07%	89.01%
Dual-ViT [19]	92.41%	92.48%	92.41%	92.38%
Ours	93.70%	93.72%	93.70%	93.69%

dataset DemogPairs dirangkum pada Table 12. Model usulan berbasis Tri-Domain ViT + SVM (Face $\oplus$ Emotion $\oplus$ Age) meraih Akurasi 93.70%, Presisi 93.72%, Recall 93.70%, dan F1-Score 93.69%. Capaian kuantitatif tersebut melampaui metrik yang dilaporkan pada model Dual-ViT + SVM, yaitu Akurasi 92.41% dan F1-Score 92.38%, serta model MD-ViT + XGBoost dengan Akurasi 89.07% dan F1-Score 89.01% [19], [20]. Seluruh angka pembandingan disitasi langsung dari publikasi masing-masing, sehingga komparasi ini berfungsi sebagai penempatan kontekstual pada dataset acuan yang sama dan tidak dimaksudkan sebagai replikasi eksperimen yang sepenuhnya identik.

Penelitian seminal mengenai perancangan dataset DemogPairs meletakkan landasan penting dalam mengukur dampak ketidakseimbangan demografis pada sistem pengenalan wajah [25]. Menanggapi tantangan tersebut, kerangka kerja integrasi representasi tiga domain yang diusulkan dalam penelitian ini menghasilkan akurasi tertinggi di antara studi-studi yang dibandingkan pada dataset DemogPairs [19], [20]. Selain mengevaluasi metrik agregat global, penyelidikan ini menjalankan analisis disparitas subkelompok secara komprehensif pada konfigurasi tri-domain terbaik untuk memetakan variasi performa antarsubkelompok demografis secara transparan. Evaluasi terperinci tersebut membuktikan stabilitas pengenalan lintas kategori ras dan gender interseksional, meskipun perbandingan disparitas lintas seluruh skema sebelumnya tidak dapat disertakan karena informasi variasi performa tersebut tidak dilaporkan dalam literatur terkait [19], [20].

V. CONCLUSION

Penelitian ini mengevaluasi kerangka kerja fusi representasi laten Tri-Domain ViT (Face $\oplus$ Emotion $\oplus$ Age: 2,304 dimensi) untuk klasifikasi ras dan gender interseksional pada dataset DemogPairs. Hasil eksperimen menunjukkan bahwa fusi tri-domain menjadi konfigurasi terbaik pada 3 dari 4 classifier yang dievaluasi, mencakup SVM, LR, dan GNB. Dalam search space yang dievaluasi, model SVM teroptimasi dengan hyperparameter $C = 10$ dan kernel polinomial derajat dua menghasilkan performa klasifikasi tertinggi, yakni Akurasi 93.70% serta F1-Score 93.69%. Meskipun demikian, manfaat integrasi representasi multi-domain terbukti bersifat classifier-dependent karena RF justru meraih performa puncak pada skema dual-domain Emotion $\oplus$ Face dengan akurasi 86.85%. Di samping itu, evaluasi kinerja subkelompok mengonfirmasi bahwa nilai F1-Score pada keenam subkelompok demografis terdistribusi stabil pada rentang 91.74% hingga 96.14%.

Terlepas dari capaian tersebut, penelitian ini memiliki sejumlah keterbatasan yang membuka peluang riset lanjutan. Pertama, cakupan demografis penyelidikan ini terbatas pada tiga kelompok ras makro (Asian, Black, dan White) pada dataset DemogPairs, sehingga temuan empiris yang diperoleh tidak dapat digeneralisasikan secara langsung ke populasi multirasial maupun kelompok etnisitas lain tanpa pengujian komprehensif tambahan. Kedua, ekstraksi representasi laten dijalankan secara terpisah (offline) memanfaatkan backbone ViT pra-latih yang dibekukan tanpa fine-tuning end-to-end secara simultan. Ketiga, evaluasi eksperimental masih berfokus pada citra lingkungan laboratorium terkontrol, sehingga respons model terhadap variasi pose ekstrem, oklusi, dan pencahayaan liar (in-the-wild) memerlukan pengujian lebih jauh. Oleh karena itu, arah penelitian mendatang disarankan untuk mengeksplorasi mekanisme fusi atensi adaptif lintas-modal (cross-attention transformer fusion) yang dilatih secara end-to-end untuk mempelajari bobot interaksi dinamis antardomain, serta memperluas pengujian pada dataset berskala besar yang lebih heterogen seperti FairFace atau UTKFace. Selain itu, penerapan metode visual explainability seperti Attention Rollout atau Grad-CAM sangat diperlukan untuk memetakan kontribusi spasial tiap domain secara transparan, disertai penegakan tata kelola etika kecerdasan buatan (Responsible AI) dengan pengawasan manusia (human-in-the-loop) untuk mencegah eksploitasi pada sistem pengawasan publik.

REFERENCES

- [1] M. K. Rusia and D. K. Singh, "A comprehensive survey on techniques to handle face identity threats: challenges and opportunities," *Multimedia Tools and Applications*, vol. 82, no. 2, pp. 1669–1748, Jan. 2023.
- [2] B. Meden *et al.*, "Privacy-enhancing face biometrics: a comprehensive survey," *IEEE Transactions on Information Forensics and Security*, vol. 16, pp. 4147–4183, 2021.
- [3] A. Birhane, "The unseen Black faces of AI algorithms," *Nature*, vol. 610, no. 7932, pp. 451–452, Oct. 2022.
- [4] H. Overbye-Thompson, K. A. Hamilton, and D. Mastro, "Reinvention mediates impacts of skin tone bias in algorithms: implications for technology diffusion," *Journal of Computer-Mediated Communication*, vol. 29, no. 5, p. zmae016, Sept. 2024.
- [5] P. Terhöst *et al.*, "A comprehensive study on face recognition biases beyond demographics," *IEEE Transactions on Technology and Society*, vol. 3, no. 1, pp. 16–30, Mar. 2022.
- [6] N. Liu, F. Zhang, L. Chang, and F. Duan, "Facial attribute classification by deep mining inter-attribute correlations," *IET Computer Vision*, vol. 17, no. 3, pp. 352–365, 2023.
- [7] D. R. Yoder-Himes *et al.*, "Racial, skin tone, and sex disparities in automated proctoring software," *Frontiers in Education*, vol. 7, p. 881449, 2022.
- [8] Z. S. Marzooq, A. D. Hasan, and H. H. Abbas, "Gender and race classification using geodesic distance measurement," *Indonesian Journal of Electrical Engineering and Computer Science*, vol. 27, no. 2, pp. 820–831, Aug. 2022.
- [9] J. P. Robinson, C. Qin, Y. Henon, S. Timoner, and Y. Fu, "Balancing biases and preserving privacy on Balanced Faces in the Wild," *IEEE Transactions on Image Processing*, vol. 32, pp. 4365–4377, Aug. 2023.
- [10] M. Sohail *et al.*, "Racial identity-aware facial expression recognition using deep convolutional neural networks," *Applied Sciences*, vol. 12, no. 1, p. 88, 2022.
- [11] D. Belcar, P. Grd, and I. Tomičić, "Automatic ethnicity classification from middle part of the face using convolutional neural networks," *Informatics*, vol. 9, no. 1, p. 18, 2022.
- [12] H. Liao, L. Yuan, M. Wu, L. Zhong, G. Jin, and N. Xiong, "Face gender and age classification based on multi-task, multi-instance and multi-scale learning," *Applied Sciences*, vol. 12, no. 23, p. 12432, 2022.
- [13] G. Sunitha, K. Geetha, S. Neelakandan, A. K. S. Pundir, S. Hemalatha, and V. Kumar, "Intelligent deep learning based ethnicity recognition and classification using facial images," *Image and Vision Computing*, vol. 121, p. 104404, 2022.
- [14] J. Brinkmann, P. Swoboda, and C. Bartelt, "A multidimensional analysis of social biases in vision transformers," in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 2023, pp. 4891–4900.
- [15] S. Ramachandran and A. Rattani, "Deep generative views to mitigate gender classification bias across gender-race groups," in *Pattern Recognition, Computer Vision, and Image Processing. ICPR 2022 International Workshops and Challenges*, J.-J. Rousseau and B. Kapralos, Eds. Cham, Switzerland: Springer Nature Switzerland, 2023, pp. 551–569.
- [16] S. Chen, X. Lai, Y. Yan, D.-H. Wang, and S. Zhu, "Learning an attention-aware parallel sharing network for facial attribute recognition," *Journal of Visual Communication and Image Representation*, vol. 90, p. 103745, 2023.
- [17] G. G. Tahyudin, M. D. Sulistiyo, M. Arzaki, and E. Rachmawati, "Classifying gender based on face images using vision transformer," *International Journal on Informatics Visualization*, vol. 8, no. 1, pp. 18–25, 2024.
- [18] A.-A. Kalkatawi and U. Saeed, "Ethnicity classification based on facial images using deep learning approach," *International Journal of Advanced Computer Science and Applications*, vol. 15, no. 2, pp. 217–226, 2024.
- [19] R. A. Putri, L. Anifah, R. E. Putra, Y. Yamasari, and R. A. Akbar, "Dual vision transformer integration for race and gender recognition based on facial images," in *Proceedings of the 2025 8th International Conference on Vocational Education and Electrical Engineering (ICVEE)*, 2025, pp. 258–264.
- [20] R. A. Putri, R. E. Putra, and Y. Yamasari, "MD-ViT: Multidomain vision transformer fusion for fair demographic attribute recognition," *Journal of Information Engineering and Educational Technology*, vol. 9, no. 2, pp. 64–79, 2025.
- [21] S. K. Gupta and N. Nain, "Review: single attribute and multi attribute facial gender and age estimation," *Multimedia Tools and Applications*, vol. 82, no. 1, pp. 1289–1311, 2023.
- [22] Y. Deng, S. Teng, L. Fei, W. Zhang, and I. Rida, "A multifeature learning and fusion network for facial age estimation," *Sensors*, vol. 21, no. 13, p. 4597, 2021.
- [23] Z. Wang, L. Xiao, Z. Cao, and H. Lu, "Vision transformer off-the-shelf: a surprising baseline for few-shot class-agnostic counting," in *Proceedings of the AAAI Conference on Artificial Intelligence (AAAI)*, 2024, p. 648.
- [24] D. Wilimitis and C. G. Walsh, "Practical considerations and applied examples of cross-validation for model development and evaluation in health care: tutorial," *JMIR AI*, vol. 2, p. e49023, 2023.
- [25] I. Hupont and C. Fernández, "DemogPairs: Quantifying the impact of demographic imbalance in deep face recognition," in *Proceedings of the 2019 14th IEEE International Conference on Automatic Face and Gesture Recognition (FG)*, 2019, pp. 1–7.

- [26] L. Yu, "Visual perception based deep learning transformers for classifying paintings and photographs through feature extraction," *Scientific Reports*, vol. 16, no. 1, p. 5326, Jan. 2026.
- [27] H. D. Jahja, N. Yudistira, and Sutrisno, "Mask usage recognition using vision transformer with transfer learning and data augmentation," *Intelligent Systems with Applications*, vol. 17, p. 200186, Feb. 2023.
- [28] Y. Bazi, L. Bashmal, M. M. A. Rahhal, R. A. Dayil, and N. A. Ajlan, "Vision transformers for remote sensing image classification," *Remote Sensing*, vol. 13, no. 3, p. 516, 2021.
- [29] J. Ma, Y. Bai, B. Zhong, W. Zhang, T. Yao, and T. Mei, "Visualizing and understanding patch interactions in vision transformer," *IEEE Transactions on Neural Networks and Learning Systems*, vol. 35, no. 10, pp. 13 671–13 680, 2024.
- [30] M. A. Ganaie, M. Tanveer, P. N. Suganthan, and V. Snasel, "Oblique and rotation double random forest," *Neural Networks*, vol. 153, pp. 496–517, 2022.
- [31] C. Zhao *et al.*, "BoostTree and BoostForest for ensemble learning," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 45, no. 7, pp. 8110–8126, 2023.
- [32] Y.-X. He, S.-H. Lyu, and Y. Jiang, "Interpreting deep forest through feature contribution and MDI feature importance," *ACM Transactions on Knowledge Discovery from Data*, vol. 20, no. 1, p. 15, Dec. 2025.
- [33] N. Zhu, C. Zhu, L. Zhou, Y. Zhu, and X. Zhang, "Optimization of the random forest hyperparameters for power industrial control systems intrusion detection using an improved grid search algorithm," *Applied Sciences*, vol. 12, no. 20, p. 10456, 2022.
- [34] J. Chen, X. Wang, and F. Lei, "Data-driven multinomial random forest: a new random forest variant with strong consistency," *Journal of Big Data*, vol. 11, no. 1, p. 34, Feb. 2024.
- [35] E. Redivo, C. Viroli, and A. Farcomeni, "Quantile-distribution functions and their use for classification, with application to naïve Bayes classifiers," *Statistics and Computing*, vol. 33, no. 2, p. 55, Mar. 2023.
- [36] J. Norrena, S. Louhenkilpi, V.-V. Visuri, T. Alatarvas, A. Bogdanoff, and T. Fabritius, "Coupling of solidification and heat transfer simulations with interpretable machine learning algorithms to predict transverse cracks in continuous casting of steel," *Steel Research International*, vol. 95, no. 4, p. 2300529, 2024.
- [37] A. J. Molstad and K. Motwani, "Multiresolution categorical regression for interpretable cell-type annotation," *Biometrics*, vol. 79, no. 4, pp. 3485–3496, Dec. 2023.
- [38] P. Zhang, R. Wang, and N. Xiu, "Multinomial logistic regression classifier via lq,0-proximal Newton algorithm," *Neurocomputing*, vol. 468, pp. 148–164, 2022.
- [39] Y. Zhang, C. Wei, and X. Liu, "Group logistic regression models with lp,q regularization," *Mathematics*, vol. 10, no. 13, p. 2227, 2022.
- [40] Z. Lai, X. Chen, J. Zhang, H. Kong, and J. Wen, "Maximal margin support vector machine for feature representation and classification," *IEEE Transactions on Cybernetics*, vol. 53, no. 10, pp. 6700–6713, 2023.
- [41] C. Yang, S.-K. Oh, B. Yang, W. Pedrycz, and L. Wang, "Hybrid fuzzy multiple SVM classifier through feature fusion based on convolution neural networks and its practical applications," *Expert Systems with Applications*, vol. 202, p. 117392, 2022.
- [42] N.-Y. Nguyen, L. V. Tran, and V. T. S. Dao, "Churn prediction in telecommunication industry using kernel support vector machines," *PLOS ONE*, vol. 17, no. 5, pp. 1–18, May 2022.
- [43] R. Guido, M. C. Groccia, and D. Conforti, "A hyper-parameter tuning approach for cost-sensitive support vector machine classifiers," *Soft Computing*, vol. 27, no. 18, pp. 12 863–12 881, Sept. 2023.
- [44] H. H. Rashidi, S. Albahra, S. Robertson, N. K. Tran, and B. Hu, "Common statistical concepts in the supervised machine learning arena," *Frontiers in Oncology*, vol. 13, p. 1130229, Feb. 2023.
- [45] I. M. De Diego, A. R. Redondo, R. R. Fernández, J. Navarro, and J. M. Moguerza, "General performance score for classification problems," *Applied Intelligence*, vol. 52, no. 10, pp. 12 049–12 063, Aug. 2022.
- [46] M. Bowles, A. M. M. Scaife, F. Porter, H. Tang, and D. J. Bastien, "Attention-gating for improved radio galaxy classification," *Monthly Notices of the Royal Astronomical Society*, vol. 501, no. 3, pp. 4579–4595, Mar. 2021.
- [47] S. A. Hicks *et al.*, "On evaluation metrics for medical applications of artificial intelligence," *Scientific Reports*, vol. 12, no. 1, p. 5979, Apr. 2022.
- [48] G. Hanczár *et al.*, "Feature space reduction method for ultrahigh-dimensional, multiclass data: random forest-based multiround screening (RFMS)," *Machine Learning: Science and Technology*, vol. 4, no. 4, p. 045012, Oct. 2023.
- [49] S. Guo *et al.*, "Functional multivariable logistic regression with an application to HIV viral suppression prediction," *Biometrical Journal*, vol. 66, no. 5, p. e202300081, 2024.
- [50] K. Nadeem and M.-A. Jabri, "Stable variable ranking and selection in regularized logistic regression for severely imbalanced big binary data," *PLOS ONE*, vol. 18, no. 1, pp. 1–26, Jan. 2023.
- [51] Scikit-learn Developers, "SVC," <https://scikit-learn.org/stable/modules/generated/sklearn.svm.SVC.html>, 2026, accessed: Feb. 2, 2026.



RICKY EKA PUTRA menyelesaikan studi Sarjana, Magister, dan Doktor di bidang Ilmu Komputer di Institut Teknologi Sepuluh Nopember (ITS) masing-masing pada tahun 2008, 2011, dan 2020, serta memperoleh gelar Profesi Insinyur pada tahun 2024. Saat ini, beliau bertugas sebagai dosen dan peneliti di Departemen Informatika, Fakultas Informatika, Universitas Negeri Surabaya. Beliau aktif berkiprah dalam pelaksanaan tridarma perguruan tinggi yang mencakup pengajaran bidang informatika, program pemberdayaan masyarakat, publikasi karya ilmiah pada berbagai jurnal bereputasi, diseminasi riset pada forum seminar ilmiah, serta perolehan Hak Kekayaan Intelektual (HKI). Fokus penelitian utama beliau diarahkan pada pengembangan model kecerdasan buatan terapan yang menjembatani kemajuan metode komputasi cerdas dengan penyelesaian tantangan berbasis data nyata. Bidang minat penelitian beliau meliputi Deep Learning, Computer Vision, Big Data Analytics, aplikasi digital dan user experience, psikologi klinis, intensi perilaku, healthcare informatics, metode statistika, serta pendidikan digital dan anak usia dini.



REZKY ARISANTI PUTRI meraih gelar Sarjana Teknik Informatika pada tahun 2019 dengan peminatan bidang Kecerdasan Buatan (Artificial Intelligence) dan telah menuntaskan studi Magister Informatika di Universitas Negeri Surabaya (UNESA). Saat ini, beliau aktif berkiprah sebagai peneliti di Departemen Informatika, Fakultas Informatika, Universitas Negeri Surabaya. Beliau terlibat intensif dalam riset pengenalan atribut demografis wajah berbasis model transformer serta secara aktif mendiseminasikan kontribusi keilmuannya melalui publikasi pada forum konferensi internasional dan jurnal ilmiah bereputasi. Fokus dan minat penelitian beliau mencakup Computer Vision, Deep Learning, Vision Transformer, Facial Attribute Recognition, Natural Language Processing, Machine Learning, dan Algorithmic Fairness. Melalui kegiatan akademik dan eksplorasi riset yang konsisten, beliau terus memperdalam kompetensi keilmuan serta berkontribusi nyata dalam kemajuan teknologi komputasi cerdas.



YUNI YAMASARI merupakan dosen dan peneliti di Departemen Informatika, Fakultas Informatika, Universitas Negeri Surabaya (UNESA) dengan landasan keilmuan yang kokoh di dunia akademik maupun praktis. Beliau menyelesaikan pendidikan Sarjana, Magister, hingga Doktor di Institut Teknologi Sepuluh Nopember (ITS), dengan kepakaran utama pada bidang Software Engineering dan Data Mining. Aktivitas tridarma beliau ditandai oleh keterlibatan aktif dalam pemberdayaan masyarakat, publikasi artikel ilmiah bereputasi, serta penulisan buku teks akademik. Beliau secara berkala mendiseminasikan temuan penelitiannya di berbagai forum ilmiah nasional maupun internasional dan telah memperoleh beberapa Hak Kekayaan Intelektual (HKI). Dedikasi akademik beliau diarahkan untuk mendorong perkembangan rekayasa perangkat lunak, analisis data komprehensif, dan bidang informatika terapan.



RAFY AULIA AKBAR menyelesaikan pendidikan Sarjana Teknik Informatika pada tahun 2019 dan meraih gelar Magister Informatika di Universitas Negeri Surabaya dengan konsentrasi pada bidang Ilmu Komputer. Semasa studi, beliau berhasil menorehkan prestasi dengan menerima penghargaan Best Solution Award pada kompetisi regional ASEAN Vocational and Engineering Camp 2017 bertema “Toward School 4.0”. Saat ini, beliau aktif mendedikasikan diri sebagai peneliti di Departemen Informatika, Fakultas Informatika, Universitas Negeri Surabaya. Fokus dan minat penelitian beliau terpusat pada domain Computer Vision, Medical Image Analysis, Multimodal Deep Learning, Natural Language Processing, serta arsitektur Vision Transformer, khususnya dalam pengembangan sistem pembangkitan laporan medis otomatis.

...