

Date of publication xxxx 00, 0000, date of current version xxxx 00, 0000.

Digital Object Identifier 10.1109/ACCESS.2026.0000000

Multi-Domain Vision Transformer Fusion for Intersectional Demographic Classification from Facial Images

RICKY EKA PUTRA¹, REZKY ARISANTI PUTRI¹, YUNI YAMASARI¹, AND RAFY AULIA AKBAR¹

Department of Informatics, Faculty of Informatics, Universitas Negeri Surabaya, Surabaya 60231, Indonesia

Corresponding author: Ricky Eka Putra (e-mail: rickyeka@unesa.ac.id).

This research was supported in part by the Department of Informatics, Faculty of Informatics, Universitas Negeri Surabaya.

ABSTRACT Pengenalan atribut demografis wajah seperti ras dan gender secara simultan menghadapi tantangan variasi ekspresi, penuaan biologis, phenotypic overlap, serta keterbatasan representasi single-domain. Penelitian ini mengusulkan kerangka kerja fusi fitur laten multi-domain yang mengintegrasikan representasi visual dari tiga model Vision Transformer (ViT) pre-trained spesifik tugas untuk biometrik wajah, ekspresi afektif, dan estimasi usia, yang dipadukan dengan optimasi pipeline machine learning klasik untuk klasifikasi enam intersectional demographic subgroups pada dataset DemogPairs. Representasi laten diekstraksi secara offline dari setiap model untuk menghasilkan representasi visual terpadu yang memadukan informasi komplementer lintas-domain. Tujuh konfigurasi fitur dievaluasi melalui 5-Fold Stratified Cross-Validation pada empat classifier: Random Forest (RF), Gaussian Naive Bayes (GNB), Logistic Regression (LR), dan Support Vector Machine (SVM) dengan hyperparameter tuning via Grid Search Cross-Validation (GridSearchCV). Hasil eksperimen menunjukkan bahwa fusi tri-domain meraih performa terbaik pada tiga dari empat classifier yang dievaluasi, dengan model SVM menghasilkan performa tertinggi, mencatat Accuracy 93.70%, Precision 93.72%, Recall 93.70%, dan F1-Score 93.69% pada data uji independen. Evaluasi mendalam pada keenam subkelompok mencatat rentang F1-Score antara 91.74% dan 96.14%, yang membuktikan efektivitas fusi representasi laten multi-domain dalam mengenali atribut demografis interseksional.

INDEX TERMS Race and gender classification, intersectional demographic recognition, Vision Transformer, multi-domain feature fusion, algorithmic fairness.

I. INTRODUCTION

Pengenalan otomatis atribut demografis wajah memegang peranan penting dalam berbagai domain aplikasi cerdas, termasuk sistem forensik digital, kontrol akses biometrik, interaksi manusia-komputer, dan personalisasi layanan interaktif. Namun, sejumlah studi melaporkan bahwa sistem pengenalan wajah kerap memperlihatkan disparitas performa terhadap subkelompok demografis tertentu, dengan penurunan akurasi yang substansial secara konsisten teramati pada kelompok wanita dan populasi berkulit gelap. Ketimpangan akurasi tersebut bersumber dari beragam faktor fundamental, meliputi ketidakseimbangan distribusi data latih pada dataset publik dan keterbatasan ekstraktor fitur konvensional dalam mengekstraksi representasi visual yang invarian terhadap variasi pose serta degradasi visual alami. Keterbatasan sistem konvensional dalam mengatasi variasi visual ini menegaskan bahwa pengenalan demografis yang adil dan akurat masih

menghadapi kendala besar, sehingga diperlukan pendekatan baru yang mampu memodelkan atribut demografis secara komprehensif.

Sebagian besar literatur pengenalan atribut wajah memformulasikan klasifikasi ras dan gender sebagai dua tugas terpisah yang diselesaikan secara independen. Pendekatan terisolasi ini mengabaikan sifat alami identitas visual wajah dan tidak mengevaluasi performa pengenalan secara eksplisit pada persilangan kelompok demografis, seperti wanita berkulit hitam atau wanita Asia. Akibatnya, penurunan performa yang terkonsentrasi pada subkelompok interseksional tertentu luput dari pengamatan metrik global, sehingga kondisi tersebut membatasi pemahaman komprehensif mengenai keandalan model di lapangan. Formulasi klasifikasi interseksional terpadu pada pengaturan evaluasi seimbang menyediakan landasan komparatif yang objektif untuk mengukur variasi performa lintas subkelompok secara adil. Namun, pemod-

elan klasifikasi interseksional menuntut representasi visual yang kaya dan berkapasitas tinggi untuk memisahkan batas keputusan antarsubkelompok yang memiliki derajat tumpang tindih visual tinggi, sehingga pemodelan ini memerlukan arsitektur ekstraksi representasi visual yang tangguh terhadap variasi fenotipe dan ekspresi wajah.

Perkembangan metodologi pengenalan atribut wajah telah bertransformasi secara substansial dari pendekatan ekstraksi fitur buatan tangan menuju arsitektur deep learning dan ViT. Pada era arsitektur Convolutional Neural Networks (CNN), berbagai penelitian mengeksplorasi ekstraksi ciri demografis melalui pemanfaatan region spesifik wajah seperti area wajah bagian tengah [1], kerangka kerja multi-tugas berbasis multi-skala untuk estimasi usia dan gender secara simultan [2], serta model CNN mendalam untuk pengenalan etnisitas [3]. Perkembangan terkini menunjukkan keunggulan ViT dalam memodelkan ketergantungan spasial global antarpatch citra melalui mekanisme Multi-Head Self-Attention (MHSA), yang membuka ruang analisis mendalam terhadap bias representasi visual [4], sementara pemanfaatan representasi generatif sintetis turut dikembangkan untuk memitigasi disparitas demografis [5]. Di samping itu, integrasi mekanisme atensi paralel [6], pemanfaatan ViT untuk klasifikasi gender wajah [7], serta eksplorasi arsitektur transformer multi-aksis [8] semakin memperkaya variasi pemodelan representasi visual. Lebih lanjut, eksplorasi penggabungan representasi ViT lintas domain mulai dikembangkan melalui integrasi fitur ganda wajah dan emosi untuk meningkatkan diskriminasi atribut ras dan gender [9], [10]. Meskipun demikian, eksplorasi fusi representasi multi-domain komprehensif yang secara simultan mengintegrasikan isyarat biometrik struktural, dinamika ekspresi emosi, dan morfologi penuaan biologis wajah masih memerlukan kajian empiris terpadu.

Meskipun eksplorasi ViT dan model visi telah berkembang pesat, terdapat tiga kesenjangan penelitian utama yang belum terpecahkan secara optimal. Pertama, sebagian besar studi terdahulu bertumpu pada representasi biometrik wajah domain tunggal tanpa mengintegrasikan isyarat afektif dinamis secara simultan, sehingga model yang dikembangkan kesulitan membedakan subkelompok dengan derajat phenotypic overlap yang tinggi. Kedua, pengenalan demografis sering kali menunjukkan sensitivitas tinggi terhadap perubahan morfologi wajah seiring pertambahan usia karena ekstraksi fitur yang digunakan tidak mengikutsertakan representasi penuaan biologis. Ketiga, evaluasi komparatif mengenai perilaku batas keputusan antarmodel classifier hilir yang mencakup model linier, probabilistik, ensemble, dan kernel-based, beserta interaksinya terhadap penskalaan dan reduksi dimensi pada ruang representasi transformer, masih sangat terbatas. Untuk menjembatani keterbatasan representasi domain tunggal serta mengevaluasi batas keputusan classifier hilir tersebut, penelitian ini mengusulkan integrasi tiga domain representasi ViT yang dipadukan dengan optimasi pipeline classical classifier terstruktur.

Untuk mengatasi kesenjangan riset tersebut, penelitian ini mengusulkan kerangka kerja fusi fitur Tri-Domain ViT yang

memadukan tiga representasi laten spesifik tugas untuk klasifikasi demografis interseksional pada citra wajah. Kerangka kerja yang diusulkan mengintegrasikan tiga domain representasi komplementer, meliputi representasi geometri biometrik wajah, isyarat ekspresi afektif dinamis, dan karakteristik morfologi penuaan biologis dari model backbone ViT pre-trained spesifik tugas ke dalam satu representasi terpadu melalui operasi konkatenasi fitur. Ekstraksi fitur laten dilakukan secara offline dari model backbone pre-trained yang dibekukan, sehingga prosedur ini mampu menjaga efisiensi komputasi sekaligus mengisolasi representasi visual dari variabilitas proses pelatihan ulang. Vektor fitur yang dihasilkan selanjutnya dievaluasi secara sistematis melalui serangkaian skema ablasi domain tunggal, domain ganda, dan tri-domain pada empat kelompok algoritma classical machine learning, yaitu RF, GNB, LR, dan SVM. Seluruh arsitektur klasifikasi hilir dioptimalkan melalui prosedur Stratified Cross-Validation yang dikombinasikan dengan pipeline modular penskalaan fitur dan reduksi dimensionalitas Principal Component Analysis (PCA) terisolasi, untuk memastikan pencegahan kebocoran data dan pembentukan batas keputusan yang tangguh antarsubkelompok demografis.

Kontribusi ilmiah utama dari penelitian ini dirangkum ke dalam empat poin utama sebagai berikut:

- 1) A Tri-Domain ViT feature fusion framework integrating face-associated biometric representations, expression-related representations, and age-associated facial representations into a unified latent feature vector for intersectional demographic classification (Kerangka kerja fusi fitur Tri-Domain ViT yang mengintegrasikan representasi terkait biometrik wajah, representasi terkait ekspresi, dan representasi terkait usia wajah ke dalam vektor fitur laten terpadu untuk klasifikasi demografis interseksional).
- 2) An empirical comparative benchmark across multiple feature ablation schemes and classical machine learning classifiers optimized via Stratified Cross-Validation hyperparameter tuning, examining decision boundary behavior across linear, probabilistic, ensemble, and kernel-based models (Tolok ukur komparatif empiris melintasi berbagai skema ablasi fitur dan pengklasifikasi machine learning klasik yang dioptimalkan melalui penyetelan hyperparameter validasi silang berstrata, mengkaji perilaku batas keputusan antarmodel linier, probabilistik, ensemble, dan berbasis kernel).
- 3) Competitive classification performance on the DemogPairs dataset, achieving higher reported performance compared to the evaluated single-domain and dual-domain configurations on the majority of classifiers (Capaian performa klasifikasi kompetitif pada dataset DemogPairs yang mencapai performa lebih tinggi dibandingkan konfigurasi domain tunggal dan domain ganda yang dievaluasi pada mayoritas pengklasifikasi).

- 4) A granular intersectional subgroup performance analysis, evaluating subgroup-level classification performance across six demographic subgroups, providing an in-depth characterization of model behaviors across racial and gender intersections while systematically revealing the consistency of multi-domain feature representations on independent evaluation cohorts without exhibiting acute performance degradation (Analisis performa subkelompok interseksional granular yang mengevaluasi performa klasifikasi di keenam subkelompok demografis, memberikan karakterisasi mendalam mengenai perilaku model melintasi persilangan ras dan gender sekaligus mengungkap secara sistematis konsistensi representasi fitur multi-domain pada kohort evaluasi independen tanpa memperlihatkan degradasi performa yang akut).

Sistematika penulisan artikel ini disusun sebagai berikut: Section II mengulas tinjauan pustaka mengenai pengenalan demografis wajah dan arsitektur transformer. Section III menjabarkan spesifikasi dataset DemogPairs, ekstraksi representasi multi-domain ViT, dan pipeline klasifikasi teroptimasi. Section IV memaparkan hasil evaluasi eksperimental, studi ablasi fitur, serta analisis performa subkelompok interseksional. Terakhir, Section V merangkum kesimpulan utama penelitian, keterbatasan metodologis, dan rekomendasi arah riset mendatang.

II. RELATED WORKS

Evolusi metodologi pengenalan atribut demografis wajah bertransformasi dari deskriptor konvensional berbasis bagian wajah dan ekstraksi ciri buatan tangan menuju arsitektur representasi mendalam. Pada fase awal, pendekatan berbasis region lokal mengeksplorasi geometri wajah bagian tengah untuk mengenali etnisitas dan meminimalkan interferensi variasi latar belakang [1]. Akan tetapi, ekstraktor berbasis CNN klasik kerap memperlihatkan penurunan akurasi yang tajam ketika berhadapan dengan variasi pencahayaan ekstrem serta disparitas pengenalan antarras atau fenomena Other-Race Effect. Penambahan kedalaman jaringan konvolusi terbukti meningkatkan diskriminasi fitur visual lintas populasi yang beragam [3]. Selain itu, integrasi mekanisme berbagi fitur paralel dengan atensi visual dirancang untuk memperkuat korelasi antar-atribut wajah sekaligus mereduksi bias representasi lokal [6].

Penerapan arsitektur ViT dalam domain biometrik wajah memberikan kemampuan pemodelan visual yang berbeda secara fundamental dibandingkan pendekatan konvensional. Melalui mekanisme MHSA, model transformer mampu menangkap dependensi spasial global antarpatch citra wajah secara langsung tanpa dibatasi oleh receptive field lokal yang kaku [4]. Karakteristik struktural tersebut terbukti efektif dalam memetakan atribut demografis seperti gender pada citra wajah beresolusi terstandarisasi [7]. Di samping model transformer standar, eksplorasi arsitektur hibrida seperti MaxViT menggabungkan atensi berbasis jendela dan atensi kisi untuk memproses representasi spasial secara

bertingkat [8]. Meskipun arsitektur transformer menawarkan fleksibilitas representasi global yang tinggi, efektivitas empiris pemisahan kelas demografis sangat bergantung pada kualitas dan karakteristik data latih yang digunakan.

Investigasi terhadap disparitas performa dalam sistem visi komputer mendorong pengembangan protokol evaluasi berbasis distribusi kelas yang seimbang. Pengujian pada dataset berimbang menyediakan kondisi eksperimen yang terkontrol untuk mengukur perbedaan akurasi antarsubkelompok demografis secara objektif tanpa distorsi ketimpangan jumlah sampel, walaupun distribusi seimbang tidak serta-merta mengeliminasi bias sosial yang melekat pada data. Analisis representasi laten menunjukkan bahwa model transformer tetap rentan mereproduksi bias sosial yang berasal dari korpus pra-latih berskala besar [4]. Untuk memitigasi ketimpangan performa antarkelompok ras dan gender, teknik augmentasi generatif berbasis StyleGAN2 dimanfaatkan untuk menghasilkan variasi sudut pandang sintetis yang mempersempit celah kesalahan klasifikasi [5]. Pendekatan tersebut menegaskan pentingnya pengujian komprehensif lintas subkelompok demografis.

Keterbatasan representasi domain tunggal dalam membedakan variasi visual wajah mendorong eksplorasi arsitektur fusi multi-skala dan multi-tugas. Pendekatan pembelajaran multi-tugas terbukti mampu mengekstraksi dependensi antara estimasi usia dan gender melalui pemrosesan beberapa patch citra wajah sekaligus [2]. Mekanisme berbagi representasi paralel juga dikembangkan untuk mengombinasikan berbagai atribut afektif secara simultan [6], sementara pemanfaatan sudut pandang generatif memperkaya variasi fitur antarkelompok demografis [5]. Lebih lanjut, integrasi fitur laten ganda berbasis ViT yang menggabungkan biometrik wajah dan ekspresi emosi mampu meningkatkan akurasi klasifikasi interseksional [9]. Penggabungan fitur biometrik dengan representasi usia juga memperlihatkan kontribusi informasi yang saling melengkapi [10], sehingga temuan tersebut membuktikan potensi empiris penggabungan representasi laten antar-domain.

Pemilihan model pengklasifikasi hilir memiliki pengaruh substansial terhadap efektivitas pemisahan batas keputusan pada ruang fitur berdimensi tinggi. Lapisan klasifikasi SoftMax end-to-end umum diterapkan pada arsitektur jaringan saraf tiruan konvolusional untuk memetakan probabilitas kelas secara langsung [1], [8]. Di sisi lain, algoritma berbasis kernel seperti SVM dan model kernel adaptif memperlihatkan ketangguhan tinggi dalam memisahkan batas keputusan non-linier yang kompleks tanpa memerlukan proses pembaruan bobot secara menyeluruh [3]. Selain itu, model ensemble berbasis pohon seperti RF terbukti efektif dalam memodelkan interaksi hierarkis antardata demografis melalui partisi bertingkat [2], sedangkan pendekatan probabilistik seperti GNB menawarkan efisiensi inferensi tinggi. Perilaku pemisahan kelas tersebut menegaskan bahwa setiap model klasifikasi memiliki karakteristik batas keputusan yang unik.

Berdasarkan literatur yang telah dipaparkan, penelitian ini menempati posisi strategis dalam menjembatani kesenjangan

pemodelan atribut demografis wajah secara komprehensif. Berbeda dari studi terdahulu yang bertumpu pada representasi domain tunggal atau fusi parsial dua domain, penelitian ini mengusulkan kerangka kerja fusi tri-domain yang memadukan representasi geometri biometrik wajah, isyarat afektif ekspresi dinamis, dan karakteristik morfologi penuaan biologis berbasis model ViT pra-latih yang dibekukan secara terpadu. Representasi laten multi-domain tersebut kemudian diintegrasikan dengan optimasi pipeline SVM untuk membentuk batas keputusan nonlinier yang tangguh. Evaluasi komparatif komprehensif dilakukan pada dataset seimbang DemogPairs untuk menganalisis performa klasifikasi ras dan gender secara interseksional beserta variasi disparitasnya.

III. MATERIALS AND METHODS

Kerangka kerja yang diusulkan memadukan representasi visual multi-domain dan optimasi model pembelajaran mesin untuk klasifikasi ras dan gender interseksional, sebagaimana diilustrasikan pada Figure 1. Metodologi diawali pemisahan citra wajah resolusi 224×224 piksel pada dataset DemogPairs menjadi partisi latih dan uji via stratified split. Tiga model ViT-Base pre-trained yang dibekukan mengekstraksi representasi laten berdimensi 768 dari token [CLS] secara offline. Ketiga vektor digabungkan melalui fusi konkatenasi $\mathbf{z}_{tri} = \mathbf{f}_{face} \oplus \mathbf{f}_{emotion} \oplus \mathbf{f}_{age}$, di mana $\mathbf{z}_{tri}$ menyatakan vektor tri-domain berdimensi 2,304, $\oplus$ adalah operator konkatenasi, serta $\mathbf{f}_{face}$, $\mathbf{f}_{emotion}$, dan $\mathbf{f}_{age}$ merepresentasikan fitur biometrik wajah, ekspresi, dan usia. Vektor representasi diproses dalam pipeline modular Scaler dan PCA sebelum diklasifikasikan ke enam kelas interseksional oleh RF, GNB, LR, dan SVM. Penalaan hyperparameter dijalankan melalui 5-Fold Stratified Cross-Validation dengan skema GridSearchCV terisolasi untuk mencegah kebocoran informasi sebelum evaluasi data uji.

A. DATASET

Dataset yang digunakan dalam penelitian ini adalah DemogPairs [11], sebuah dataset yang dirancang khusus untuk mengukur ketimpangan performa pengenalan wajah lintas kelompok demografis. Dataset ini memuat total 10,800 citra wajah yang terdistribusi secara seimbang ke dalam enam kelas interseksional. Keenam subkelompok tersebut mencakup kombinasi persilangan dari tiga kelompok ras makro dan dua kelompok gender, yaitu Asian Females, Asian Males, Black Females, Black Males, White Females, dan White Males, dengan kuota tepat 1,800 citra per kelas. Distribusi yang seimbang ini menyediakan kondisi evaluasi terkontrol untuk membandingkan performa antarsubkelompok secara objektif tanpa distorsi dominasi sampel mayoritas. Sampel visual dari keenam subkelompok demografis diilustrasikan pada Figure 2.

Untuk memastikan integritas pengujian empiris, dataset dibagi menggunakan prosedur stratified split 80/20 (80% data latih dan 20% data uji). Pembagian tersebut menghasilkan 8,640 citra latih dengan 1,440 sampel per kelas serta 2,160 citra uji independen dengan 360 sampel per kelas, sebagaimana dirinci pada Table 1. Subset uji tersebut diisolasi

TABLE 1. Dataset Partition and Demographic Subgroup Distribution.

Subgroup	Train Set (80%)	Test Set (20%)	Total
Black Males	1,440	360	1,800
White Females	1,440	360	1,800
Asian Males	1,440	360	1,800
White Males	1,440	360	1,800
Black Females	1,440	360	1,800
Asian Females	1,440	360	1,800
Total	8,640	2,160	10,800

secara ketat, tidak pernah dilibatkan selama proses pencarian hyperparameter, dan hanya digunakan untuk evaluasi akhir. Pada tahapan standarisasi citra, setiap citra wajah dikonversi ke dalam format 3-channel Red, Green, Blue (RGB), diubah ukurannya ke resolusi 224×224 piksel, dan diskalakan intensitas pikselnya dari rentang $[0, 255]$ menjadi $[0, 1]$ agar selaras dengan masukan model transformer.

B. VISION TRANSFORMER

Arsitektur ekstraksi representasi visual penelitian ini mengadopsi ViT-Base (vit-base-patch16-224) sebagaimana diilustrasikan pada Figure 3. Citra wajah masukan berukuran 224×224 piksel dengan 3 saluran warna dibagi menjadi 196 patch spasial non-overlapping $\mathbf{x}_p^i$ berukuran 16×16 piksel. Setiap patch diproyeksikan secara linier melalui matriks $\mathbf{E}$ ke ruang laten berdimensi $D = 768$, lalu dirangkaikan dengan token kelas $\mathbf{x}_{class}$ dan embedding posisi $\mathbf{E}_{pos}$ sesuai (1), di mana $\mathbf{z}_0$ merupakan vektor sekuens token awal masukan encoder:

$$\mathbf{z}_0 = [\mathbf{x}_{class}; \mathbf{x}_p^1 \mathbf{E}; \dots; \mathbf{x}_p^{196} \mathbf{E}] + \mathbf{E}_{pos} \quad (1)$$

Vektor sekuens token awal $\mathbf{z}_0$ dialirkan ke tumpukan 12 layer transformer encoder identik. Setiap layer encoder ℓ memproses masukan $\mathbf{z}_{\ell-1}$ menjadi representasi antara $\mathbf{z}'_{\ell}$ melalui mekanisme MHSA setelah operasi Layer Normalization (LN) sesuai (2), di mana $\text{LN}(\cdot)$ menyatakan normalisasi lapisan dan $\mathbf{z}_{\ell-1}$ adalah representasi luaran dari layer sebelumnya:

$$\mathbf{z}'_{\ell} = \text{MHSA}(\text{LN}(\mathbf{z}_{\ell-1})) + \mathbf{z}_{\ell-1} \quad (2)$$

Proses tersebut dilanjutkan menuju representasi luaran $\mathbf{z}_{\ell}$ melalui blok Multi-Layer Perceptron (MLP) dua lapis beraktivasi GeLU berdasarkan (3), di mana $\text{MLP}(\cdot)$ merupakan jaringan perceptron multilapis dan $\mathbf{z}'_{\ell}$ adalah representasi antara berresidual:

$$\mathbf{z}_{\ell} = \text{MLP}(\text{LN}(\mathbf{z}'_{\ell})) + \mathbf{z}'_{\ell} \quad (3)$$

Mekanisme self-attention dengan 12 attention heads memetakan relasi spasial global antarpatch wajah secara langsung tanpa pembatasan receptive field lokal.

Untuk mempertahankan efisiensi komputasi dan mencegah variabilitas pelatihan ulang, ketiga model backbone ViT dibekukan (frozen) sebagai penyedia task-associated representations secara offline. Model ViT-Face




FIGURE 1. End-to-End Framework of the Proposed Multi-Domain Vision Transformer Feature Fusion and Classical Classifier Optimization for Intersectional Race and Gender Classification.



FIGURE 2. Sample Images of the DemogPairs Dataset across Six Intersectional Demographic Subgroups: (a) Asian Females, (b) Asian Males, (c) Black Females, (d) Black Males, (e) White Females, and (f) White Males.




FIGURE 3. Architecture of the ViT Backbone and Patch Projection.

(skutaada/VITVGGFace) menangkap representasi terkait geometri biometrik wajah, ViT-Emotion (dima806/facial_emotions_image_detection) menghasilkan representasi terkait ekspresi wajah, dan ViT-Age (dima806/facial_age_image_detection) mengekstraksi representasi terkait estimasi usia wajah. Dari setiap model domain, vektor fitur $\mathbf{f}_{\text{domain}} \in \mathbb{R}^{768}$ diekstraksi dari representasi token [CLS] pada layer encoder terakhir L ($\mathbf{z}_L^0$) setelah operasi LN sesuai (4), di

mana $\mathbf{z}_L^0$ merupakan vektor representasi token pertama pada layer ke- L :

$$\mathbf{f}_{\text{domain}} = \text{LN}(\mathbf{z}_L^0) \in \mathbb{R}^{768} \quad (4)$$

Ketiga representasi laten domain tunggal tersebut digabungkan menjadi vektor fusi tri-domain $\mathbf{z}_{\text{tri}} \in \mathbb{R}^{2304}$ melalui operasi konkatenasi fitur ($\oplus$) dari vektor $\mathbf{f}_{\text{face}}$, $\mathbf{f}_{\text{emotion}}$, dan $\mathbf{f}_{\text{age}}$ sebagaimana dirumuskan pada (5), di mana $\mathbf{z}_{\text{tri}}$ menyatakan vektor representasi terfusi tri-domain:

$$\mathbf{z}_{\text{tri}} = \mathbf{f}_{\text{face}} \oplus \mathbf{f}_{\text{emotion}} \oplus \mathbf{f}_{\text{age}} \in \mathbb{R}^{2304} \quad (5)$$

Eksplorasi sistematis mencakup tujuh skema ablasi fitur, yang meliputi tiga konfigurasi domain tunggal berdimensi 768, tiga konfigurasi domain ganda berdimensi 1,536, serta satu konfigurasi tri-domain berdimensi 2,304 seperti dirangkum pada Table 2.

C. RANDOM FOREST

Model ensemble RF mengagregasikan prediksi sekumpulan pohon keputusan independen untuk mengklasifikasikan fi-

TABLE 2. Multi-Domain Feature Fusion and Ablation Configurations.

#	Configuration	Domain Category	Dimension
1	Face	Single-Domain	768
2	Emotion	Single-Domain	768
3	Age	Single-Domain	768
4	Emotion $\oplus$ Face	Dual-Domain	1,536
5	Face $\oplus$ Age	Dual-Domain	1,536
6	Emotion $\oplus$ Age	Dual-Domain	1,536
7	Face $\oplus$ Emotion $\oplus$ Age	Tri-Domain (Proposed)	2,304

tur wajah berdasarkan prinsip bootstrap aggregating (bagging) dan random subspace method. Pendekatan ini mereduksi varians prediksi dengan membangun sebanyak B pohon klasifikasi dari sampel acak data latih. Setiap percabangan node membatasi pemilihan fitur pada subset acak berukuran $\max_features \in \{\sqrt{\cdot}, \log_2\}$ untuk menekan korelasi antarpohon. Kriteria pemisahan cabang mengoptimalkan indeks Gini impurity hingga memenuhi ambang batas minimum pemisahan node $\min_samples_split$, batas kedalaman $\max_depth$, atau batas minimum daun $\min_samples_leaf$. Mekanisme majority voting menentukan keputusan akhir sampel citra melintasi seluruh pohon keputusan. Prosedur penalaan hyperparameter mengevaluasi kombinasi penskalaan fitur, reduksi dimensionalitas PCA, variasi jumlah pohon $n_estimators$, serta batasan pertumbuhan pohon, menghasilkan 288 konfigurasi grid dengan 1,440 total fits melalui 5-Fold Stratified Cross-Validation sebagaimana dirangkum pada Table 3.

D. GAUSSIAN NAIVE BAYES

Berdasarkan Teorema Bayes, pengklasifikasi GNB mengestimasi probabilitas posterior kelas demografis interseksional dengan asumsi bahwa seluruh dimensi fitur kontinu bersifat independen secara bersyarat. Fungsi kerapatan probabilitas distribusi normal memodelkan likelihood fitur kontinu terhadap kelas target sesuai formulasi pada (6), di mana x_i menyatakan nilai fitur kontinu ke- i , y adalah variabel label kelas, c merupakan kategori kelas target, serta $\mu_{c,i}$ dan $\sigma_{c,i}^2$ masing-masing merepresentasikan rata-rata (mean) dan varians fitur ke- i pada kelas c :

$$P(x_i | y = c) = \frac{1}{\sqrt{2\pi\sigma_{c,i}^2}} \exp\left(-\frac{(x_i - \mu_{c,i})^2}{2\sigma_{c,i}^2}\right) \quad (6)$$

Penambahan parameter penghalusan var_smoothing menjaga stabilitas komputasi terhadap risiko varians mendekati nol pada ruang representasi laten berdimensi tinggi. Prosedur penalaan hyperparameter melalui 5-Fold Stratified Cross-Validation mengevaluasi kombinasi penskalaan data, reduksi dimensionalitas PCA, serta 40 interval var_smoothing yang dieksplorasi secara logaritmik dari 1.0×10^{-9} hingga 1.0×10^2 , menghasilkan 240 kombinasi grid dengan 1,200 total fits sebagaimana dipaparkan pada Table 4.

E. LOGISTIC REGRESSION

Pendekatan regresi multinomial (Softmax regression) pada LR memetakan representasi fitur laten ke dalam enam kategori demografis interseksional melalui estimasi probabilitas linier terpadu. Fungsi probabilitas Softmax menghitung peluang bersyarat sampel terhadap kategori target sebagaimana didefinisikan pada (7), di mana $\mathbf{x}$ merepresentasikan vektor fitur masukan, y adalah variabel label kelas, c menyatakan kategori kelas target, $\mathbf{w}_c$ dan b_c masing-masing merupakan vektor bobot serta bias kelas c , sedangkan konstanta $K = 6$ menunjukkan jumlah total kelas interseksional:

$$P(y = c | \mathbf{x}) = \frac{e^{\mathbf{w}_c^T \mathbf{x} + b_c}}{\sum_{j=1}^K e^{\mathbf{w}_j^T \mathbf{x} + b_j}} \quad (7)$$

Proses pembelajaran model meminimalkan fungsi kerugian cross-entropy dengan menyertakan penalti regularisasi L_2 untuk mengendalikan kompleksitas bobot pada ruang representasi berdimensi tinggi. Pencarian hyperparameter terstruktur mengevaluasi variasi kekuatan regularisasi C , algoritma solver optimasi (lbfgs, saga, newton-cg), batas iterasi $\max_iter$, serta integrasi penskalaan dan PCA, menghasilkan 270 kombinasi evaluasi atau 1,350 total fits pada protokol 5-Fold Stratified Cross-Validation yang disajikan pada Table 5.

F. SUPPORT VECTOR MACHINE

Pengklasifikasi SVM mengonstruksikan bidang pemisah berjarak terjauh (maximum margin hyperplane) untuk memisahkan enam kelas interseksional pada ruang representasi laten berdimensi tinggi. Fungsi kernel memproyeksikan distribusi data nonlinier dari fusi multi-domain ke ruang fitur berdimensi lebih tinggi, mencakup opsi kernel linear, Radial Basis Function (RBF), dan polinomial. Formulasi kernel polinomial derajat dua pada (8) menghitung produk titik $\langle \mathbf{x}_i, \mathbf{x}_j \rangle$ antara pasangan vektor fitur $\mathbf{x}_i$ dan $\mathbf{x}_j$, di mana γ menyatakan parameter penskalaan kernel, $d = 2$ menentukan derajat pemetaan, dan konstanta intercept $\text{coef0} = 0.0$ mengikuti nilai bawaan scikit-learn:

$$K(\mathbf{x}_i, \mathbf{x}_j) = (\gamma \langle \mathbf{x}_i, \mathbf{x}_j \rangle + \text{coef0})^d, \quad d = 2 \quad (8)$$

Pemetaan kuadratik ini memfasilitasi penangkapan interaksi nonlinier antardimensi visual secara efisien.

Optimasi hyperparameter menelusuri rentang parameter penalti $C \in \{0.01, 0.1, 1, 10\}$, ragam fungsi kernel, koefisien γ , derajat polinomial, serta opsi penskalaan dan PCA, menghasilkan 288 kombinasi konfigurasi atau 1,440 total fits pada prosedur 5-Fold Stratified Cross-Validation sesuai Table 6.

G. CLASSIFICATION PIPELINE

Kerangka kerja pipeline modular menyatukan penskalaan fitur, reduksi dimensi representasi, dan estimasi model hilir ke dalam rantai transformasi terpadu. Rantai pemrosesan tersebut dirumuskan pada (9), di mana vektor fitur input $\mathbf{x}$ ditransformasikan oleh modul penskalaan menjadi $\tilde{\mathbf{x}}$, direduksi dimensinya melalui PCA menjadi $\hat{\mathbf{x}}$, dan dipetakan oleh

TABLE 3. Hyperparameter Search Space for Random Forest Classifier.

Component / Hyperparameter	Evaluated Values	Count
Feature Scaler	None, MinMaxScaler	2
Dimensionality Reduction (PCA)	None, 0.50, 0.75	3
Number of Estimators	100, 200	2
Maximum Tree Depth	None, 20, 30	3
Feature Subspace	'sqrt', 'log2'	2
Minimum Samples Split	2, 5	2
Minimum Samples Leaf	1, 2	2
Total Grid Combinations	–	288 (1,440 fits)

TABLE 4. Hyperparameter Search Space for Gaussian Naive Bayes Classifier.

Component / Hyperparameter	Evaluated Values	Count
Feature Scaler	None, MinMaxScaler	2
Dimensionality Reduction (PCA)	None, 0.50, 0.75	3
Variance Smoothing	logspace(−9, 2, 40) (1.0×10^{-9} to 1.0×10^2)	40
Total Grid Combinations	–	240 (1,200 fits)

TABLE 5. Hyperparameter Search Space for Logistic Regression Classifier.

Component / Hyperparameter	Evaluated Values	Count
Feature Scaler	None, MinMaxScaler	2
Dimensionality Reduction (PCA)	None, 0.50, 0.75	3
Regularization Strength	0.01, 0.1, 1, 10, 100	5
Optimization Solver	'lbfgs', 'saga', 'newton-cg'	3
Maximum Iterations	500, 1000, 2000	3
Total Grid Combinations	–	270 (1,350 fits)

TABLE 6. Hyperparameter Search Space for Support Vector Machine.

Component / Hyperparameter	Evaluated Values	Count
Feature Scaler	None, MinMaxScaler	2
Dimensionality Reduction (PCA)	None, 0.50, 0.75	3
Regularization Parameter	0.01, 0.1, 1, 10	4
Kernel Function	'linear', 'rbf', 'poly'	3
Polynomial Degree	2, 3	2
Kernel Coefficient	'scale', 'auto'	2
Total Grid Combinations	–	288 (1,440 fits)

pengklasifikasi menuju prediksi label $\hat{y} \in \{0, 1, 2, 3, 4, 5\}$ untuk enam subkelompok demografis:

$$\mathbf{x} \xrightarrow{\text{Scaler}} \tilde{\mathbf{x}} \xrightarrow{\text{PCA}} \hat{\mathbf{x}} \xrightarrow{\text{Classifier}} \hat{y} \in \{0, 1, 2, 3, 4, 5\} \quad (9)$$

Protokol validasi silang menerapkan skema 5-Fold Stratified Cross-Validation dengan pengacakan terkontrol untuk mempertahankan proporsi seimbang $\sim 16.67\%$ per kelas di setiap fold. Untuk mencegah kebocoran informasi, Scaler dan PCA di-fit secara eksklusif hanya pada data latih di dalam GridSearchCV sebelum diterapkan ke data validasi. Penelusuran terhadap 1,086 kombinasi hyperparameter menghasilkan 5,430 fits per skema fitur atau 38,010 total fits untuk tujuh konfigurasi representasi, serta 28 refit final sebelum pengujian pada data uji held-out independen.

H. EVALUATION METRICS

Evaluasi performa klasifikasi multi-kelas enam subkelompok demografis pada tingkat subkelompok dilakukan melalui skema biner One-vs-Rest (OvR). Skema ini memanfaatkan empat komponen matriks konfusi per kelas untuk menghitung Akurasi OvR, Presisi, Recall, dan F1-Score pada setiap kelas $c \in \{1, \dots, K\}$. Keempat komponen tersebut mencakup TP_c (True Positive), TN_c (True Negative), FP_c (False Positive), dan FN_c (False Negative). Akurasi OvR pada (10) mengukur rasio total prediksi benar terhadap seluruh data uji:

$$\text{Accuracy}_c = \frac{TP_c + TN_c}{TP_c + TN_c + FP_c + FN_c} \quad (10)$$

Sedangkan Presisi pada (11) dan Recall pada (12) memetakan ketepatan positif serta sensitivitas deteksi sistem per sub-

kelompok:

$$\text{Precision}_c = \frac{TP_c}{TP_c + FP_c} \quad (11)$$

$$\text{Recall}_c = \frac{TP_c}{TP_c + FN_c} \quad (12)$$

F1-Score pada (13) dirumuskan sebagai rata-rata harmonik antara Presisi dan Recall untuk merepresentasikan keseimbangan evaluasi performa deteksi per subkelompok:

$$\text{F1-Score}_c = \frac{2 \cdot \text{Precision}_c \cdot \text{Recall}_c}{\text{Precision}_c + \text{Recall}_c} \quad (13)$$

Untuk mengevaluasi efektivitas sistem klasifikasi secara menyeluruh pada data uji independen, metrik performa per subkelompok diintegrasikan menjadi metrik evaluasi global. Pada formulasi ini, simbol N menyatakan total sampel data uji ($N = 2,160$), sedangkan K menyatakan jumlah total subkelompok demografis ($K = 6$). Akurasi Global (Overall Accuracy) pada (14) dihitung sebagai rasio total prediksi benar, yaitu penjumlahan elemen diagonal utama matriks konfusi $\sum_{c=1}^K TP_c$, terhadap total sampel data uji N :

$$\text{Accuracy}_{\text{Global}} = \frac{\sum_{c=1}^K TP_c}{N} \quad (14)$$

Selanjutnya, Presisi global (Macro Precision) pada (15), Recall global (Macro Recall) pada (16), dan F1-Score global (Macro F1-Score) pada (17) dihitung melalui perataan makro tanpa bobot (unweighted macro average) melintasi $K = 6$ subkelompok untuk memberikan bobot evaluasi yang setara pada setiap kelas demografis:

$$\text{Precision}_{\text{Global}} = \frac{1}{K} \sum_{c=1}^K \text{Precision}_c \quad (15)$$

$$\text{Recall}_{\text{Global}} = \frac{1}{K} \sum_{c=1}^K \text{Recall}_c \quad (16)$$

$$\text{F1-Score}_{\text{Global}} = \frac{1}{K} \sum_{c=1}^K \text{F1-Score}_c \quad (17)$$

IV. RESULTS AND DISCUSSION

A. GLOBAL PERFORMANCE ANALYSIS

Evaluasi performa RF melintasi tujuh konfigurasi fitur pada data uji DemogPairs disajikan pada Table 7. Hasil eksperimen empiris menunjukkan bahwa skema dual-domain Emotion $\oplus$ Face mencapai capaian tertinggi dengan Akurasi 86.85% dan F1-Score 86.82%. Sebaliknya, penggabungan tri-domain Face $\oplus$ Emotion $\oplus$ Age mengalami sedikit penurunan performa menjadi Akurasi 86.20% dan F1-Score 86.13%. Penurunan ini diinterpretasikan sebagai kemungkinan tantangan partisi ruang fitur berdimensi 2,304 melalui pemotongan pohon acak (random splits). Seluruh konfigurasi RF secara konsisten memilih reduksi dimensionalitas PCA 0.75 untuk menyeimbangkan varians data. Pada kategori domain tunggal, fitur Face mencatatkan performa terbaik dengan Akurasi 85.46%, melampaui fitur domain Emotion sebesar 80.60% serta domain Age sebesar 73.66%.

Evaluasi performa klasifikasi probabilistik GNB pada tujuh variasi konfigurasi fitur dirangkum pada Table 8. Meskipun dibatasi oleh asumsi dasar independensi fitur kontinu, model GNB menunjukkan tren peningkatan performa yang konsisten dari kategori domain tunggal ke multi-domain. Pada domain tunggal, konfigurasi Age menghasilkan capaian terendah dengan Akurasi 69.63% dan F1-Score 69.52%, sedangkan fitur Face mencapai Akurasi 82.69%. Integrasi fitur pada kategori dual-domain meningkatkan akurasi secara konsisten, dipimpin oleh kombinasi Emotion $\oplus$ Face sebesar 84.86%. Puncak performa klasifikasi GNB tercapai pada konfigurasi tri-domain Face $\oplus$ Emotion $\oplus$ Age dengan Akurasi 85.05% dan F1-Score 85.05%. Seluruh konfigurasi fitur GNB secara seragam memilih reduksi dimensionalitas PCA 0.75 untuk meminimalkan korelasi antarfitur laten.

Hasil benchmark performa multinomial LR pada seluruh konfigurasi fitur dipaparkan pada Table 9. Karakteristik utama dari model LR adalah retensi representasi fitur penuh, di mana seluruh skema (tujuh dari tujuh konfigurasi) memilih tanpa reduksi PCA ($\text{pca}=\text{None}$). Evaluasi empiris menunjukkan bahwa konfigurasi tri-domain Face $\oplus$ Emotion $\oplus$ Age mencatatkan performa tertinggi dengan Akurasi 92.73% dan F1-Score 92.73% melalui parameter penalti $C = 0.1$ serta solver newton-cg. Capaian tri-domain ini melampaui konfigurasi dual-domain terbaik Emotion $\oplus$ Face yang meraih Akurasi 92.41% dan F1-Score 92.40%, serta mengungguli konfigurasi single-domain terbaik Face dengan Akurasi 90.60%. Temuan ini mengindikasikan efektivitas regularisasi L_2 dalam menangani ruang fitur berdimensi tinggi tanpa kompresi komponen utama.

Perkembangan performa SVM melintasi seluruh tahapan ablasi fitur dirangkum pada Table 10. Serupa dengan model linier, seluruh konfigurasi SVM secara konsisten mempertahankan ruang representasi penuh tanpa reduksi PCA ($\text{pca}=\text{None}$). Evaluasi empiris memperlihatkan peningkatan performa berjenjang, dimulai dari konfigurasi domain tunggal terbaik Face dengan Akurasi 90.83% dan F1-Score 90.83%. Integrasi representasi pada skema dual-domain Emotion $\oplus$ Face meningkatkan performa dengan Akurasi 93.29% dan F1-Score 93.29%, sebelum akhirnya mencapai titik tertinggi pada konfigurasi tri-domain Face $\oplus$ Emotion $\oplus$ Age dengan Akurasi 93.70% dan F1-Score 93.69%. Pada penalaan hyperparameter, parameter degree bernilai 2 hanya aktif pada fungsi kernel poly, sedangkan model berbasis kernel RBF tidak mengaktifkan parameter tersebut.

Sintesis komparatif deskriptif melintasi 28 kombinasi eksperimen menunjukkan bahwa model SVM berbasis fusi tri-domain Face $\oplus$ Emotion $\oplus$ Age menempati capaian performa tertinggi dalam ruang pencarian yang dievaluasi, dengan raihan Akurasi 93.70% dan F1-Score 93.69%. Berdasarkan nilai rata-rata performa pengklasifikasi di seluruh konfigurasi fitur, urutan hierarki deskriptif efektivitas algoritma dipimpin oleh SVM (91.47%), diikuti oleh LR (90.40%), RF (82.81%), dan GNB (79.37%). Karakteristik non-linier kernel polinomial pada SVM terbukti efektif dalam

TABLE 7. Performance Benchmark of Random Forest across Seven Feature Configurations.

Configuration	Accuracy	Precision	Recall	F1-Score	Best Parameters
Face	0.8546	0.8543	0.8546	0.8539	n_est=200, depth=30, max_feat=log2, min_split=2, min_leaf=1, pca=PCA(0.75), scaler=MinMaxScaler
Emotion	0.8060	0.8063	0.8060	0.8057	n_est=200, depth=None, max_feat=log2, min_split=5, min_leaf=1, pca=PCA(0.75), scaler=None
Age	0.7366	0.7363	0.7366	0.7354	n_est=200, depth=30, max_feat=log2, min_split=2, min_leaf=1, pca=PCA(0.75), scaler=None
Emotion $\oplus$ Face	0.8685	0.8689	0.8685	0.8682	n_est=200, depth=None, max_feat=sqrt, min_split=5, min_leaf=1, pca=PCA(0.75), scaler=None
Face $\oplus$ Age	0.8579	0.8578	0.8579	0.8573	n_est=200, depth=None, max_feat=sqrt, min_split=2, min_leaf=1, pca=PCA(0.75), scaler=None
Emotion $\oplus$ Age	0.8111	0.8111	0.8111	0.8108	n_est=200, depth=None, max_feat=log2, min_split=5, min_leaf=2, pca=PCA(0.75), scaler=None
Face $\oplus$ Emotion $\oplus$ Age	0.8620	0.8620	0.8620	0.8613	n_est=200, depth=30, max_feat=sqrt, min_split=5, min_leaf=1, pca=PCA(0.75), scaler=None

TABLE 8. Performance Benchmark of Gaussian Naive Bayes across Seven Feature Configurations.

Configuration	Accuracy	Precision	Recall	F1-Score	Best Parameters
Face	0.8269	0.8271	0.8269	0.8258	var_smoothing=4.1246e-02, pca=PCA(0.75), scaler=MinMaxScaler
Emotion	0.7338	0.7387	0.7338	0.7329	var_smoothing=3.0703e-03, pca=PCA(0.75), scaler=None
Age	0.6963	0.6979	0.6963	0.6952	var_smoothing=4.3755e-04, pca=PCA(0.75), scaler=MinMaxScaler
Emotion $\oplus$ Face	0.8486	0.8490	0.8486	0.8481	var_smoothing=5.8780e-03, pca=PCA(0.75), scaler=MinMaxScaler
Face $\oplus$ Age	0.8315	0.8343	0.8315	0.8317	var_smoothing=1.1253e-02, pca=PCA(0.75), scaler=MinMaxScaler
Emotion $\oplus$ Age	0.7681	0.7686	0.7681	0.7681	var_smoothing=1.6037e-03, pca=PCA(0.75), scaler=MinMaxScaler
Face $\oplus$ Emotion $\oplus$ Age	0.8505	0.8512	0.8505	0.8505	var_smoothing=5.8780e-03, pca=PCA(0.75), scaler=None

memetakan batas keputusan antarsubkelompok demografis berdimensi tinggi. Akan tetapi, perbandingan urutan performa ini sepenuhnya bersifat deskriptif empiris pada pengaturan eksperimen terkontrol dan tidak mencerminkan superioritas statistik mutlak antarfamili algoritma tanpa pengujian hipotesis formal.

B. FEATURE ABLATION STUDY

Kuantifikasi perubahan akurasi klasifikasi dari skema domain tunggal menuju konfigurasi ganda dan tiga domain dirangkum pada Table 7, Table 8, Table 9, dan Table 10. Pada model SVM, transisi representasi dari Face (90.83%) ke Emotion $\oplus$ Face (93.29%) meningkatkan akurasi sebesar 2.46% (0.0246). Penambahan domain ketiga pada konfigurasi tri-domain Face $\oplus$ Emotion $\oplus$ Age menghasilkan peningkatan performa lebih lanjut menjadi 93.70%, yang mencerminkan peningkatan kumulatif sebesar 2.87% (0.0287) di atas fitur tunggal Face. Pola peningkatan progresif ini mengindikasikan kehadiran informasi diskriminatif tambahan dari setiap domain representasi visual yang digabungkan, meskipun mekanisme interaksi antardimensi fitur laten tidak dapat dipastikan hanya dari hasil pengujian empiris.

Analisis kontribusi representasi domain usia (Age) membedah peranan informasi laten penuaan dalam sistem klasi-

fikasi demografis. Pada seluruh pengklasifikasi yang dievaluasi, Age merupakan konfigurasi single-domain dengan capaian akurasi terendah, seperti tercatat sebesar 87.64% pada SVM dan 69.63% pada GNB. Namun demikian, penggabungan fitur Age dengan fitur biometrik wajah pada skema dual-domain Face $\oplus$ Age menghasilkan akurasi 92.55%, yang memberikan peningkatan sebesar 1.72% (0.0172) di atas performa fitur Face murni (90.83%) pada model SVM. Hasil empiris tersebut menunjukkan kemungkinan adanya informasi diskriminatif tambahan dari age-associated representations yang melengkapi profil morfologi wajah, tanpa mengklaim bahwa kontribusi informasi tersebut bersifat ortogonal atau komplementer mutlak secara teoretis.

C. INTERSECTIONAL SUBGROUP PERFORMANCE

Profil kinerja klasifikasi granular pada model terbaik SVM berbasis fusi tri-domain Face $\oplus$ Emotion $\oplus$ Age dievaluasi secara mendalam berdasarkan metrik OvR sebagaimana disajikan pada Table 11. Seluruh subkelompok demografis berhasil mencapai F1-Score melampaui 91.00%, dengan rentang capaian bergerak dari 91.74% pada Black Females hingga 96.14% pada White Males, sehingga menghasilkan selisih disparitas rentang sebesar 4.40% (0.0440). Sementara itu, nilai Akurasi OvR berada pada rentang 97.31% hingga 98.70% dengan disparitas sebesar 1.39 pp. Perlu dicatat se-

TABLE 9. Performance Benchmark of Logistic Regression across Seven Feature Configurations.

Configuration	Accuracy	Precision	Recall	F1-Score	Best Parameters
Face	0.9060	0.9060	0.9060	0.9059	$C = 1$, solver=newton-cg, max_iter=500, pca=None, scaler=MinMaxScaler
Emotion	0.8847	0.8850	0.8847	0.8846	$C = 1$, solver=saga, max_iter=500, pca=None, scaler=MinMaxScaler
Age	0.8648	0.8649	0.8648	0.8648	$C = 0.1$, solver=lbfgs, max_iter=500, pca=None, scaler=None
Emotion $\oplus$ Face	0.9241	0.9241	0.9241	0.9240	$C = 0.1$, solver=lbfgs, max_iter=500, pca=None, scaler=None
Face $\oplus$ Age	0.9162	0.9162	0.9162	0.9162	$C = 0.1$, solver=newton-cg, max_iter=500, pca=None, scaler=None
Emotion $\oplus$ Age	0.9051	0.9052	0.9051	0.9051	$C = 0.1$, solver=lbfgs, max_iter=500, pca=None, scaler=None
Face $\oplus$ Emotion $\oplus$ Age	0.9273	0.9275	0.9273	0.9273	$C = 0.1$, solver=newton-cg, max_iter=500, pca=None, scaler=None

TABLE 10. Performance Benchmark of Support Vector Machine across Seven Feature Configurations.

Configuration	Accuracy	Precision	Recall	F1-Score	Best Parameters
Face	0.9083	0.9084	0.9083	0.9083	$C = 10$, rbf, γ =scale, pca=None, scaler=None
Emotion	0.9019	0.9020	0.9019	0.9017	$C = 10$, rbf, γ =scale, pca=None, scaler=None
Age	0.8764	0.8767	0.8764	0.8765	$C = 10$, rbf, γ =scale, pca=None, scaler=None
Emotion $\oplus$ Face	0.9329	0.9333	0.9329	0.9329	$C = 10$, rbf, γ =scale, pca=None, scaler=MinMaxScaler
Face $\oplus$ Age	0.9255	0.9254	0.9255	0.9254	$C = 10$, poly, γ =scale, deg=2, pca=None, scaler=None
Emotion $\oplus$ Age	0.9208	0.9210	0.9208	0.9209	$C = 10$, rbf, γ =scale, pca=None, scaler=None
Face $\oplus$ Emotion $\oplus$ Age	0.9370	0.9372	0.9370	0.9369	$C = 10$, poly, γ =scale, deg=2, pca=None, scaler=None

TABLE 11. Subgroup-Level Performance for Tri-Domain Models.

Classifier	Subgroup	Recall	Precision	F1-Score	OvR Accuracy
SVM (Tri)	White Males	0.9694	0.9536	0.9614	98.70%
	Black Males	0.9417	0.9549	0.9483	98.29%
	White Females	0.9472	0.9241	0.9355	97.82%
	Asian Males	0.9444	0.9239	0.9341	97.78%
	Asian Females	0.9250	0.9250	0.9250	97.50%
	Black Females	0.8944	0.9415	0.9174	97.31%
LR (Tri)	White Males	0.9611	0.9505	0.9558	98.52%
	Black Males	0.9306	0.9571	0.9437	98.15%
	White Females	0.9222	0.9121	0.9171	97.22%
	Asian Males	0.9278	0.9076	0.9176	97.22%
	Asian Females	0.9111	0.9162	0.9136	97.13%
	Black Females	0.9111	0.9213	0.9162	97.22%

cara metodologis bahwa tingginya nilai Akurasi OvR tersebut turut dipengaruhi oleh rasio dominansi sampel negatif sebesar 5:1 pada evaluasi biner OvR, sehingga metrik ini tidak diposisikan sebagai indikator tunggal disparitas kinerja.

Perbandingan profil kinerja subkelompok antara model SVM dan pengklasifikasi linier LR pada konfigurasi tri-domain disajikan pada Table 11. Model LR tri-domain turut memperlihatkan konsistensi performa yang tinggi dengan capaian F1-Score melampaui 91.00% pada seluruh kelas demografis, yang merentang dari 91.36% pada Asian Females

hingga 95.58% pada White Males dengan selisih disparitas rentang sebesar 4.22% (0.0422). Subkelompok White Males secara konsisten mencatatkan performa klasifikasi tertinggi pada kedua pengklasifikasi tersebut. Temuan empiris ini membuktikan bahwa fusi representasi tri-domain menghasilkan representasi visual yang tangguh dan terdistribusi stabil melintasi seluruh subkelompok demografis, baik pada model linier maupun model non-linier. Meskipun demikian, evaluasi subkelompok ini mencerminkan kinerja granular per kelas dan bukan audit keadilan algoritmik komprehensif.

D. ERROR PATTERN ASSESSMENT

Pergeseran distribusi kesalahan klasifikasi dari skema domain tunggal menuju konfigurasi ganda dan tiga domain dianalisis melalui diagram matriks konfusi pada Figure 4, yang mencakup Figure 4(a), Figure 4(b), dan Figure 4(c). Evaluasi empiris menunjukkan bahwa total misklasifikasi pada 2,160 data uji held-out menurun secara konsisten seiring perluasan domain representasi laten. Model SVM domain tunggal Face menghasilkan 198 kesalahan prediksi, yang kemudian berkurang menjadi 145 sampel pada skema dual-domain Emotion $\oplus$ Face. Konfigurasi tri-domain Face $\oplus$ Emotion $\oplus$ Age menekan kesalahan klasifikasi hingga mencapai titik terendah sebesar 136 sampel. Penurunan kesalahan yang konsisten ini mengindikasikan bahwa fusi representasi multi-domain mempertegas batas pemisahan antar-subkelompok demografis di ruang fitur laten.

Pemeriksaan mendalam terhadap matriks konfusi model domain tunggal Face pada Figure 4(a) mengungkap bahwa kesalahan klasifikasi terkonsentrasi secara dominan pada subkelompok antarras dalam gender yang sama. Kecenderungan tersebut terlihat sangat menonjol pada kohort wanita, di mana subkelompok Asian Females mengalami 46 misklasifikasi, yang mencakup 16 sampel terprediksi sebagai White Females dan 16 sampel sebagai Black Females. Sebaliknya, subkelompok White Females mencatatkan 20 kesalahan prediksi yang terdistribusi ke Asian Females. Pola empiris ini konsisten dengan kemungkinan adanya tumpang tindih fenotipe (phenotypic overlap) antarras pada representasi geometri biometrik wajah tunggal. Meskipun demikian, bukti matriks konfusi tersebut tidak membuktikan bahwa faktor tumpang tindih visual merupakan penyebab tunggal dari seluruh misklasifikasi yang teramati.

Perubahan distribusi kesalahan klasifikasi pada model dual-domain Emotion $\oplus$ Face dianalisis lebih lanjut berdasarkan matriks konfusi pada Figure 4(b). Penambahan representasi laten ekspresi afektif secara efektif mereduksi pola misklasifikasi antarras pada subkelompok bergender sama, terutama pada kelompok wanita. Kesalahan prediksi dari Asian Females ke White Females berhasil ditekan secara nyata dari 16 kasus menjadi 9 kasus. Pada saat yang bersamaan, jumlah sampel prediksi benar (true positive) pada subkelompok White Females meningkat dari 325 citra menjadi 334 citra. Integrasi sinyal dinamis ekspresi wajah tersebut memperkuat batas pembeda visual antarras dalam ruang representasi laten, sehingga pengklasifikasi mampu membedakan fitur morfologi yang serupa dengan tingkat kepastian yang lebih kokoh dan stabil.

Pola misklasifikasi pada konfigurasi tri-domain Face $\oplus$ Emotion $\oplus$ Age dievaluasi secara komprehensif berdasarkan matriks konfusi pada Figure 4(c). Integrasi representasi domain usia meningkatkan jumlah prediksi benar secara konsisten pada subkelompok Asian Females menjadi 333 sampel dan White Females menjadi 341 sampel. Selain itu, kesalahan klasifikasi lintas gender, yaitu kondisi ketika subjek wanita tertukar menjadi pria atau sebaliknya, hanya berjumlah 51 kasus dari total 2,160 data uji held-out (2.36%). Temuan

empiris ini mengindikasikan bahwa batas antargender terpisah dengan sangat tegas di dalam ruang representasi laten multi-domain, sehingga kesalahan klasifikasi yang tersisa pada model tri-domain hampir seluruhnya didominasi oleh misklasifikasi antarras di dalam kelompok gender yang sama.

E. SELECTED SVM KERNEL CONFIGURATION

Optimasi hyperparameter melalui GridSearchCV menetapkan model SVM berbasis kernel polinomial derajat dua sebagai konfigurasi terbaik untuk klasifikasi ras dan gender interseksional. Konfigurasi terpilih ini menerapkan parameter penalti $C = 10$ tanpa PCA maupun Scaler, serta mengadopsi fungsi kernel polinomial pada (8) dengan koefisien penskalaan $\gamma = \text{scale}$, konstanta bawaan $\text{coef0} = 0.0$, dan derajat pemetaan $d = 2$. Temuan empiris ini menegaskan bahwa konfigurasi terpilih merupakan model berkinerja tertinggi di dalam search space yang dievaluasi, bukan klaim keunggulan matematis mutlak dari fungsi kernel tersebut secara umum. Secara konseptual, pemetaan polinomial derajat dua memungkinkan model menangkap interaksi kuadratik antardimensi fitur laten multi-domain tanpa memerlukan proyeksi eksplisit berdimensi tak terhingga, sehingga batas keputusan yang terbentuk menjadi lebih fleksibel dalam memisahkan subkelompok demografis.

Karakteristik penting lain dari konfigurasi SVM terbaik pada evaluasi empiris adalah konsistensi pemilihan ruang representasi fitur penuh tanpa reduksi dimensi PCA ($\text{pca}=\text{None}$). Pemilihan opsi $\text{pca}=\text{None}$ tersebut menunjukkan bahwa mempertahankan seluruh 2,304 dimensi representasi laten tri-domain memberikan performa klasifikasi terbaik di dalam search space yang dievaluasi. Namun demikian, interpretasi ini sepenuhnya berlandaskan pada bukti observasi empiris, sehingga hasil pengujian tidak dapat disimpulkan sebagai bukti definitif bahwa reduksi PCA membuang informasi diskriminatif yang penting. Karakteristik regularisasi SVM melalui pemaksimalan margin terbukti efektif dalam mengelola ruang fitur berdimensi tinggi tanpa mengalami degradasi performa akibat overfitting, sehingga struktur geometri laten dari ketiga domain representasi wajah tetap terpelihara secara komprehensif.

F. COMPARISON WITH PRIOR STUDIES

Perbandingan empiris secara langsung antara kerangka kerja yang diusulkan dan studi terdahulu yang dievaluasi pada dataset DemogPairs dirangkum pada Table 12. Model usulan berbasis Tri-Domain ViT + SVM (Face $\oplus$ Emotion $\oplus$ Age) meraih Akurasi 93.70%, Presisi 0.9372, Recall 0.9370, dan F1-Score 0.9369. Capaian kuantitatif tersebut melampaui metrik yang dilaporkan pada model Dual-ViT + SVM oleh Putri *et al.* [9], yaitu Akurasi 92.41% dan F1-Score 0.9238, serta model MD-ViT + XGBoost oleh Putri *et al.* [10] dengan Akurasi 89.07% dan F1-Score 0.8901. Seluruh angka pembandingan disitasi langsung dari publikasi masing-masing, sehingga komparasi ini berfungsi sebagai penempatan kontekstual pada dataset acuan yang sama dan tidak dimaksudkan sebagai replikasi eksperimen yang sepenuhnya identik.




FIGURE 4. Confusion Matrices across Feature Fusion Schemes on the Held-Out Test Set: (a) Single-Domain (Face), (b) Dual-Domain (Emotion $\oplus$ Face), and (c) Tri-Domain (Face $\oplus$ Emotion $\oplus$ Age).

TABLE 12. Comparative Performance of Proposed Framework against Prior Studies on the DemogPairs Dataset.

Model	Accuracy	Precision	Recall	F1-Score
MD-ViT [10]	89.07%	0.8912	0.8907	0.8901
Dual-ViT [9]	92.41%	0.9248	0.9241	0.9238
Ours (Tri-Domain ViT + SVM)	93.70%	0.9372	0.9370	0.9369

Penelitian seminal mengenai perancangan dataset DemogPairs oleh Hupont dan Fernández [11] meletakkan landasan penting dalam mengukur dampak ketidakseimbangan demografis pada sistem pengenalan wajah. Menanggapi tantangan tersebut, kerangka kerja integrasi representasi tiga domain yang diusulkan dalam penelitian ini menghasilkan akurasi tertinggi di antara studi-studi yang dibandingkan pada dataset DemogPairs. Selain mengevaluasi metrik agregat global, penyelidikan ini menjalankan analisis disparitas subkelompok secara komprehensif pada konfigurasi tri-domain terbaik untuk memetakan variasi performa antarsubkelompok demografis secara transparan. Evaluasi terperinci tersebut membuktikan stabilitas pengenalan lintas kategori ras dan gender interseksional, meskipun perbandingan disparitas lintas seluruh skema sebelumnya tidak dapat disertakan karena informasi variasi performa tersebut tidak dilaporkan dalam literatur terkait.

V. CONCLUSION

Penelitian ini mengevaluasi kerangka kerja fusi representasi laten Tri-Domain ViT (Face $\oplus$ Emotion $\oplus$ Age: 2,304 dimensi) untuk klasifikasi ras dan gender interseksional pada dataset DemogPairs. Hasil eksperimen menunjukkan bahwa fusi tri-domain menjadi konfigurasi terbaik pada 3 dari 4 classifier yang dievaluasi, mencakup SVM, LR, dan GNB. Dalam search space yang dievaluasi, model SVM teroptimasi dengan hyperparameter $C = 10$ dan kernel polinomial derajat dua menghasilkan performa klasifikasi tertinggi, yakni Akurasi 93.70% serta F1-Score 93.69% (0.9369). Meskipun demikian, manfaat integrasi representasi multi-domain terbukti bersifat classifier-dependent karena RF justru meraih performa puncak pada skema dual-domain Emotion $\oplus$ Face

dengan akurasi 86.85%. Di samping itu, evaluasi kinerja subkelompok mengonfirmasi bahwa nilai F1-Score pada keenam subkelompok demografis terdistribusi stabil pada rentang 91.74% hingga 96.14% (0.9174 hingga 0.9614).

Terlepas dari capaian tersebut, penelitian ini memiliki sejumlah keterbatasan yang membuka peluang riset lanjutan. Pertama, cakupan demografis penyelidikan ini terbatas pada tiga kelompok ras makro (Asian, Black, dan White) pada dataset DemogPairs, sehingga temuan empiris yang diperoleh tidak dapat digeneralisasikan secara langsung ke populasi multirasial maupun kelompok etnisitas lain tanpa pengujian komprehensif tambahan. Kedua, ekstraksi representasi laten dijalankan secara terpisah (offline) memanfaatkan backbone ViT pra-latih yang dibekukan tanpa fine-tuning end-to-end secara simultan. Ketiga, evaluasi eksperimental masih berfokus pada citra lingkungan laboratorium terkontrol, sehingga respons model terhadap variasi pose ekstrem, oklusi, dan pencahayaan liar (in-the-wild) memerlukan pengujian lebih jauh. Oleh karena itu, arah penelitian mendatang disarankan untuk mengeksplorasi mekanisme fusi atensi adaptif lintas-modal (cross-attention transformer fusion) yang dilatih secara end-to-end untuk mempelajari bobot interaksi dinamis antardomain, serta memperluas pengujian pada dataset berskala besar yang lebih heterogen seperti FairFace atau UTKFace. Selain itu, penerapan metode visual explainability seperti Attention Rollout atau Grad-CAM sangat diperlukan untuk memetakan kontribusi spasial tiap domain secara transparan, disertai penegakan tata kelola etika kecerdasan buatan (Responsible AI) dengan pengawasan manusia (human-in-the-loop) untuk mencegah eksploitasi pada sistem pengawasan publik.

REFERENCES

- [1] D. Belcar, P. Grd, and I. Tomićić, "Automatic ethnicity classification from middle part of the face using convolutional neural networks," *Informatics*, vol. 9, no. 1, p. 18, 2022.
- [2] H. Liao, L. Yuan, M. Wu, L. Zhong, G. Jin, and N. Xiong, "Face gender and age classification based on multi-task, multi-instance and multi-scale learning," *Applied Sciences*, vol. 12, no. 23, p. 12432, 2022.
- [3] G. Sunitha, K. Geetha, S. Neelakandan, A. K. S. Pundir, S. Hemalatha, and V. Kumar, "Intelligent deep learning based ethnicity recognition and classification using facial images," *Image and Vision Computing*, vol. 121, p. 104404, 2022.
- [4] J. Brinkmann, P. Swoboda, and C. Bartelt, "A multidimensional analysis of social biases in vision transformers," in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 2023, pp. 4891–4900.
- [5] S. Ramachandran and A. Rattani, "Deep generative views to mitigate gender classification bias across gender-race groups," in *Pattern Recognition, Computer Vision, and Image Processing. ICPR 2022 International Workshops and Challenges*, J.-J. Rousseau and B. Kapralos, Eds. Cham, Switzerland: Springer Nature Switzerland, 2023, pp. 551–569.
- [6] S. Chen, X. Lai, Y. Yan, D.-H. Wang, and S. Zhu, "Learning an attention-aware parallel sharing network for facial attribute recognition," *Journal of Visual Communication and Image Representation*, vol. 90, p. 103745, 2023.
- [7] G. G. Tahyudin, M. D. Sulistiyo, M. Arzaki, and E. Rachmawati, "Classifying gender based on face images using vision transformer," *International Journal on Informatics Visualization*, vol. 8, no. 1, pp. 18–25, 2024.
- [8] M. Kalkatawi and U. Saeed, "Ethnicity classification based on facial images using deep learning approach," *International Journal of Advanced Computer Science and Applications*, vol. 15, no. 2, pp. 217–226, 2024.
- [9] R. A. Putri, L. Anifah, R. E. Putra, Y. Yamasari, and R. A. Akbar, "Dual vision transformer integration for race and gender recognition based on facial images," in *Proceedings of the 2025 8th International Conference on Vocational Education and Electrical Engineering (ICVEE)*, 2025, pp. 258–264.
- [10] R. A. Putri, R. E. Putra, and Y. Yamasari, "MD-ViT: Multidomain vision transformer fusion for fair demographic attribute recognition," *Journal of Information Engineering and Educational Technology*, vol. 9, no. 2, pp. 64–79, 2025.
- [11] I. Hupont and C. Fernández, "DemogPairs: Quantifying the impact of demographic imbalance in deep face recognition," in *Proceedings of the 2019 14th IEEE International Conference on Automatic Face and Gesture Recognition (FG)*, 2019, pp. 1–7.



RICKY EKA PUTRA menyelesaikan studi Sarjana, Magister, dan Doktor di bidang Ilmu Komputer di Institut Teknologi Sepuluh Nopember (ITS) masing-masing pada tahun 2008, 2011, dan 2020, serta memperoleh gelar Profesi Insinyur pada tahun 2024. Saat ini, beliau bertugas sebagai dosen dan peneliti di Departemen Informatika, Fakultas Informatika, Universitas Negeri Surabaya. Beliau aktif berkiprah dalam pelaksanaan tridarma perguruan tinggi yang mencakup pengajaran bidang informatika, program pemberdayaan masyarakat, publikasi karya ilmiah pada berbagai jurnal bereputasi, diseminasi riset pada forum seminar ilmiah, serta perolehan Hak Kekayaan Intelektual (HKI). Fokus penelitian utama beliau diarahkan pada pengembangan model kecerdasan buatan terapan yang menjembatani kemajuan metode komputasi cerdas dengan penyelesaian tantangan berbasis data nyata. Bidang minat penelitian beliau meliputi Deep Learning, Computer Vision, Big Data Analytics, aplikasi digital dan user experience, psikologi klinis, intensi perilaku, healthcare informatics, metode statistika, serta pendidikan digital dan anak usia dini. Profil akademik dan rekaman publikasi beliau dapat diakses melalui tautan [ORCID: 0000-0002-5515-7967](https://orcid.org/0000-0002-5515-7967).



REZKY ARISANTI PUTRI meraih gelar Sarjana Teknik Informatika pada tahun 2019 dengan peminatan bidang Kecerdasan Buatan (Artificial Intelligence) dan telah menuntaskan studi Magister Informatika di Universitas Negeri Surabaya (UNESA). Saat ini, beliau aktif berkiprah sebagai peneliti di Departemen Informatika, Fakultas Informatika, Universitas Negeri Surabaya. Beliau terlibat intensif dalam riset pengenalan atribut demografis wajah berbasis model transformer serta secara aktif mendiseminasikan kontribusi keilmuannya melalui publikasi pada forum konferensi internasional dan jurnal ilmiah bereputasi. Fokus dan minat penelitian beliau mencakup Computer Vision, Deep Learning, Vision Transformer, Facial Attribute Recognition, Natural Language Processing, Machine Learning, dan Algorithmic Fairness. Melalui kegiatan akademik dan eksplorasi riset yang konsisten, beliau terus memperdalam kompetensi keilmuan serta berkontribusi nyata dalam kemajuan teknologi komputasi cerdas. Rekam jejak penelitian serta profil akademik beliau dapat diakses melalui tautan [ORCID: 0009-0000-8021-1833](https://orcid.org/0009-0000-8021-1833).



YUNI YAMASARI merupakan dosen dan peneliti di Departemen Informatika, Fakultas Informatika, Universitas Negeri Surabaya (UNESA) dengan landasan keilmuan yang kokoh di dunia akademik maupun praktis. Beliau menyelesaikan pendidikan Sarjana, Magister, hingga Doktor di Institut Teknologi Sepuluh Nopember (ITS), dengan kepakaran utama pada bidang Software Engineering dan Data Mining. Aktivitas tridarma beliau ditandai oleh keterlibatan aktif dalam pemberdayaan masyarakat, publikasi artikel ilmiah bereputasi, serta penulisan buku teks akademik. Beliau secara berkala mendiseminasikan temuan penelitiannya di berbagai forum ilmiah nasional maupun internasional dan telah memperoleh beberapa Hak Kekayaan Intelektual (HKI). Dedikasi akademik beliau diarahkan untuk mendorong perkembangan rekayasa perangkat lunak, analisis data komprehensif, dan bidang informatika terapan. Profil akademik dan riwayat publikasi beliau dapat ditelusuri melalui tautan [ORCID: 0000-0001-9719-3491](https://orcid.org/0000-0001-9719-3491).



RAFY AULIA AKBAR menyelesaikan pendidikan Sarjana Teknik Informatika pada tahun 2019 dan meraih gelar Magister Informatika di Universitas Negeri Surabaya dengan konsentrasi pada bidang Ilmu Komputer. Semasa studi, beliau berhasil menorehkan prestasi dengan menerima penghargaan Best Solution Award pada kompetisi regional ASEAN Vocational and Engineering Camp 2017 bertema "Toward School 4.0". Saat ini, beliau aktif mendedikasikan diri sebagai peneliti di Departemen Informatika, Fakultas Informatika, Universitas Negeri Surabaya. Fokus dan minat penelitian beliau terpusat pada domain Computer Vision, Medical Image Analysis, Multimodal Deep Learning, Natural Language Processing, serta arsitektur Vision Transformer, khususnya dalam pengembangan sistem pembangkitan laporan medis otomatis. Rekam jejak publikasi dan profil ilmiah beliau dapat diakses melalui tautan [ORCID: 0009-0003-6991-0694](https://orcid.org/0009-0003-6991-0694).

...