

Date of publication xxxx 00, 0000, date of current version xxxx 00, 0000.

Digital Object Identifier 10.1109/ACCESS.2026.0000000

Multi-Domain Vision Transformer Fusion for Intersectional Demographic Classification from Facial Images

RICKY EKA PUTRA¹, REZKY ARISANTI PUTRI¹, YUNI YAMASARI¹, RAFY AULIA AKBAR¹,
AND SHUKOR SANIM MOHD FAUZI²

¹Department of Informatics, Faculty of Informatics, Universitas Negeri Surabaya, Surabaya 60231, Indonesia

²Faculty of Computer and Mathematical Sciences, Universiti Teknologi MARA Perlis Branch, 02600 Arau, Perlis, Malaysia

Corresponding author: Ricky Eka Putra (e-mail: rickyeka@unesa.ac.id).

This research was supported in part by the Department of Informatics, Faculty of Informatics, Universitas Negeri Surabaya.

ABSTRACT Pengenalan atribut demografis wajah seperti ras dan gender secara simultan menghadapi tantangan variasi ekspresi, penuaan biologis, phenotypic overlap, serta keterbatasan representasi single-domain. Oleh karena itu, dibutuhkan kerangka representasi terpadu yang mampu memadukan berbagai karakteristik wajah secara komprehensif. Penelitian ini mengusulkan kerangka kerja fusi fitur multi-domain yang mengintegrasikan representasi visual dari tiga model Vision Transformer (ViT) pre-trained spesifik tugas untuk biometrik wajah, ekspresi afektif, dan estimasi usia, yang dipadukan dengan optimasi pipeline machine learning klasik untuk klasifikasi enam intersectional demographic subgroups pada dataset DemogPairs. Representasi visual diekstraksi secara offline dari setiap model untuk menghasilkan representasi visual terpadu yang memadukan informasi komplementer lintas-domain. Tujuh konfigurasi fitur dievaluasi melalui 5-Fold Stratified Cross-Validation pada empat classifier: Random Forest (RF), Gaussian Naive Bayes (GNB), Logistic Regression (LR), dan Support Vector Machine (SVM) dengan hyperparameter tuning via Grid Search Cross-Validation (GridSearchCV). Hasil eksperimen menunjukkan bahwa fusi tri-domain meraih performa terbaik pada tiga dari empat classifier yang dievaluasi, dengan model SVM menghasilkan performa tertinggi, mencatat Accuracy 93.70%, Precision 93.72%, Recall 93.70%, dan F1-Score 93.69% pada data uji independen. Evaluasi mendalam pada keenam subkelompok mencatat rentang F1-Score antara 91.74% dan 96.14%, yang membuktikan efektivitas fusi representasi multi-domain dalam mengenali atribut demografis interseksional.

INDEX TERMS Race and gender classification, intersectional demographic recognition, multi-domain feature fusion, Vision Transformer.

I. INTRODUCTION

Pengenalan otomatis atribut demografis wajah memegang peranan penting dalam berbagai domain aplikasi cerdas, termasuk sistem forensik digital, kontrol akses biometrik, interaksi manusia-komputer, dan personalisasi layanan interaktif [1], [2]. Namun, sejumlah studi melaporkan adanya disparitas performa pada subkelompok demografis tertentu, termasuk perempuan dan individu dengan warna kulit lebih gelap [3], [4]. Ketimpangan tersebut dapat dipengaruhi oleh berbagai faktor, termasuk ketidakseimbangan distribusi data dan keterbatasan representasi fitur terhadap variasi visual [5]. Keterbatasan sistem konvensional dalam menangani variasi visual tersebut memperlihatkan bahwa pengenalan demografis yang

adil dan akurat masih menghadapi kendala nyata di lapangan, sehingga diperlukan pendekatan representasi baru yang mampu memodelkan interaksi atribut demografis ras dan gender secara terpadu serta komprehensif.

Sebagian pendekatan pengenalan atribut wajah memodelkan atribut secara terpisah, sedangkan multi-task learning memungkinkan beberapa atribut dipelajari secara simultan [6]. Pemodelan atribut secara terpisah dapat membatasi analisis terhadap kelompok yang terbentuk dari kombinasi atribut, seperti ras dan gender [7], [8]. Akibatnya, metrik agregat berpotensi tidak menangkap disparitas performa pada subkelompok tertentu [9]. Evaluasi pada subkelompok demografis dengan representasi yang seimbang se-

cara terkontrol dapat menyediakan landasan komparatif yang lebih konsisten dan objektif untuk mengukur variasi performa antarkelompok [9]. Pemodelan interseksional juga menghadapi tantangan representasi karena karakteristik wajah dan ekspresi dapat bervariasi antar kelompok demografis, sehingga diperlukan representasi visual yang mampu mempertahankan informasi diskriminatif sekaligus robust terhadap variasi tersebut [10].

Perkembangan metodologi pengenalan atribut wajah telah bergeser dari fitur buatan tangan menuju deep learning, termasuk CNN dan ViT. Pada era arsitektur Convolutional Neural Networks (CNN), berbagai penelitian mengeksplorasi ekstraksi ciri demografis melalui pemanfaatan region spesifik wajah seperti area wajah bagian tengah, kerangka kerja multi-tugas berbasis multi-skala untuk estimasi usia dan gender secara simultan, serta model CNN mendalam untuk pengenalan etnisitas [11], [12], [13]. ViT mampu memodelkan hubungan global antarpatch melalui Multi-Head Self-Attention (MHSA), sehingga berpotensi menghasilkan representasi visual yang lebih kontekstual, sementara pemanfaatan representasi generatif sintesis turut dikembangkan untuk memitigasi disparitas demografis [14], [15]. Di samping itu, integrasi mekanisme atensi paralel, pemanfaatan ViT untuk klasifikasi gender wajah, serta eksplorasi arsitektur transformer multi-aksis semakin memperkaya variasi pemodelan representasi visual [16], [17], [18]. Lebih lanjut, eksplorasi penggabungan representasi ViT lintas domain mulai dikembangkan melalui integrasi fitur ganda wajah dan emosi untuk meningkatkan diskriminasi atribut ras dan gender [19], [20]. Meskipun demikian, fusi representasi biometrik, ekspresi, dan penuaan dalam satu representasi terpadu masih relatif terbatas.

Meskipun perkembangan ViT terus berlangsung, masih terdapat beberapa kesenjangan yang relevan dengan klasifikasi demografis interseksional. Pertama, sebagian besar studi terdahulu bertumpu pada representasi biometrik wajah domain tunggal, namun integrasi informasi afektif secara simultan untuk klasifikasi demografis interseksional masih terbatas [11], [17], [18]. Kedua, pengenalan demografis sering kali menunjukkan sensitivitas tinggi terhadap perubahan morfologi wajah seiring pertambahan usia karena ekstraksi fitur yang digunakan tidak mengikutsertakan representasi penuaan biologis [12], [17]. Ketiga, studi komparatif mengenai pengaruh classifier, penskalaan fitur, dan reduksi dimensionalitas pada representasi transformer masih terbatas [13], [19], [20]. Untuk menjembatani keterbatasan representasi domain tunggal serta mengevaluasi batas keputusan classifier hilir tersebut, penelitian ini mengusulkan integrasi tiga domain representasi ViT yang dipadukan dengan optimasi pipeline classical classifier terstruktur.

Untuk menjawab kesenjangan riset tersebut, penelitian ini menyajikan kerangka evaluasi fusi representasi multi-domain terpadu yang memadukan tiga representasi spesifik tugas untuk klasifikasi demografis interseksional pada citra wajah. Kerangka evaluasi ini mengintegrasikan tiga domain representasi komplementer, meliputi representasi biometrik wajah,

ekspresi emosi afektif, dan karakteristik penuaan biologis, ke dalam satu representasi terpadu melalui fusi fitur [21], [22]. Ekstraksi fitur dilakukan secara offline dari model backbone ViT pre-trained yang dibekukan, sehingga klasifikasi hilir dapat dijalankan secara efisien tanpa memerlukan komputasi fine-tuning ulang backbone [23]. Vektor fitur gabungan yang dihasilkan kemudian dievaluasi secara sistematis melalui skema ablasi single-domain, dual-domain, dan tri-domain menggunakan empat famili classical machine learning classifiers, yaitu RF, GNB, LR, dan SVM. Seluruh classifier hilir dioptimalkan dan dievaluasi menggunakan Stratified Cross-Validation dalam pipeline pembelajaran terstruktur yang mengintegrasikan penskalaan fitur serta reduksi dimensionalitas Principal Component Analysis (PCA), dengan setiap transformasi dipelajari secara ketat hanya pada lipatan data pelatihan di setiap fold untuk mencegah data leakage [24]. Pendekatan ini memungkinkan analisis empiris yang objektif mengenai kontribusi relatif masing-masing domain representasi terhadap ketahanan pemodelan batas keputusan demografis.

Kontribusi ilmiah utama dari penelitian ini dirangkum ke dalam tiga poin utama sebagai berikut:

- 1) Merumuskan kerangka evaluasi fusi representasi multi-domain yang mengintegrasikan domain biometrik wajah, ekspresi afektif, dan estimasi penuaan dari tiga model Vision Transformer pra-latih yang dibekukan, dikombinasikan dengan optimasi pipeline machine learning klasik (SVM, LR, RF, GNB) serta hyperparameter tuning sistematis melalui 5-Fold Stratified Cross-Validation.
- 2) Menyajikan evaluasi komparatif komprehensif pada 28 konfigurasi model di dataset DemogPairs yang mengonfirmasi keunggulan fusi tri-domain pada model nonlinier SVM, serta membuktikan secara inferensial terjadinya kejenuhan fitur representasi (feature saturation) dan dinamika fusi yang bergantung pada arsitektur pengklasifikasi (classifier-dependent).
- 3) Menyediakan investigasi granular disparitas performa pada enam subkelompok demografis interseksional melalui metrik keadilan formal, evaluasi pola kesalahan within-race dan cross-gender, serta pemosisian sebagai baseline terkontrol 6-kelas pertama yang komprehensif pada dataset DemogPairs.

Sistematika penulisan artikel ini disusun sebagai berikut: Section II membahas penelitian terdahulu mengenai pengenalan demografis wajah dan arsitektur transformer. Section III menjabarkan spesifikasi dataset DemogPairs, ekstraksi representasi multi-domain ViT, dan pipeline klasifikasi teroptimasi. Section IV memaparkan hasil evaluasi eksperimental, studi ablasi fitur, serta analisis performa subkelompok interseksional. Terakhir, Section V merangkum kesimpulan utama penelitian, keterbatasan metodologis, dan rekomendasi arah riset mendatang.

II. RELATED WORKS

Perkembangan pengenalan atribut demografis wajah beralih dari deskriptor berbasis region dan ciri buatan tangan menuju representasi mendalam. Pendekatan berbasis region lokal memanfaatkan geometri bagian tengah wajah untuk mengenali etnisitas dan mengurangi interferensi latar belakang [11]. Namun, pendekatan CNN masih menghadapi tantangan dalam mempertahankan performa terhadap variasi pencahayaan dan perbedaan karakteristik wajah antarkelompok ras, termasuk fenomena Other-Race Effect. Peningkatan kedalaman jaringan konvolusi dapat memperkaya representasi fitur visual untuk membedakan populasi yang beragam [13]. Selain itu, mekanisme berbagi fitur paralel dengan atensi visual dikembangkan untuk menangkap keterkaitan antara-tribut wajah sekaligus mengurangi keterbatasan representasi lokal. Pendekatan ini menunjukkan pergeseran dari rekayasa fitur menuju pembelajaran representasi yang lebih adaptif terhadap keragaman wajah [16].

Penerapan ViT dalam biometrik wajah memberikan kemampuan pemodelan visual yang berbeda dari pendekatan konvolusional. Melalui mekanisme Multi-Head Self-Attention (MHSA), transformer dapat memodelkan hubungan antarpatch secara global sehingga menangkap dependensi spasial yang lebih luas dibandingkan operasi konvolusi lokal [14]. Karakteristik tersebut menunjukkan potensi transformer dalam memodelkan atribut demografis, termasuk gender, pada citra wajah beresolusi terstandarisasi [17]. Selain ViT standar, arsitektur hibrida seperti MaxViT menggabungkan perhatian berbasis jendela dan kisi untuk membangun representasi spasial secara bertingkat [18]. Meskipun transformer memiliki kemampuan representasi global yang kuat, performanya tetap dipengaruhi oleh kualitas, ukuran, dan karakteristik distribusi data latih yang digunakan dalam proses pembelajaran.

Investigasi terhadap disparitas performa dalam sistem visi komputer mendorong penggunaan protokol evaluasi yang mempertimbangkan keseimbangan distribusi kelas dan subkelompok demografis. Pengujian pada dataset yang seimbang dapat menyediakan kondisi eksperimen yang lebih terkontrol untuk membandingkan performa antarsubkelompok dengan mengurangi pengaruh ketimpangan jumlah sampel. Namun, keseimbangan distribusi tidak serta-merta menghilangkan bias sosial yang melekat pada data. Analisis representasi laten juga menunjukkan bahwa model transformer dapat mereproduksi bias sosial yang berasal dari korpus pra-latih berskala besar [14]. Untuk mengurangi disparitas performa antarkelompok ras dan gender, augmentasi generatif berbasis StyleGAN2 digunakan untuk menghasilkan variasi sintesis yang dapat membantu mengurangi kesalahan klasifikasi [15]. Temuan tersebut menegaskan pentingnya evaluasi lintas subkelompok demografis secara sistematis.

Keterbatasan representasi berbasis satu domain dalam menangkap keragaman karakteristik wajah mendorong eksplorasi pembelajaran multi-tugas dan fusi representasi dari berbagai sumber informasi. Pendekatan multi-tugas digunakan untuk mempelajari keterkaitan antara atribut usia

dan gender melalui representasi wajah yang diproses secara bersama [12]. Mekanisme berbagi representasi paralel juga dikembangkan untuk mengombinasikan berbagai atribut afektif secara simultan, sedangkan pendekatan generatif dapat memperkaya variasi fitur antarkelompok demografis [16], [15]. Lebih lanjut, integrasi fitur laten berbasis ViT yang memadukan representasi biometrik wajah dan ekspresi emosi menunjukkan potensi untuk meningkatkan klasifikasi atribut interseksional [19]. Penggabungan representasi biometrik dengan informasi usia juga memperlihatkan kontribusi informasi yang saling melengkapi, sehingga fusi lintas domain menjadi pendekatan yang relevan [20].

Setelah representasi fitur diperoleh, pemilihan classifier hilir memengaruhi cara fitur berdimensi tinggi dipetakan ke ruang keputusan. Pendekatan end-to-end umumnya menggunakan lapisan SoftMax untuk memetakan representasi fitur ke probabilitas kelas secara langsung [11], [18]. Sebagai alternatif, Support Vector Machine (SVM) dapat mempelajari batas keputusan nonlinier pada ruang fitur tanpa memperbarui parameter backbone yang telah dibekukan [13]. Model ensemble berbasis pohon seperti RF dan pendekatan probabilistik seperti GNB juga dapat digunakan sebagai classifier dengan karakteristik kompleksitas dan pemisahan kelas yang berbeda [12]. Perbedaan tersebut menunjukkan bahwa pemilihan classifier dapat memengaruhi efektivitas pemanfaatan representasi laten, khususnya ketika fitur berasal dari beberapa domain dan memiliki dimensi yang tinggi.

Berdasarkan literatur tersebut, masih terdapat ruang untuk mengeksplorasi pemodelan atribut demografis wajah melalui integrasi representasi dari beberapa domain. Berbeda dari studi terdahulu yang umumnya menggunakan representasi domain tunggal atau menggabungkan sebagian domain, penelitian ini mengusulkan fusi tri-domain yang memadukan representasi geometri biometrik wajah, isyarat afektif ekspresi, dan karakteristik morfologi penuaan biologis menggunakan model ViT pra-latih dengan backbone yang dibekukan. Representasi laten dari ketiga domain kemudian dikonkatenasi dan digunakan sebagai masukan bagi SVM untuk mempelajari batas keputusan nonlinier. Evaluasi dilakukan pada dataset DemogPairs yang seimbang untuk membandingkan klasifikasi ras dan gender secara interseksional serta menganalisis disparitas performa antarsubkelompok secara sistematis pada setiap kelompok yang dievaluasi.

III. MATERIALS AND METHODS

Kerangka kerja yang diusulkan memadukan representasi visual multi-domain dan optimasi model pembelajaran mesin untuk klasifikasi ras dan gender interseksional, sebagaimana diilustrasikan pada Figure 1. Metodologi diawali pemisahan citra wajah 224×224 piksel pada dataset DemogPairs menjadi partisi latih dan uji via stratified split. Tiga model ViT-Base pre-trained yang dibekukan mengekstraksi representasi laten berdimensi 768 dari token [CLS] secara offline. Ketiga vektor digabungkan melalui fusi konkatenasi $\mathbf{z}_{\text{tri}} = \mathbf{f}_{\text{face}} \oplus \mathbf{f}_{\text{emotion}} \oplus \mathbf{f}_{\text{age}}$, di mana $\mathbf{z}_{\text{tri}}$ menyatakan vektor tri-domain berdimensi 2,304, $\oplus$ adalah operator konkatenasi,




FIGURE 1. End-to-End Framework of the Proposed Multi-Domain Vision Transformer Feature Fusion and Classical Classifier Optimization for Intersectional Race and Gender Classification.

serta f_{face} , f_{emotion} , dan f_{age} merepresentasikan fitur biometrik wajah, ekspresi, dan usia. Vektor representasi diproses dalam pipeline modular Scaler dan PCA sebelum diklasifikasikan ke enam kelas interseksional oleh RF, GNB, LR, dan SVM. Penalaan hyperparameter dijalankan melalui 5-Fold Stratified Cross-Validation dengan skema GridSearchCV terisolasi untuk mencegah kebocoran informasi sebelum evaluasi data uji.

A. DATASET

Dataset yang digunakan dalam penelitian ini adalah DemogPairs [25], sebuah dataset yang dirancang khusus untuk pengenalan wajah lintas kelompok demografis. Dataset ini memuat total 10,800 citra wajah yang terdistribusi secara seimbang ke dalam enam kelas interseksional. Keenam subkelompok tersebut mencakup kombinasi persilangan dari tiga kelompok ras makro dan dua kelompok gender, yaitu Asian Females, Asian Males, Black Females, Black Males, White Females, dan White Males, dengan alokasi seragam tepat 1,800 citra per kelas. Struktur data yang seimbang ini menyediakan kondisi evaluasi terkontrol untuk membandingkan performa model antarsubkelompok secara objektif, sekaligus memitigasi distorsi yang timbul akibat ketimpangan jumlah sampel [20]. Karakteristik visual dari keenam subkelompok demografis diilustrasikan pada Figure 2.

Untuk memastikan integritas pengujian empiris, dataset dibagi menggunakan protokol 80/20 stratified split dengan `random_state=42` dan parameter `stratify=y`. Pembagian tersebut menghasilkan 8,640 citra latih dengan 1,440 sampel per kelas serta 2,160 citra uji held-out independen dengan 360 sampel per kelas pada enam kelas interseksional, sebagaimana dirinci pada Table 1. Partisi ini sepenuhnya mengisolasi set uji held-out, sehingga seluruh data uji tidak pernah

TABLE 1. Dataset Partition and Demographic Subgroup Distribution.

Subgroup	Train Set (80%)	Test Set (20%)	Total
Black_Males	1,440	360	1,800
White_Females	1,440	360	1,800
Asian_Males	1,440	360	1,800
White_Males	1,440	360	1,800
Black_Females	1,440	360	1,800
Asian_Females	1,440	360	1,800
Total	8,640	2,160	10,800

terlihat saat tuning hyperparameter maupun fitting PCA dan Scaler. Pada tahapan standarisasi citra, setiap citra wajah dikonversi ke format 3-channel Red, Green, Blue (RGB), diubah resolusinya ke 224×224 piksel, dan diskalakan intensitas pikselnya dari rentang $[0, 255]$ menjadi $[0, 1]$ untuk model transformer.

B. VISION TRANSFORMER

Arsitektur ekstraksi representasi visual penelitian ini mengadopsi ViT-Base sebagaimana diilustrasikan pada Figure 3 [26]. Citra wajah masukan berukuran 224×224 piksel dengan 3 saluran warna dibagi menjadi 196 patch spasial non-overlapping x_p^i berukuran 16×16 piksel [27]. Setiap patch diproyeksikan secara linier melalui matriks E ke ruang laten berdimensi $D = 768$, lalu dirangkaikan dengan token kelas x_{class} dan embedding posisi E_{pos} sesuai (1) [27]. Vektor sekuens token awal z_0 dialirkan ke tumpukan 12 layer transformer encoder identik. Setiap layer encoder ℓ memproses masukan $z_{\ell-1}$ menjadi representasi antara z'_ℓ melalui mekanisme MHSA setelah operasi Layer Normalization (LN) sesuai (2), yang dilanjutkan menuju representasi luaran z_ℓ



FIGURE 2. Sample Images of the DemogPairs Dataset across Six Intersectional Demographic Subgroups: (a) Asian Females, (b) Asian Males, (c) Black Females, (d) Black Males, (e) White Females, and (f) White Males.




FIGURE 3. Architecture of the ViT Backbone and Patch Projection.

melalui blok Multi-Layer Perceptron (MLP) dua lapis beraktivasi GeLU berdasarkan (3) [28]. Mekanisme self-attention memungkinkan pemodelan hubungan global antarpatch wajah tanpa ketergantungan pada receptive field lokal seperti pada operasi konvolusi [29].

$$\mathbf{z}_0 = [\mathbf{x}_{\text{class}}; \mathbf{x}_p^1 \mathbf{E}; \dots; \mathbf{x}_p^{196} \mathbf{E}] + \mathbf{E}_{\text{pos}} \quad (1)$$

$$\mathbf{z}'_\ell = \text{MHSA}(\text{LN}(\mathbf{z}_{\ell-1})) + \mathbf{z}_{\ell-1} \quad (2)$$

$$\mathbf{z}_\ell = \text{MLP}(\text{LN}(\mathbf{z}'_\ell)) + \mathbf{z}'_\ell \quad (3)$$

TABLE 2. Multi-Domain Feature Fusion and Ablation Configurations.

#	Configuration	Domain Category	Dimension
1	Face	Single-Domain	768
2	Emotion	Single-Domain	768
3	Age	Single-Domain	768
4	Emotion $\oplus$ Face	Dual-Domain	1,536
5	Face $\oplus$ Age	Dual-Domain	1,536
6	Emotion $\oplus$ Age	Dual-Domain	1,536
7	Face $\oplus$ Emotion $\oplus$ Age	Tri-Domain (Proposed)	2,304

Untuk mempertahankan efisiensi komputasi dan mencegah variabilitas pelatihan ulang, ketiga model backbone ViT dibekukan (frozen) sebagai penyedia task-associated representations secara offline. Model ViT-Face (skutaada/VIT-VGGFace) menangkap representasi terkait geometri biometrik wajah, ViT-Emotion (dima806/facial_emotions_image_detection) menghasilkan representasi terkait ekspresi wajah, dan ViT-Age (dima806/facial_age_image_detection)

mengekstraksi representasi terkait estimasi usia wajah. Dari setiap model domain, vektor fitur $\mathbf{f}_{\text{domain}} \in \mathbb{R}^{768}$ diekstraksi dari representasi token [CLS] pada layer encoder terakhir L ($\mathbf{z}_L^0$) setelah operasi LN sesuai (4). Ketiga representasi laten domain tunggal tersebut digabungkan menjadi vektor fusi tri-domain $\mathbf{z}_{\text{tri}} \in \mathbb{R}^{2304}$ melalui operasi konkatenasi fitur ($\oplus$) dari vektor $\mathbf{f}_{\text{face}}$, $\mathbf{f}_{\text{emotion}}$, dan $\mathbf{f}_{\text{age}}$ sebagaimana dirumuskan pada (5). Eksplorasi sistematis mencakup tujuh skema ablasi fitur, yang meliputi tiga konfigurasi domain tunggal berdimensi 768, tiga konfigurasi domain ganda berdimensi 1,536, serta satu konfigurasi tri-domain berdimensi 2,304 seperti dirangkum pada Table 2.

$$\mathbf{f}_{\text{domain}} = \text{LN}(\mathbf{z}_L^0) \in \mathbb{R}^{768} \quad (4)$$

$$\mathbf{z}_{\text{tri}} = \mathbf{f}_{\text{face}} \oplus \mathbf{f}_{\text{emotion}} \oplus \mathbf{f}_{\text{age}} \in \mathbb{R}^{2304} \quad (5)$$

C. RANDOM FOREST

Model ensemble RF mengagregasikan prediksi sekumpulan pohon keputusan independen untuk mengklasifikasikan fitur wajah berdasarkan prinsip bootstrap aggregating (bagging) dan random subspace method [30]. Pendekatan ini mereduksi varians prediksi dengan membangun sebanyak B pohon klasifikasi dari sampel acak data latih [31]. Setiap percabangan node membatasi pemilihan fitur pada subset acak berukuran $\text{max_features} \in \{\text{'sqrt'}, \text{'log2'}\}$ untuk menekan korelasi antarpohon [32]. Kriteria pemisahan cabang mengoptimalkan indeks Gini impurity hingga memenuhi ambang batas minimum pemisahan node min_samples_split , batas kedalaman max_depth , atau batas minimum daun min_samples_leaf [33]. Mekanisme majority voting menentukan keputusan akhir sampel citra melintasi seluruh pohon keputusan [34]. Prosedur penalaan hyperparameter mengevaluasi kombinasi penskalaan fitur, reduksi dimensionalitas PCA, variasi jumlah pohon $n_{\text{estimators}}$, serta batasan pertumbuhan pohon, menghasilkan 288 konfigurasi grid dengan 1,440 total fits melalui 5-Fold Stratified Cross-Validation sebagaimana dirangkum pada Table 3.

D. GAUSSIAN NAIVE BAYES

Berdasarkan Teorema Bayes, pengklasifikasi GNB mengestimasi probabilitas posterior kelas demografis interseksional dengan asumsi bahwa seluruh dimensi fitur kontinu bersifat

TABLE 3. Hyperparameter Search Space for Random Forest Classifier.

Component / Hyperparameter	Evaluated Values	Count
Feature Scaler	None, MinMaxScaler	2
Dimensionality Reduction (PCA)	None, 0.50, 0.75	3
Number of Estimators	100, 200	2
Maximum Tree Depth	None, 20, 30	3
Feature Subspace	'sqrt', 'log2'	2
Minimum Samples Split	2, 5	2
Minimum Samples Leaf	1, 2	2
Total Grid Combinations		288 (1,440 fits)

TABLE 4. Hyperparameter Search Space for Gaussian Naive Bayes Classifier.

Component / Hyperparameter	Evaluated Values	Count
Feature Scaler	None, MinMaxScaler	2
Dimensionality Reduction (PCA)	None, 0.50, 0.75	3
Variance Smoothing	logspace($-9, 2, 40$) (1.0×10^{-9} to 1.0×10^2)	40
Total Grid Combinations		240 (1,200 fits)

independen secara bersyarat [35]. Fungsi kerapatan probabilitas distribusi normal memodelkan likelihood fitur kontinu terhadap kelas target sesuai formulasi pada (6), di mana x_i menyatakan nilai fitur kontinu ke- i , y adalah variabel label kelas, c merupakan kategori kelas target, serta $\mu_{c,i}$ dan $\sigma_{c,i}^2$ masing-masing merepresentasikan rata-rata (mean) dan varians fitur ke- i pada kelas c [35]:

$$P(x_i | y = c) = \frac{1}{\sqrt{2\pi\sigma_{c,i}^2}} \exp\left(-\frac{(x_i - \mu_{c,i})^2}{2\sigma_{c,i}^2}\right) \quad (6)$$

Penambahan parameter penghalusan var_smoothing menjaga stabilitas komputasi terhadap risiko varians mendekati nol pada ruang representasi laten berdimensi tinggi [36]. Prosedur penalaan hyperparameter melalui 5-Fold Stratified Cross-Validation mengevaluasi kombinasi penskalaan data, reduksi dimensionalitas PCA, serta 40 interval var_smoothing yang dieksplorasi secara logaritmik dari 1.0×10^{-9} hingga 1.0×10^2 , menghasilkan 240 kombinasi grid dengan total 1,200 proses fitting sebagaimana dipaparkan pada Table 4.

E. LOGISTIC REGRESSION

Pendekatan regresi multinomial (Softmax regression) pada LR memetakan representasi fitur laten ke dalam enam kategori demografis interseksional melalui estimasi probabilitas linier terpadu [37]. Fungsi probabilitas Softmax menghitung peluang bersyarat sampel terhadap kategori target sebagaimana didefinisikan pada (7), di mana $\mathbf{x}$ merepresentasikan vektor fitur masukan, y adalah variabel label kelas, c menyatakan kategori kelas target, $\mathbf{w}_c$ dan b_c masing-masing merupakan vektor bobot serta bias kelas c , sedangkan konstanta $K = 6$ menunjukkan jumlah total kelas interseksional [38]:

$$P(y = c | \mathbf{x}) = \frac{e^{\mathbf{w}_c^T \mathbf{x} + b_c}}{\sum_{j=1}^K e^{\mathbf{w}_j^T \mathbf{x} + b_j}} \quad (7)$$

Proses pembelajaran model meminimalkan fungsi kerugian cross-entropy dengan menyertakan penalti regularisasi L_2 untuk mengendalikan kompleksitas bobot pada ruang representasi berdimensi tinggi [39]. Pencarian hyperparameter terstruktur mengevaluasi variasi kekuatan regularisasi C , algoritma solver optimasi (lbfgs, saga, newton-cg), batas iterasi max_iter, serta integrasi penskalaan dan PCA, menghasilkan 270 kombinasi evaluasi atau 1,350 total fits pada protokol 5-Fold Stratified Cross-Validation yang disajikan pada Table 5.

F. SUPPORT VECTOR MACHINE

Pengklasifikasi SVM mengonstruksikan bidang pemisah berjarak terjauh (maximum margin hyperplane) untuk memisahkan enam kelas interseksional pada ruang representasi laten berdimensi tinggi [40]. Fungsi kernel memproyeksikan distribusi data nonlinier dari fusi multi-domain ke ruang fitur berdimensi lebih tinggi, mencakup opsi kernel linear, Radial Basis Function (RBF), dan polinomial [41]. Formulasi kernel polinomial derajat dua pada (8) menghitung produk titik $\langle \mathbf{x}_i, \mathbf{x}_j \rangle$ antara pasangan vektor fitur $\mathbf{x}_i$ dan $\mathbf{x}_j$, di mana γ menyatakan parameter penskalaan kernel, $d = 2$ menentukan derajat pemetaan, dan konstanta intercept coef0 = 0.0 mengikuti nilai bawaan scikit-learn [42]:

$$K(\mathbf{x}_i, \mathbf{x}_j) = (\gamma \langle \mathbf{x}_i, \mathbf{x}_j \rangle + \text{coef0})^d, \quad d = 2 \quad (8)$$

Pemetaan kuadratik ini memfasilitasi penangkapan interaksi nonlinier antardimensi visual secara efisien [43].

Optimasi hyperparameter menelusuri rentang parameter penalti $C \in \{0.01, 0.1, 1, 10\}$, ragam fungsi kernel, koefisien γ , derajat polinomial, serta opsi penskalaan dan PCA, menghasilkan 288 kombinasi konfigurasi atau 1,440 total fits pada prosedur 5-Fold Stratified Cross-Validation sesuai Table 6.

G. CLASSIFICATION PIPELINE

Kerangka kerja pipeline modular menyatukan penskalaan fitur, reduksi dimensi representasi, dan estimasi model hilir

TABLE 5. Hyperparameter Search Space for Logistic Regression Classifier.

Component / Hyperparameter	Evaluated Values	Count
Feature Scaler	None, MinMaxScaler	2
Dimensionality Reduction (PCA)	None, 0.50, 0.75	3
Regularization Strength	0.01, 0.1, 1, 10, 100	5
Optimization Solver	'lbfgs', 'saga', 'newton-cg'	3
Maximum Iterations	500, 1000, 2000	3
Total Grid Combinations		270 (1,350 fits)

TABLE 6. Hyperparameter Search Space for Support Vector Machine.

Component / Hyperparameter	Evaluated Values	Count
Feature Scaler	None, MinMaxScaler	2
Dimensionality Reduction (PCA)	None, 0.50, 0.75	3
Regularization Parameter	0.01, 0.1, 1, 10	4
Kernel Function	'linear', 'rbf', 'poly'	3
Polynomial Degree	2, 3	2
Kernel Coefficient	'scale', 'auto'	2
Total Grid Combinations		288 (1,440 fits)

ke dalam rantai transformasi terpadu. Rantai pemrosesan tersebut dirumuskan pada (9), di mana vektor fitur input $\mathbf{x}$ ditransformasikan oleh modul penskalaan menjadi $\tilde{\mathbf{x}}$, direduksi dimensinya melalui PCA menjadi $\hat{\mathbf{x}}$, dan dipetakan oleh pengklasifikasi menuju prediksi label $\hat{y} \in \{0, 1, 2, 3, 4, 5\}$ untuk enam subkelompok demografis:

$$\mathbf{x} \xrightarrow{\text{Scaler}} \tilde{\mathbf{x}} \xrightarrow{\text{PCA}} \hat{\mathbf{x}} \xrightarrow{\text{Classifier}} \hat{y} \in \{0, 1, 2, 3, 4, 5\} \quad (9)$$

Protokol validasi silang menerapkan skema 5-Fold Stratified Cross-Validation dengan pengacakan terkontrol untuk mempertahankan proporsi seimbang $\sim 16.67\%$ per kelas di setiap fold. Untuk mencegah kebocoran informasi, Scaler dan PCA di-fit secara eksklusif hanya pada data latih di dalam GridSearchCV sebelum diterapkan ke data validasi. Penelusuran terhadap 1,086 kombinasi hyperparameter menghasilkan 5,430 fits per skema fitur atau 38,010 total fits untuk tujuh konfigurasi representasi, serta 28 refit final sebelum pengujian pada data uji held-out independen.

H. EVALUATION METRICS

Evaluasi performa klasifikasi multi-kelas enam subkelompok demografis pada tingkat subkelompok dilakukan melalui skema biner One-vs-Rest (OvR) [44]. Skema ini memanfaatkan empat komponen matriks konfusi per kelas untuk menghitung Akurasi OvR, Presisi, Recall, dan F1-Score pada setiap kelas $c \in \{1, \dots, K\}$ [45]. Keempat komponen tersebut mencakup TP_c (True Positive), TN_c (True Negative), FP_c (False Positive), dan FN_c (False Negative) [46]. Akurasi OvR pada (10) mengukur rasio total prediksi benar terhadap seluruh data uji, sedangkan Presisi pada (11) dan Recall pada (12) memetakan ketepatan positif serta sensitivitas deteksi sistem per subkelompok [47]. F1-Score pada (13) dirumuskan sebagai rata-rata harmonik antara Presisi dan Recall untuk

merepresentasikan keseimbangan evaluasi performa deteksi per subkelompok [47].

$$\text{Accuracy}_c = \frac{TP_c + TN_c}{TP_c + TN_c + FP_c + FN_c} \quad (10)$$

$$\text{Precision}_c = \frac{TP_c}{TP_c + FP_c} \quad (11)$$

$$\text{Recall}_c = \frac{TP_c}{TP_c + FN_c} \quad (12)$$

$$\text{F1-Score}_c = \frac{2 \cdot \text{Precision}_c \cdot \text{Recall}_c}{\text{Precision}_c + \text{Recall}_c} \quad (13)$$

Untuk mengevaluasi efektivitas sistem klasifikasi secara menyeluruh pada data uji independen, metrik performa per subkelompok diagregasikan menjadi metrik evaluasi global. Pada formulasi ini, simbol N menyatakan total sampel data uji ($N = 2,160$), sedangkan K menyatakan jumlah total subkelompok demografis ($K = 6$). Akurasi Global (Overall Accuracy) pada (14) dihitung sebagai rasio total prediksi benar, yaitu penjumlahan elemen diagonal utama matriks konfusi $\sum_{c=1}^K TP_c$, terhadap total sampel data uji N .

$$\text{Accuracy}_{\text{Global}} = \frac{\sum_{c=1}^K TP_c}{N} \quad (14)$$

Selanjutnya, Presisi global (Macro Precision) pada (15), Recall global (Macro Recall) pada (16), dan F1-Score global (Macro F1-Score) pada (17) dihitung melalui perataan makro tanpa bobot (unweighted macro average) melintasi $K = 6$ subkelompok untuk memberikan bobot evaluasi yang setara pada setiap kelas demografis.

$$\text{Precision}_{\text{Global}} = \frac{1}{K} \sum_{c=1}^K \text{Precision}_c \quad (15)$$

$$\text{Recall}_{\text{Global}} = \frac{1}{K} \sum_{c=1}^K \text{Recall}_c \quad (16)$$

$$F1\text{-Score}_{\text{Global}} = \frac{1}{K} \sum_{c=1}^K F1\text{-Score}_c \quad (17)$$

IV. RESULTS AND DISCUSSION

A. GLOBAL PERFORMANCE ANALYSIS

Evaluasi performa RF melintasi tujuh konfigurasi fitur pada data uji DemogPairs disajikan pada Table 7. Hasil eksperimen empiris menunjukkan bahwa skema dual-domain Emotion $\oplus$ Face mencapai capaian tertinggi dengan Akurasi 86.85% dan F1-Score 86.82%. Sebaliknya, penggabungan tri-domain Face $\oplus$ Emotion $\oplus$ Age mengalami sedikit penurunan performa menjadi Akurasi 86.20% dan F1-Score 86.13%. Penurunan ini diinterpretasikan sebagai kemungkinan tantangan partisi ruang fitur berdimensi 2,304 melalui pemotongan pohon acak (random splits) [48]. Seluruh konfigurasi Grid-SearchCV secara konsisten memilih reduksi dimensionalitas PCA 0.75 untuk menyeimbangkan varians data. Pada kategori domain tunggal, fitur Face mencatatkan performa terbaik dengan Akurasi 85.46%, melampaui fitur domain Emotion sebesar 80.60% serta domain Age sebesar 73.66%.

Evaluasi performa klasifikasi probabilistik GNB pada tujuh variasi konfigurasi fitur dirangkum pada Table 8. Meskipun model ini mengasumsikan independensi kondisional antarfitur, GNB menunjukkan tren peningkatan performa yang konsisten dari kategori domain tunggal ke multi-domain. Pada domain tunggal, konfigurasi Age menghasilkan capaian terendah dengan Akurasi 69.63% dan F1-Score 69.52%, sedangkan fitur Face mencapai Akurasi 82.69%. Integrasi representasi pada kategori dual-domain meningkatkan akurasi secara bertahap, dipimpin oleh kombinasi Emotion $\oplus$ Face sebesar 84.86%. Puncak performa klasifikasi GNB tercapai pada konfigurasi tri-domain Face $\oplus$ Emotion $\oplus$ Age dengan Akurasi 85.05% dan F1-Score 85.05%. Seluruh konfigurasi fitur GNB secara seragam memilih reduksi dimensionalitas PCA 0.75 berdasarkan hasil penalaan Grid-SearchCV.

Hasil benchmark performa multinomial LR pada seluruh konfigurasi fitur dipaparkan pada Table 9. Karakteristik utama dari model LR adalah retensi representasi fitur penuh, di mana seluruh skema (tujuh dari tujuh konfigurasi) memilih tanpa reduksi PCA (pca=None) [49]. Evaluasi empiris menunjukkan bahwa konfigurasi tri-domain Face $\oplus$ Emotion $\oplus$ Age mencatatkan performa tertinggi dengan Akurasi 92.73% dan F1-Score 92.73% melalui parameter penalti $C = 0.1$ serta solver newton-cg. Capaian tri-domain ini melampaui konfigurasi dual-domain terbaik Emotion $\oplus$ Face yang meraih Akurasi 92.41% dan F1-Score 92.40%, serta mengungguli konfigurasi single-domain terbaik Face dengan Akurasi 90.60%. Temuan ini mengindikasikan efektivitas regularisasi L_2 dalam menangani ruang fitur berdimensi tinggi tanpa kompresi komponen utama [50].

Perkembangan performa SVM melintasi seluruh tahapan ablasi fitur dirangkum pada Table 10. Serupa dengan model linier, seluruh konfigurasi SVM secara konsisten mempertahankan ruang representasi penuh tanpa reduksi PCA (pca=None). Evaluasi empiris memperlihatkan

peningkatan performa berjenjang, dimulai dari konfigurasi domain tunggal terbaik Face dengan Akurasi 90.83% dan F1-Score 90.83%. Integrasi representasi pada skema dual-domain Emotion $\oplus$ Face meningkatkan performa dengan Akurasi 93.29% dan F1-Score 93.29%, sebelum akhirnya mencapai titik tertinggi pada konfigurasi tri-domain Face $\oplus$ Emotion $\oplus$ Age dengan Akurasi 93.70% dan F1-Score 93.69%. Pada hyperparameter, parameter degree bernilai 2 hanya aktif pada fungsi kernel poly, sedangkan model berbasis kernel RBF tidak mengaktifkan parameter tersebut [51].

Sintesis dari 28 eksperimen pada Table 7, Table 8, Table 9, dan Table 10 menetapkan SVM tri-domain Face $\oplus$ Emotion $\oplus$ Age sebagai model terbaik dengan Akurasi 93.70% dan F1-Score 93.69%. Rata-rata akurasi melintasi seluruh konfigurasi mencatat keunggulan SVM (91.47%), diikuti LR (90.40%), RF (82.81%), dan GNB (79.37%). Hasil Uji McNemar berpasangan antara Tri-Domain vs Dual-Domain pada SVM mencatat selisih +9 citra (+0.41%, $\chi^2 = 1.0492$, $p = 0.3057$, $p > 0.05$), serta pada RF diperoleh selisih -14 citra (-0.65%, $\chi^2 = 1.4825$, $p = 0.2232$, $p > 0.05$). Ketidadaan signifikansi statistik tersebut mengindikasikan fenomena asymptotic feature saturation (kejenuhan representasi fitur), di mana fusi Dual-Domain Emotion $\oplus$ Face telah menyerap mayoritas varians diskriminatif utama.

B. FEATURE ABLATION STUDY

Kuantifikasi perubahan performa klasifikasi dari skema domain tunggal menuju konfigurasi ganda dan tri-domain dirangkum pada Table 7, Table 8, Table 9, dan Table 10. Pada model SVM, transisi representasi dari domain tunggal Face (90.83%) ke dual-domain Emotion $\oplus$ Face (93.29%) meningkatkan akurasi sebesar 2.46%. Penambahan domain ketiga pada konfigurasi tri-domain Face $\oplus$ Emotion $\oplus$ Age meningkatkan akurasi menjadi 93.70% (kumulatif +2.87%), dengan rentang 95% CI [92.60%, 94.65%] yang tumpang-tindih terhadap dual-domain [92.15%, 94.27%]. Konsistensi skor CV (92.65% $\pm$ 0.93%) terhadap data uji mengonfirmasi stabilitas batas keputusan model bebas overfitting. Pola peningkatan bertahap ini membuktikan bahwa penggabungan representasi visual komplementer memperkuat pemisahan antarkelas demografis secara andal.

Analisis kontribusi domain usia (Age) mengkaji peranan informasi penuaan dalam sistem klasifikasi demografis. Pada seluruh pengklasifikasi, fitur Age menghasilkan akurasi terendah sebagai domain tunggal, seperti tercatat sebesar 87.64% pada SVM dan 69.63% pada GNB. Penurunan performa pada Random Forest (-0.65% dari dual-domain ke tri-domain) terjadi karena penambahan dimensi fitur membuat pohon keputusan acak lebih rentan memilih fitur usia yang kurang informatif pada setiap percabangannya. Sebaliknya, model SVM dengan kernel polinomial mampu mengevaluasi kombinasi interaksi antardimensi fitur secara simultan. Temuan ini membantah anggapan bahwa penambahan fitur pasti meningkatkan akurasi, melainkan bergantung pada karakteristik masing-masing pengklasifikasi dalam memproses ruang fitur, sekaligus membuktikan bahwa repre-

TABLE 7. Performance Benchmark of Random Forest across Seven Feature Configurations.

Configuration	Accuracy	95% CI	CV Score	Precision	Recall	F1-Score	Best Parameters
Face	85.46%	[83.91%, 86.89%]	87.07% $\pm$ 0.68%	85.43%	85.46%	85.39%	n_est=200, depth=30, max_feat=log2, min_split=2, min_leaf=1, pca=PCA(0.75), scaler=MinMaxScaler
Emotion	80.60%	[78.88%, 82.21%]	79.65% $\pm$ 1.01%	80.63%	80.60%	80.57%	n_est=200, depth=None, max_feat=log2, min_split=5, min_leaf=1, pca=PCA(0.75), scaler=None
Age	73.66%	[71.76%, 75.47%]	72.93% $\pm$ 0.85%	73.63%	73.66%	73.54%	n_est=200, depth=30, max_feat=log2, min_split=2, min_leaf=1, pca=PCA(0.75), scaler=None
Emotion $\oplus$ Face	86.85%	[85.36%, 88.21%]	87.72% $\pm$ 0.69%	86.89%	86.85%	86.82%	n_est=200, depth=None, max_feat=sqrt, min_split=5, min_leaf=1, pca=PCA(0.75), scaler=None
Face $\oplus$ Age	85.79%	[84.25%, 87.20%]	87.20% $\pm$ 0.84%	85.78%	85.79%	85.73%	n_est=200, depth=None, max_feat=sqrt, min_split=2, min_leaf=1, pca=PCA(0.75), scaler=None
Emotion $\oplus$ Age	81.11%	[79.41%, 82.71%]	80.07% $\pm$ 0.87%	81.11%	81.11%	81.08%	n_est=200, depth=None, max_feat=log2, min_split=5, min_leaf=2, pca=PCA(0.75), scaler=None
Face $\oplus$ Emotion $\oplus$ Age	86.20%	[84.68%, 87.59%]	87.48% $\pm$ 0.86%	86.20%	86.20%	86.13%	n_est=200, depth=30, max_feat=sqrt, min_split=5, min_leaf=1, pca=PCA(0.75), scaler=None

TABLE 8. Performance Benchmark of Gaussian Naive Bayes across Seven Feature Configurations.

Configuration	Accuracy	95% CI	CV Score	Precision	Recall	F1-Score	Best Parameters
Face	82.69%	[81.03%, 84.22%]	84.04% $\pm$ 0.74%	82.71%	82.69%	82.58%	var_smoothing=4.1246e-02, pca=PCA(0.75), scaler=MinMaxScaler
Emotion	73.38%	[71.48%, 75.20%]	73.11% $\pm$ 1.09%	73.87%	73.38%	73.29%	var_smoothing=3.0703e-03, pca=PCA(0.75), scaler=None
Age	69.63%	[67.66%, 71.53%]	69.19% $\pm$ 0.75%	69.79%	69.63%	69.52%	var_smoothing=4.3755e-04, pca=PCA(0.75), scaler=MinMaxScaler
Emotion $\oplus$ Face	84.86%	[83.29%, 86.31%]	85.65% $\pm$ 0.73%	84.90%	84.86%	84.81%	var_smoothing=5.8780e-03, pca=PCA(0.75), scaler=MinMaxScaler
Face $\oplus$ Age	83.15%	[81.51%, 84.67%]	84.34% $\pm$ 0.72%	83.43%	83.15%	83.17%	var_smoothing=1.1253e-02, pca=PCA(0.75), scaler=MinMaxScaler
Emotion $\oplus$ Age	76.81%	[74.98%, 78.54%]	75.54% $\pm$ 1.13%	76.86%	76.81%	76.81%	var_smoothing=1.6037e-03, pca=PCA(0.75), scaler=MinMaxScaler
Face $\oplus$ Emotion $\oplus$ Age	85.05%	[83.48%, 86.49%]	85.53% $\pm$ 0.57%	85.12%	85.05%	85.05%	var_smoothing=5.8780e-03, pca=PCA(0.75), scaler=None

TABLE 9. Performance Benchmark of Logistic Regression across Seven Feature Configurations.

Configuration	Accuracy	95% CI	CV Score	Precision	Recall	F1-Score	Best Parameters
Face	90.60%	[89.30%, 91.76%]	90.52% $\pm$ 0.59%	90.60%	90.60%	90.59%	C = 1, solver=newton-cg, max_iter=500, pca=None, scaler=MinMaxScaler
Emotion	88.47%	[87.06%, 89.75%]	87.18% $\pm$ 0.76%	88.50%	88.47%	88.46%	C = 1, solver=saga, max_iter=500, pca=None, scaler=MinMaxScaler
Age	86.48%	[84.97%, 87.86%]	84.91% $\pm$ 0.58%	86.49%	86.48%	86.48%	C = 0.1, solver=lbfgs, max_iter=500, pca=None, scaler=None
Emotion $\oplus$ Face	92.41%	[91.21%, 93.45%]	91.89% $\pm$ 0.54%	92.41%	92.41%	92.40%	C = 0.1, solver=lbfgs, max_iter=500, pca=None, scaler=None
Face $\oplus$ Age	91.62%	[90.38%, 92.72%]	91.53% $\pm$ 0.47%	91.62%	91.62%	91.62%	C = 0.1, solver=newton-cg, max_iter=500, pca=None, scaler=None
Emotion $\oplus$ Age	90.51%	[89.20%, 91.67%]	89.26% $\pm$ 0.69%	90.52%	90.51%	90.51%	C = 0.1, solver=lbfgs, max_iter=500, pca=None, scaler=None
Face $\oplus$ Emotion $\oplus$ Age	92.73%	[91.56%, 93.75%]	92.19% $\pm$ 0.45%	92.75%	92.73%	92.73%	C = 0.1, solver=newton-cg, max_iter=500, pca=None, scaler=None

TABLE 10. Performance Benchmark of Support Vector Machine across Seven Feature Configurations.

Configuration	Accuracy	95% CI	CV Score	Precision	Recall	F1-Score	Best Parameters
Face	90.83%	[89.54%, 91.98%]	91.41% $\pm$ 0.85%	90.84%	90.83%	90.83%	$C = 10$, rbf, γ =scale, pca=None, scaler=None
Emotion	90.19%	[88.86%, 91.37%]	88.38% $\pm$ 0.54%	90.20%	90.19%	90.17%	$C = 10$, rbf, γ =scale, pca=None, scaler=None
Age	87.64%	[86.18%, 88.96%]	86.78% $\pm$ 0.70%	87.67%	87.64%	87.65%	$C = 10$, rbf, γ =scale, pca=None, scaler=None
Emotion $\oplus$ Face	93.29%	[92.15%, 94.27%]	92.31% $\pm$ 0.80%	93.33%	93.29%	93.29%	$C = 10$, rbf, γ =scale, pca=None, scaler=MinMaxScaler
Face $\oplus$ Age	92.55%	[91.36%, 93.58%]	92.30% $\pm$ 0.57%	92.54%	92.55%	92.54%	$C = 10$, poly, γ =scale, deg=2, pca=None, scaler=None
Emotion $\oplus$ Age	92.08%	[90.87%, 93.15%]	90.17% $\pm$ 0.65%	92.10%	92.08%	92.09%	$C = 10$, rbf, γ =scale, pca=None, scaler=None
Face $\oplus$ Emotion $\oplus$ Age	93.70%	[92.60%, 94.65%]	92.65% $\pm$ 0.93%	93.72%	93.70%	93.69%	$C = 10$, poly, γ =scale, deg=2, pca=None, scaler=None

sentasi fitur telah mencapai titik kejenuhan.

C. INTERSECTIONAL SUBGROUP PERFORMANCE

Profil kinerja klasifikasi granular pada model terbaik SVM tri-domain Face $\oplus$ Emotion $\oplus$ Age dievaluasi berdasarkan metrik pada Table 11. Seluruh subkelompok mencapai F1-Score melampaui 91.00%, dari 91.74% pada Black Females hingga 96.14% pada White Males. Namun demikian, analisis keadilan formal mencatat kesenjangan Equal Opportunity Difference ($\Delta\text{TPR} = 7.50\%$) akibat disparitas recall antara White Males (96.94%) dan Black Females (89.44% dengan FNR 10.56%). Meskipun presisi Black Females tetap tinggi sebesar 94.15%, sensitivitas deteksi yang lebih rendah merefleksikan tantangan representasi fenotipik interseksional yang belum terhapus sepenuhnya. Pelaporan metrik False Negative Rate ini menyeimbangkan evaluasi Akurasi OvR (97.31% hingga 98.70%) yang rentan terdistorsi oleh dominansi rasio sampel negatif 5:1.

Perbandingan profil kinerja subkelompok antara model SVM dan pengklasifikasi linier LR pada konfigurasi tri-domain disajikan pada Table 11. Model LR tri-domain memperlihatkan konsistensi performa tinggi dengan F1-Score melampaui 91.00% pada seluruh kelas demografis, merentang dari 91.36% pada Asian Females hingga 95.58% pada White Males. Evaluasi keadilan formal pada model LR menunjukkan kesenjangan Equal Opportunity Difference yang lebih rapat ($\Delta\text{TPR} = 5.00\%$), dengan recall White Males sebesar 96.11% berbanding 91.11% pada Asian Females dan Black Females (FNR 8.89%). Subkelompok White Males secara konsisten mencatatkan performa klasifikasi tertinggi pada kedua pengklasifikasi. Temuan empiris ini membuktikan bahwa fusi representasi tri-domain menghasilkan representasi visual yang stabil melintasi seluruh subkelompok demografis pada model linier maupun non-linier.

D. ERROR PATTERN ASSESSMENT

Pergeseran distribusi kesalahan klasifikasi dari skema domain tunggal menuju konfigurasi ganda dan tiga domain dianalisis melalui diagram matriks konfusi pada Figure 4, yang mencakup Figure 4(a), Figure 4(b), dan Figure 4(c). Evaluasi


empiris menunjukkan bahwa total misklasifikasi pada 2,160 data uji held-out menurun secara konsisten seiring perluasan domain representasi visual. Model SVM domain tunggal Face menghasilkan 198 kesalahan prediksi, yang kemudian berkurang menjadi 145 sampel pada skema dual-domain Emotion $\oplus$ Face. Konfigurasi tri-domain Face $\oplus$ Emotion $\oplus$ Age menekan kesalahan klasifikasi hingga mencapai titik terendah sebesar 136 sampel. Penurunan kesalahan yang konsisten ini mengindikasikan bahwa fusi representasi multi-domain mempertegas batas pemisahan antar-subkelompok demografis di ruang fitur visual.

Pemeriksaan mendalam terhadap matriks konfusi model domain tunggal Face pada Figure 4(a) mengungkap bahwa kesalahan klasifikasi terkonsentrasi secara dominan pada subkelompok antarras dalam gender yang sama. Kecenderungan tersebut terlihat sangat menonjol pada kohort wanita, di mana subkelompok Asian Females mengalami 46 misklasifikasi, yang mencakup 16 sampel terprediksi sebagai White Females dan 16 sampel sebagai Black Females. Sebaliknya, subkelompok White Females mencatatkan 20 kesalahan prediksi yang terdistribusi ke Asian Females. Pola empiris ini konsisten dengan kemungkinan adanya tumpang tindih fenotipe (phenotypic overlap) antarras pada representasi geometri biometrik wajah tunggal [18]. Meskipun demikian, bukti matriks konfusi tersebut tidak membuktikan bahwa faktor tumpang tindih visual merupakan penyebab tunggal dari seluruh misklasifikasi yang teramati.

Perubahan distribusi kesalahan klasifikasi pada model dual-domain Emotion $\oplus$ Face dianalisis lebih lanjut berdasarkan matriks konfusi pada Figure 4(b). Penambahan representasi ekspresi afektif secara efektif mereduksi pola misklasifikasi antarras pada subkelompok bergender sama, terutama pada kelompok wanita. Kesalahan prediksi dari Asian Females ke White Females berhasil ditekan secara nyata dari 16 kasus menjadi 9 kasus. Pada saat yang bersamaan, jumlah sampel prediksi benar (true positive) pada subkelompok White Females meningkat dari 325 citra menjadi 334 citra. Integrasi sinyal dinamis ekspresi wajah tersebut memperkuat batas pembeda visual antarras dalam ruang representasi terpadu, sehingga pengklasifikasi mampu

TABLE 11. Subgroup-Level Performance for Tri-Domain Models.

Classifier	Subgroup	Recall (TPR)	Precision	F1-Score	OvR Accuracy	FNR
SVM (Tri)	White_Males	96.94%	95.36%	96.14%	98.70%	3.06%
	Black_Males	94.17%	95.49%	94.83%	98.29%	5.83%
	White_Females	94.72%	92.41%	93.55%	97.82%	5.28%
	Asian_Males	94.44%	92.39%	93.41%	97.78%	5.56%
	Asian_Females	92.50%	92.50%	92.50%	97.50%	7.50%
	Black_Females	89.44%	94.15%	91.74%	97.31%	10.56%
LR (Tri)	White_Males	96.11%	95.05%	95.58%	98.52%	3.89%
	Black_Males	93.06%	95.71%	94.37%	98.15%	6.94%
	Asian_Males	92.78%	90.76%	91.76%	97.22%	7.22%
	White_Females	92.22%	91.21%	91.71%	97.22%	7.78%
	Black_Females	91.11%	92.13%	91.62%	97.22%	8.89%
	Asian_Females	91.11%	91.62%	91.36%	97.13%	8.89%

**FIGURE 4.** Confusion Matrices across Feature Fusion Schemes on the Held-Out Test Set: (a) Single-Domain (Face), (b) Dual-Domain (Emotion $\oplus$ Face), and (c) Tri-Domain (Face $\oplus$ Emotion $\oplus$ Age).

membedakan fitur morfologi yang serupa dengan tingkat kepastian yang lebih kokoh dan stabil.

Pola misklasifikasi pada konfigurasi tri-domain Face $\oplus$ Emotion $\oplus$ Age dievaluasi secara komprehensif berdasarkan matriks konfusi pada Figure 4(c). Integrasi representasi domain usia meningkatkan jumlah prediksi benar secara konsisten pada subkelompok Asian Females menjadi 333 sampel dan White Females menjadi 341 sampel. Selain itu, kesalahan klasifikasi lintas-gender, yaitu kondisi ketika subjek wanita tertukar menjadi pria atau sebaliknya, hanya berjumlah 51 kasus dari total 2,160 data uji held-out (2.36%). Temuan empiris ini mengindikasikan bahwa batas antargender terpisah dengan sangat tegas di dalam ruang representasi multi-domain, sehingga kesalahan klasifikasi yang tersisa pada model tri-domain hampir seluruhnya didominasi oleh misklasifikasi antarras di dalam kelompok gender yang sama.

E. COMPARISON WITH PRIOR STUDIES

Perbandingan empiris secara langsung antara kerangka kerja usulan dan studi terdahulu pada dataset DemogPairs dirangkum pada Table 12. Model usulan berbasis Tri-Domain ViT + SVM (Face $\oplus$ Emotion $\oplus$ Age) meraih Akurasi 93.70%, Presisi 93.72%, Recall 93.70%, dan F1-Score 93.69%. Capaian kuantitatif tersebut melampaui performa yang dilaporkan pada model Dual-ViT + SVM dengan

TABLE 12. Comparative Performance of Proposed Framework against Prior Studies on the DemogPairs Dataset.

Model	Accuracy	Precision	Recall	F1-Score
MD-ViT [20]	89.07%	89.12%	89.07%	89.01%
Dual-ViT [19]	92.41%	92.48%	92.41%	92.38%
Ours	93.70%	93.72%	93.70%	93.69%

Akurasi 92.41% dan F1-Score 92.38% [19], serta model MD-ViT + XGBoost dengan Akurasi 89.07% dan F1-Score 89.01% [20]. Komparasi ini memposisikan kontribusi saintifik naskah ini sebagai evaluasi sistematis tri-domain terpadu dengan pengujian signifikansi serta batas keputusan yang melampaui studi prosiding konferensi terdahulu [19]. Seluruh angka pembandingan disitasi langsung dari publikasi masing-masing sebagai penempatan kontekstual pada dataset acuan yang sama.

Penelitian seminal perancangan dataset DemogPairs oleh Hupont dan Fernández [25] dirancang secara eksklusif sebagai benchmark verifikasi identitas (identity verification ROC pada 58.3 juta pasangan citra) dan tidak melakukan pelatihan klasifikasi 6-kelas (closed-set intersectional classification). Oleh karena itu, penelitian ini bersama studi terkait terdahulu [19], [20] memelopori dan menyediakan baseline

terkontrol internal pertama yang komprehensif untuk klasifikasi demografis interseksional 6-kelas pada dataset DemogPairs. Selain mengevaluasi metrik agregat global, penyelidikan ini menjalankan analisis disparitas subkelompok secara mendalam pada konfigurasi tri-domain terbaik untuk memetakan variasi performa antarsubkelompok demografis secara transparan. Evaluasi mendalam tersebut membuktikan stabilitas klasifikasi lintas kategori ras dan gender interseksional, di mana informasi variasi performa subkelompok tidak dilaporkan dalam literatur pembandingan sebelumnya [19], [20].

V. CONCLUSION

Penelitian ini mengevaluasi kerangka kerja fusi representasi Tri-Domain ViT (Face $\oplus$ Emotion $\oplus$ Age: 2,304 dimensi) untuk klasifikasi ras dan gender interseksional pada dataset DemogPairs. Hasil eksperimen menunjukkan bahwa fusi tri-domain menjadi konfigurasi terbaik pada 3 dari 4 classifier yang dievaluasi, mencakup SVM, LR, dan GNB. Dalam search space yang dievaluasi, model SVM teroptimasi dengan hyperparameter $C = 10$ dan kernel polinomial derajat dua menghasilkan performa klasifikasi tertinggi, yakni Akurasi 93.70% serta F1-Score 93.69%. Meskipun demikian, manfaat integrasi representasi multi-domain terbukti bersifat classifier-dependent karena RF justru meraih performa puncak pada skema dual-domain Emotion $\oplus$ Face dengan akurasi 86.85%. Di samping itu, evaluasi kinerja subkelompok mengonfirmasi bahwa nilai F1-Score pada keenam subkelompok demografis terdistribusi stabil pada rentang 91.74% hingga 96.14%.

Terlepas dari capaian tersebut, penelitian ini memiliki sejumlah keterbatasan yang membuka peluang riset lanjutan. Pertama, skema partisi dataset yang diterapkan merupakan batasan yang disengaja (deliberate limitation), di mana protokol benchmark in-distribution berfokus pada evaluasi representasi terisolasi pada tingkat citra. Kedua, cakupan demografis penyelidikan ini terbatas pada tiga kelompok ras makro (Asian, Black, dan White) pada dataset DemogPairs, sehingga temuan empiris belum mencakup populasi multirasial maupun kelompok etnisitas lain secara komprehensif. Ketiga, ekstraksi representasi fitur dijalankan secara terpisah (offline) memanfaatkan backbone ViT pra-latih yang dibekukan tanpa fine-tuning end-to-end secara simultan. Keempat, evaluasi eksperimental masih berfokus pada citra lingkungan laboratorium terkontrol, sehingga ketahanan model terhadap variasi pose ekstrem, oklusi, dan pencahayaan in-the-wild memerlukan pengujian lebih lanjut. Berdasarkan keterbatasan tersebut, arah riset masa depan disarankan untuk memformulasikan pengujian generalisasi lintas identitas (cross-identity generalization) melalui partisi strictly subject-disjoint yang memastikan subjek yang sama tidak muncul pada set latih dan uji secara bersamaan. Selain itu, penelitian mendatang perlu mengeksplorasi mekanisme fusi atensi adaptif lintas-modal (cross-attention transformer fusion) yang dilatih secara end-to-end, memperluas evaluasi pada dataset berskala besar yang heterogen seperti FairFace

atau UTKFace, serta mengintegrasikan metode visual explainability seperti Attention Rollout atau Grad-CAM demi mendukung prinsip akuntabilitas kecerdasan buatan dengan pengawasan manusia (human-in-the-loop).

DATA AVAILABILITY STATEMENT

Dataset DemogPairs yang dianalisis dalam penelitian ini merupakan dataset sekunder yang tersedia secara publik untuk keperluan riset akademis. Citra wajah beserta anotasi label demografis dapat diakses secara bebas melalui publikasi resmi pengembang pada <https://ihupont.github.io/publications/2019-05-16-demogpairs> dan direktori penyimpanan Google Drive resmi pada https://drive.google.com/file/d/1f_ez-ll6wxDXScrG4ceStZRuLT_K8Uy8/view?usp=sharing.

REFERENCES

- [1] M. K. Rusia and D. K. Singh, "A comprehensive survey on techniques to handle face identity threats: challenges and opportunities," *Multimedia Tools and Applications*, vol. 82, no. 2, pp. 1669–1748, Jan. 2023.
- [2] B. Meden, P. Rot, P. Terhörst, N. Damer, A. Kuijper, W. J. Scheirer, A. Ross, P. Peer, and V. Štruc, "Privacy-enhancing face biometrics: a comprehensive survey," *IEEE Transactions on Information Forensics and Security*, vol. 16, pp. 4147–4183, 2021.
- [3] A. Birhane, "The unseen Black faces of AI algorithms," *Nature*, vol. 610, no. 7932, pp. 451–452, Oct. 2022.
- [4] H. Overbye-Thompson, K. A. Hamilton, and D. Mastro, "Reinvention mediates impacts of skin tone bias in algorithms: implications for technology diffusion," *Journal of Computer-Mediated Communication*, vol. 29, no. 5, p. zmae016, Sept. 2024.
- [5] P. Terhörst, J. N. Kolf, M. Huber, F. Kirchbuchner, N. Damer, A. M. Moreno, J. Fierrez, and A. Kuijper, "A comprehensive study on face recognition biases beyond demographics," *IEEE Transactions on Technology and Society*, vol. 3, no. 1, pp. 16–30, Mar. 2022.
- [6] N. Liu, F. Zhang, L. Chang, and F. Duan, "Facial attribute classification by deep mining inter-attribute correlations," *IET Computer Vision*, vol. 17, no. 3, pp. 352–365, 2023.
- [7] D. R. Yoder-Himes, A. Asif, K. Kinney, T. J. Brandt, R. E. Cecil, P. R. Himes, C. Cashon, R. M. P. Hopp, and E. Ross, "Racial, skin tone, and sex disparities in automated proctoring software," *Frontiers in Education*, vol. 7, p. 881449, 2022.
- [8] Z. S. Marzoug, A. D. Hasan, and H. H. Abbas, "Gender and race classification using geodesic distance measurement," *Indonesian Journal of Electrical Engineering and Computer Science*, vol. 27, no. 2, pp. 820–831, Aug. 2022.
- [9] J. P. Robinson, C. Qin, Y. Henon, S. Timoner, and Y. Fu, "Balancing biases and preserving privacy on Balanced Faces in the Wild," *IEEE Transactions on Image Processing*, vol. 32, pp. 4365–4377, Aug. 2023.
- [10] M. Sohail, G. Ali, J. Rashid, I. Ahmad, S. H. Almotiri, M. A. AlGhamdi, A. A. Nagra, and K. Masood, "Racial identity-aware facial expression recognition using deep convolutional neural networks," *Applied Sciences*, vol. 12, no. 1, p. 88, 2022.
- [11] D. Belcar, P. Grd, and I. Tomićić, "Automatic ethnicity classification from middle part of the face using convolutional neural networks," *Informatics*, vol. 9, no. 1, p. 18, 2022.
- [12] H. Liao, L. Yuan, M. Wu, L. Zhong, G. Jin, and N. Xiong, "Face gender and age classification based on multi-task, multi-instance and multi-scale learning," *Applied Sciences*, vol. 12, no. 23, p. 12432, 2022.
- [13] G. Sunitha, K. Geetha, S. Neelakandan, A. K. S. Pundir, S. Hemalatha, and V. Kumar, "Intelligent deep learning based ethnicity recognition and classification using facial images," *Image and Vision Computing*, vol. 121, p. 104404, 2022.
- [14] J. Brinkmann, P. Swoboda, and C. Bartelt, "A multidimensional analysis of social biases in vision transformers," in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 2023, pp. 4891–4900.
- [15] S. Ramachandran and A. Rattani, "Deep generative views to mitigate gender classification bias across gender-race groups," in *Pattern Recognition, Computer Vision, and Image Processing. ICPR 2022 International*

- Workshops and Challenges*, J.-J. Rousseau and B. Kapralos, Eds. Cham, Switzerland: Springer Nature Switzerland, 2023, pp. 551–569.
- [16] S. Chen, X. Lai, Y. Yan, D.-H. Wang, and S. Zhu, “Learning an attention-aware parallel sharing network for facial attribute recognition,” *Journal of Visual Communication and Image Representation*, vol. 90, p. 103745, 2023.
 - [17] G. G. Tahyudin, M. D. Sulistiyono, M. Arzaki, and E. Rachmawati, “Classifying gender based on face images using vision transformer,” *International Journal on Informatics Visualization*, vol. 8, no. 1, pp. 18–25, 2024.
 - [18] A.-A. Kalkatawi and U. Saeed, “Ethnicity classification based on facial images using deep learning approach,” *International Journal of Advanced Computer Science and Applications*, vol. 15, no. 2, pp. 217–226, 2024.
 - [19] R. A. Putri, L. Anifah, R. E. Putra, Y. Yamasari, and R. A. Akbar, “Dual vision transformer integration for race and gender recognition based on facial images,” in *Proceedings of the 2025 8th International Conference on Vocational Education and Electrical Engineering (ICVEE)*, 2025, pp. 258–264.
 - [20] R. A. Putri, R. E. Putra, and Y. Yamasari, “MD-ViT: Multidomain vision transformer fusion for fair demographic attribute recognition,” *Journal of Information Engineering and Educational Technology*, vol. 9, no. 2, pp. 64–79, 2025.
 - [21] S. K. Gupta and N. Nain, “Review: single attribute and multi attribute facial gender and age estimation,” *Multimedia Tools and Applications*, vol. 82, no. 1, pp. 1289–1311, 2023.
 - [22] Y. Deng, S. Teng, L. Fei, W. Zhang, and I. Rida, “A multifeature learning and fusion network for facial age estimation,” *Sensors*, vol. 21, no. 13, p. 4597, 2021.
 - [23] Z. Wang, L. Xiao, Z. Cao, and H. Lu, “Vision transformer off-the-shelf: a surprising baseline for few-shot class-agnostic counting,” in *Proceedings of the AAAI Conference on Artificial Intelligence (AAAI)*, vol. 38, no. 6, Mar. 2024, pp. 5832–5840.
 - [24] D. Wilimitis and C. G. Walsh, “Practical considerations and applied examples of cross-validation for model development and evaluation in health care: tutorial,” *JMIR AI*, vol. 2, p. e49023, 2023.
 - [25] I. Hupont and C. Fernández, “DemogPairs: Quantifying the impact of demographic imbalance in deep face recognition,” in *Proceedings of the 2019 14th IEEE International Conference on Automatic Face and Gesture Recognition (FG)*, 2019, pp. 1–7.
 - [26] K. Han, Y. Wang, H. Chen, X. Chen, J. Guo, Z. Liu, Y. Tang, A. Xiao, C. Xu, Y. Xu, Z. Yang, Y. Zhang, and D. Tao, “A survey on vision transformer,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 45, no. 1, pp. 87–110, Jan. 2023.
 - [27] S. Khan, M. Naseer, M. Hayat, S. W. Zamir, F. S. Khan, and M. Shah, “Transformers in vision: A survey,” *ACM Computing Surveys*, vol. 54, no. 10s, pp. 200:1–200:41, Sept. 2022.
 - [28] Y. Liu, Y. Zhang, Y. Wang, F. Hou, J. Yuan, J. Tian, Y. Zhang, Z. Shi, J. Fan, and Z. He, “A survey of visual transformers,” *IEEE Transactions on Neural Networks and Learning Systems*, vol. 35, no. 6, pp. 7478–7498, June 2024.
 - [29] J. Ma, Y. Bai, B. Zhong, W. Zhang, T. Yao, and T. Mei, “Visualizing and understanding patch interactions in vision transformer,” *IEEE Transactions on Neural Networks and Learning Systems*, vol. 35, no. 10, pp. 13 671–13 680, 2024.
 - [30] M. A. Ganaie, M. Tanveer, P. N. Suganthan, and V. Snasel, “Oblique and rotation double random forest,” *Neural Networks*, vol. 153, pp. 496–517, 2022.
 - [31] C. Zhao, D. Wu, J. Huang, Y. Yuan, H.-T. Zhang, R. Peng, and Z. Shi, “BoostTree and BoostForest for ensemble learning,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 45, no. 7, pp. 8110–8126, 2023.
 - [32] Y.-X. He, S.-H. Lyu, and Y. Jiang, “Interpreting deep forest through feature contribution and MDI feature importance,” *ACM Transactions on Knowledge Discovery from Data*, vol. 20, no. 1, p. 15, Dec. 2025.
 - [33] N. Zhu, C. Zhu, L. Zhou, Y. Zhu, and X. Zhang, “Optimization of the random forest hyperparameters for power industrial control systems intrusion detection using an improved grid search algorithm,” *Applied Sciences*, vol. 12, no. 20, p. 10456, 2022.
 - [34] J. Chen, X. Wang, and F. Lei, “Data-driven multinomial random forest: a new random forest variant with strong consistency,” *Journal of Big Data*, vol. 11, no. 1, p. 34, Feb. 2024.
 - [35] E. Redivo, C. Viroli, and A. Farcomeni, “Quantile-distribution functions and their use for classification, with application to naïve Bayes classifiers,” *Statistics and Computing*, vol. 33, no. 2, p. 55, Mar. 2023.
 - [36] Y. A. Khan, S. Imaduddin, Y. P. Singh, M. Wajid, M. Usman, and M. Abbas, “Artificial intelligence based approach for classification of human activities using MEMS sensors data,” *Sensors*, vol. 23, no. 3, p. 1275, Jan. 2023.
 - [37] A. J. Molstad and K. Motwani, “Multiresolution categorical regression for interpretable cell-type annotation,” *Biometrics*, vol. 79, no. 4, pp. 3485–3496, Dec. 2023.
 - [38] P. Zhang, R. Wang, and N. Xiu, “Multinomial logistic regression classifier via lq,0-proximal Newton algorithm,” *Neurocomputing*, vol. 468, pp. 148–164, 2022.
 - [39] Y. Zhang, C. Wei, and X. Liu, “Group logistic regression models with l_{p,q} regularization,” *Mathematics*, vol. 10, no. 13, p. 2227, 2022.
 - [40] Z. Lai, X. Chen, J. Zhang, H. Kong, and J. Wen, “Maximal margin support vector machine for feature representation and classification,” *IEEE Transactions on Cybernetics*, vol. 53, no. 10, pp. 6700–6713, 2023.
 - [41] C. Yang, S.-K. Oh, B. Yang, W. Pedrycz, and L. Wang, “Hybrid fuzzy multiple SVM classifier through feature fusion based on convolution neural networks and its practical applications,” *Expert Systems with Applications*, vol. 202, p. 117392, 2022.
 - [42] M. A. Chandra and S. S. Bedi, “Survey on SVM and their application in image classification,” *International Journal of Information Technology*, vol. 13, no. 5, pp. 1–11, Oct. 2021.
 - [43] R. Guido, M. C. Groccia, and D. Conforti, “A hyper-parameter tuning approach for cost-sensitive support vector machine classifiers,” *Soft Computing*, vol. 27, no. 18, pp. 12 863–12 881, Sept. 2023.
 - [44] H. H. Rashidi, S. Albahra, S. Robertson, N. K. Tran, and B. Hu, “Common statistical concepts in the supervised machine learning arena,” *Frontiers in Oncology*, vol. 13, p. 1130229, Feb. 2023.
 - [45] I. M. De Diego, A. R. Redondo, R. R. Fernández, J. Navarro, and J. M. Moguerza, “General performance score for classification problems,” *Applied Intelligence*, vol. 52, no. 10, pp. 12 049–12 063, Aug. 2022.
 - [46] A. Tharwat, “Classification assessment methods,” *Applied Computing and Informatics*, vol. 17, no. 1, pp. 168–192, Jan. 2021.
 - [47] S. A. Hicks, I. Strümke, V. Thambawita, M. Hammou, M. A. Riegler, P. Halvorsen, and S. Parasa, “On evaluation metrics for medical applications of artificial intelligence,” *Scientific Reports*, vol. 12, no. 1, p. 5979, Apr. 2022.
 - [48] G. Hanczár, M. Stippinger, D. Hanák, M. T. Kurbucz, O. M. Törteli, Á. Chripkó, and Z. Somogyvári, “Feature space reduction method for ultrahigh-dimensional, multiclass data: random forest-based multi-round screening (RFMS),” *Machine Learning: Science and Technology*, vol. 4, no. 4, p. 045012, Oct. 2023.
 - [49] S. Guo, J. Zhang, Y. Wu, A. C. McLain, J. W. Hardin, B. Olatosi, and X. Li, “Functional multivariable logistic regression with an application to HIV viral suppression prediction,” *Biometrical Journal*, vol. 66, no. 5, p. e202300081, 2024.
 - [50] K. Nadeem and M.-A. Jabri, “Stable variable ranking and selection in regularized logistic regression for severely imbalanced big binary data,” *PLOS ONE*, vol. 18, no. 1, pp. 1–26, Jan. 2023.
 - [51] Scikit-learn Developers, “SVC,” <https://scikit-learn.org/stable/modules/generated/sklearn.svm.SVC.html>, 2026, accessed: Feb. 2, 2026.



RICKY EKA PUTRA menyelesaikan studi Sarjana, Magister, dan Doktor di bidang Ilmu Komputer di Institut Teknologi Sepuluh Nopember (ITS) masing-masing pada tahun 2008, 2011, dan 2020, serta memperoleh gelar Profesi Insinyur pada tahun 2024. Saat ini, beliau bertugas sebagai dosen dan peneliti di Departemen Informatika, Fakultas Informatika, Universitas Negeri Surabaya. Beliau aktif berkiprah dalam pelaksanaan tridarma perguruan tinggi yang mencakup pengajaran bidang informatika, program pemberdayaan masyarakat, publikasi karya ilmiah pada berbagai jurnal bereputasi, diseminasi riset pada forum seminar ilmiah, serta perolehan Hak Kekayaan Intelektual (HKI). Fokus penelitian utama beliau diarahkan pada pengembangan model kecerdasan buatan terapan yang menjembatani kemajuan metode komputasi cerdas dengan penyelesaian tantangan berbasis data nyata. Bidang minat penelitian beliau meliputi Deep Learning, Computer Vision, Big Data Analytics, aplikasi digital dan user experience, psikologi klinis, intensi perilaku, healthcare informatics, metode statistika, serta pendidikan digital dan anak usia dini.



RAFY AULIA AKBAR menyelesaikan pendidikan Sarjana Teknik Informatika pada tahun 2019 dan meraih gelar Magister Informatika di Universitas Negeri Surabaya dengan konsentrasi pada bidang Ilmu Komputer. Semasa studi, beliau berhasil menorehkan prestasi dengan menerima penghargaan Best Solution Award pada kompetisi regional ASEAN Vocational and Engineering Camp 2017 bertema “Toward School 4.0”. Saat ini, beliau aktif mendedikasikan diri sebagai peneliti di Departemen Informatika, Fakultas Informatika, Universitas Negeri Surabaya. Fokus dan minat penelitian beliau terpusat pada domain Computer Vision, Medical Image Analysis, Multimodal Deep Learning, Natural Language Processing, serta arsitektur Vision Transformer, khususnya dalam pengembangan sistem pembangkitan laporan medis otomatis.



REZKY ARISANTI PUTRI meraih gelar Sarjana Teknik Informatika pada tahun 2019 dengan peminatan bidang Kecerdasan Buatan (Artificial Intelligence) dan telah menuntaskan studi Magister Informatika di Universitas Negeri Surabaya (UNESA). Saat ini, beliau aktif berkiprah sebagai peneliti di Departemen Informatika, Fakultas Informatika, Universitas Negeri Surabaya. Beliau terlibat intensif dalam riset pengenalan atribut demografis wajah berbasis model transformer serta secara aktif mendiseminasikan kontribusi keilmuannya melalui publikasi pada forum konferensi internasional dan jurnal ilmiah bereputasi. Fokus dan minat penelitian beliau mencakup Computer Vision, Deep Learning, Vision Transformer, Facial Attribute Recognition, Natural Language Processing, Machine Learning, dan Algorithmic Fairness. Melalui kegiatan akademik dan eksplorasi riset yang konsisten, beliau terus memperdalam kompetensi keilmuan serta berkontribusi nyata dalam kemajuan teknologi komputasi cerdas.



SHUKOR SANIM MOHD FAUZI merupakan Senior Lecturer pada Faculty of Computer and Mathematical Sciences, Universiti Teknologi MARA (UiTM), Malaysia. Ia memperoleh Diploma in Computer Science dan Bachelor of Science (Hons.) in Information Systems Engineering dari UiTM, kemudian melanjutkan studi magister di Centre for Advanced Software Engineering, Universiti Teknologi Malaysia, serta meraih gelar doktor (Ph.D.) di bidang Software Engineering dari University of New South Wales (UNSW), Australia. Bidang penelitiannya mencakup software engineering dan empirical software engineering, dengan perhatian khusus pada mining software repositories, social network analysis, socio-technical congruence, computer-supported collaborative work, serta analisis dan pengembangan proses perangkat lunak.

...



YUNI YAMASARI merupakan dosen dan peneliti di Departemen Informatika, Fakultas Informatika, Universitas Negeri Surabaya (UNESA) dengan landasan keilmuan yang kokoh di dunia akademik maupun praktis. Beliau menyelesaikan pendidikan Sarjana, Magister, hingga Doktor di Institut Teknologi Sepuluh Nopember (ITS), dengan kepakaran utama pada bidang Software Engineering dan Data Mining. Aktivitas tridarma beliau ditandai oleh keterlibatan aktif dalam pemberdayaan masyarakat, publikasi artikel ilmiah bereputasi, serta penulisan buku teks akademik. Beliau secara berkala mendiseminasikan temuan penelitiannya di berbagai forum ilmiah nasional maupun internasional dan telah memperoleh beberapa Hak Kekayaan Intelektual (HKI). Dedikasi akademik beliau diarahkan untuk mendorong perkembangan rekayasa perangkat lunak, analisis data komprehensif, dan bidang informatika terapan.