IEEE Access
Multidisciplinary | Rapid Review | Open Access Journal

Date of publication xxxx 00, 0000, date of current version xxxx 00, 0000.

Digital Object Identifier 10.1109/ACCESS.2026.0000000

Multi-Domain Vision Transformer Fusion for Intersectional Demographic Classification from Facial Images

RICKY EKA PUTRA[1], REZKY ARISANTI PUTRI[1], YUNI YAMASARI[1], RAFY AULIA AKBAR[1], AND SHUKOR SANIM MOHD FAUZI[2]

[1]Department of Informatics, Faculty of Informatics, Universitas Negeri Surabaya, Surabaya 60231, Indonesia
[2]Faculty of Computer and Mathematical Sciences, Universiti Teknologi MARA Perlis Branch, 02600 Arau, Perlis, Malaysia

Corresponding author: Ricky Eka Putra (e-mail: rickyeka@unesa.ac.id).

This research was supported in part by the Department of Informatics, Faculty of Informatics, Universitas Negeri Surabaya.

ABSTRACT Pengenalan atribut demografis wajah interseksional (ras dan gender) menghadapi tantangan variasi ekspresi afektif, penuaan biologis, phenotypic overlap, keterbatasan representasi domain tunggal, serta ancaman kebocoran identitas akibat pemisahan berbasis citra acak. Penelitian ini mengusulkan kerangka fusi multi-domain Vision Transformer (ViT) yang mengintegrasikan representasi biometrik wajah, ekspresi afektif, dan usia biologis melalui konkatenasi langsung berdimensi 2.304. Evaluasi menerapkan protokol Strict Subject-Disjoint Partitioning bebas kebocoran identitas pada dataset DemogPairs. Berbasis backbone ViT beku, representasi laten diproses melalui penskalaan fitur, Principal Component Analysis (PCA), dan empat pengklasifikasi klasik (RF, GNB, LR, SVM) yang dioptimasi via 5-Fold StratifiedGroupKFold GridSearchCV pada tingkat-fold terisolasi. Hasil empiris membuktikan keunggulan fusi tri-domain pada pengklasifikasi linier dan non-linier. Logistic Regression memimpin tolok ukur dengan akurasi 88.66%, presisi makro 88.75%, recall makro 88.66%, F1-score makro 88.68%, dan selang kepercayaan 95% Wilson Score [87.25%, 89.93%], setara secara statistik dengan Support Vector Machine yang mencatat akurasi 88.61%, presisi makro 88.66%, recall makro 88.61%, F1-score makro 88.63%, dan selang kepercayaan 95% Wilson Score [87.20%, 89.88%]. Uji hipotesis McNemar mengonfirmasi keunggulan signifikan fusi tri-domain atas domain tunggal ($p < 0.001$) serta menegaskan paritas prediktif antara Logistic Regression dan Support Vector Machine ($p = 1.0000$). Namun, Logistic Regression unggul mutlak dalam efisiensi komputasi dengan latensi inferensi 0.0046 ms per sampel dan ukuran model 0.11 MB, beroperasi lebih dari 1.000 kali lebih cepat serta 330 kali lebih hemat memori dibanding Support Vector Machine. Model teratas mempertahankan stabilitas lintas enam kelompok interseksional dengan rentang recall 84.72% hingga 94.44% dan kesenjangan Equal Opportunity Difference sebesar 9.72 poin persentase.

INDEX TERMS Biometrics, face recognition, feature extraction, intersectional demographic recognition, multi-domain feature fusion, Vision Transformer.

I. INTRODUCTION

Pengenalan otomatis atribut ras dan gender wajah memegang peranan krusial pada tata kelola identitas digital, kontrol akses biometrik, forensik digital, dan personalisasi antarmuka cerdas [1], [2]. Berbagai studi independen dan evaluasi National Institute of Standards and Technology (NIST) menunjukkan bahwa model visi komputer komersial memperlihatkan disparitas performa yang merugikan kelompok minoritas tertentu, khususnya wanita berkulit gelap [3], [4]. Kesenjangan akurasi ini bersumber dari karakteristik distribusi data latih yang tidak seimbang serta representasi fitur visual yang kurang tangguh terhadap variasi fenotipik dan pencahayaan lingkungan [5]. Keterbatasan sistem konvensional dalam menangani variasi visual tersebut memperlihatkan perlunya pendekatan representasi baru yang memodelkan interaksi ras dan gender secara terpadu.

Praktik umum dalam literatur visi komputer memisahkan klasifikasi ras dan gender sebagai dua model komputasi independen yang berdiri sendiri [6]. Pendekatan terisolasi tersebut gagal menangkap dinamika interaksi dan kesalahan

pada persilangan subkelompok demografis tertentu, seperti wanita berkulit hitam atau wanita Asia [7], [8]. Akibatnya, penurunan performa klasifikasi pada irisan demografis spesifik tersebut sering kali luput dari audit metrik akurasi agregat konvensional [9]. Formulasi interseksional terpadu yang memetakan enam kelas gabungan (3 Ras $\times$ 2 Gender) pada kondisi evaluasi seimbang memungkinkan audit performa yang adil dan transparan. Pemodelan klasifikasi interseksional ini menuntut representasi visual kaya yang mampu memisahkan batas keputusan antarsubkelompok yang saling tumpang tindih secara fenotipik [10].

Metodologi pengenalan atribut wajah telah berevolusi dari fitur buatan tangan klasik menuju arsitektur Convolutional Neural Network (CNN) dan Vision Transformer (ViT). Pada era CNN, penelitian terdahulu mengeksplorasi ekstraksi ciri demografis melalui pemanfaatan wilayah wajah tengah [11] serta kerangka kerja multi-tugas multi-skala untuk estimasi usia dan gender [12]. Di samping itu, model CNN mendalam turut dikembangkan untuk meningkatkan akurasi pengenalan etnisitas berbasis citra wajah [13]. Arsitektur ViT kemudian hadir membawa keunggulan pemodelan hubungan spasial global antarpatch citra melalui mekanisme Multi-Head Self-Attention (MHSA) [14]. Pendekatan representasi generatif sintetis juga dieksplorasi untuk memitigasi disparitas demografis lintas kelompok gender dan ras [15]. Perkembangan mutakhir mencakup integrasi modul atensi paralel [16] serta pemanfaatan ViT untuk klasifikasi gender wajah [17]. Selain itu, eksplorasi arsitektur transformer multi-aksis diusulkan untuk memperkaya variasi pemodelan representasi visual hierarkis [18]. Penggabungan representasi ViT lintas domain mulai dirintis melalui integrasi fitur ganda wajah dan emosi [19], serta fusi representasi multi-domain untuk pengenalan atribut demografis yang adil [20]. Terlepas dari kemajuan pesat model visi transformer tersebut, telaah literatur mengidentifikasi sejumlah tantangan metodologis yang masih memerlukan kajian empiris terpadu.

Keterbatasan representasi domain tunggal menjadi kesenjangan metodologis utama karena biometrik wajah statis rentan terhadap distorsi ekspresi afektif dinamis [11], [17]. Selain itu, sistem pengenalan wajah sensitif terhadap variasi penuaan biologis jika fitur morfologi usia diabaikan [12], [18]. Kesenjangan kritis lainnya adalah ancaman kebocoran identitas, di mana evaluasi konvensional berbasis partisi acak citra membagi foto dari subjek yang sama ke data latih dan uji, sehingga memicu memorisasi identitas. Terlebih lagi, studi terdahulu umumnya minim pembuktian signifikansi inferensial formal [13], [19]. Profil efisiensi komputasi praktis pada pengklasifikasi hilir juga belum dieksplorasi secara mendalam [20]. Untuk menjembatani kesenjangan tersebut, penelitian ini mengusulkan fusi tri-domain ViT di bawah protokol evaluasi ketat.

Untuk menjawab kesenjangan tersebut, penelitian ini mengusulkan fusi tri-domain ViT yang memadukan geometri biometrik statis (ViT-Face), ekspresi afektif dinamis (ViT-Emotion), dan morfologi penuaan biologis (ViT-Age) melalui operasi konkatenasi langsung (Face $\oplus$ Emotion $\oplus$ Age: 2.304 dimensi) [21], [22]. Ekstraksi representasi laten visual dilakukan secara offline dari backbone ViT pra-latih yang dibekukan untuk menjaga efisiensi komputasi tanpa fine-tuning ulang [23]. Penelitian ini mengadopsi arsitektur evaluasi Dual-Benchmark, yang menetapkan Strict Subject-Disjoint Partitioning (600 subjek unik, 480 latih dan 120 uji held-out, 0% kebocoran) sebagai tolok ukur utama generalisasi, sekaligus mempertahankan evaluasi subject-overlap historis sebagai studi ablasi empiris untuk menguantifikasi efek memorisasi identitas. Optimasi hyperparameter komprehensif dilakukan pada empat famili pengklasifikasi klasik, yaitu Random Forest (RF), Gaussian Naive Bayes (GNB), Logistic Regression (LR), dan Support Vector Machine (SVM), melalui validasi silang 5-Fold StratifiedGroupKFold. Pipeline modular penskalaan dan Principal Component Analysis (PCA) dipelajari secara terisolasi pada lipatan latih untuk mencegah kebocoran informasi dengan total 31.920 penyesuaian model [24].

Kontribusi ilmiah utama dari penelitian ini dirangkum ke dalam empat poin utama sebagai berikut:

1) Formulasi kerangka kerja ablasi tujuh skema fitur yang mengintegrasikan backbone Vision Transformer pralatih yang dibekukan dengan prapemrosesan tingkat-fold bebas kebocoran serta optimasi hyperparameter lintas empat famili pengklasifikasi untuk klasifikasi demografis interseksional.
2) Penetapan tolok ukur evaluasi bebas kebocoran identitas pada dataset DemogPairs dan studi komparatif ablasi kebocoran data untuk menguantifikasi efek memorisasi identitas wajah.
3) Pengujian hipotesis inferensial berpasangan yang memvalidasi peningkatan signifikan representasi multi-domain atas baseline domain tunggal, menunjukkan tidak adanya perbedaan performa prediktif yang signifikan secara statistik antara pengklasifikasi linier dan non-linier terbaik, serta mengkarakterisasi komplementaritas fitur usia linier versus kejenuhan representasi asimtotik non-linier lintas famili pengklasifikasi.
4) Penyajian profil efisiensi komputasi komprehensif mencakup waktu ekstraksi ViT, biaya pelatihan, latensi inferensi, dan jejak memori yang merealisasikan kepala pengklasifikasi hilir berbobot sangat ringan untuk implementasi praktis.

Sistematika penulisan artikel ini disusun sebagai berikut: Section II mengulas sintesis literatur terkait pengenalan demografis wajah dan arsitektur transformer. Section III menjabarkan spesifikasi dataset, metodologi ekstraksi fitur multi-domain ViT, serta pipeline optimasi pengklasifikasi. Section IV menyajikan hasil evaluasi eksperimental, studi ablasi kebocoran data, pengujian inferensial, profil efisiensi komputasi, dan analisis keadilan interseksional. Terakhir, Section V merangkum kesimpulan utama, batasan metodologis, serta rekomendasi arah riset lanjutan.

II. RELATED WORKS

A. DEMOGRAPHIC FACE RECOGNITION

Perkembangan analisis atribut demografis wajah bermula dari pemanfaatan deskriptor geometri lokal serta fitur buatan tangan seperti Local Binary Patterns dan filter Gabor menuju representasi fitur mendalam berbasis Convolutional Neural Networks (CNN). Pendekatan berbasis region lokal memanfaatkan geometri area wajah bagian tengah untuk mengenali etnisitas sekaligus menekan interferensi latar belakang citra [11]. Namun, arsitektur konvolusi klasik masih menghadapi tantangan ketahanan terhadap fluktuasi pencahayaan ekstrem dan disparitas performa antarras yang dikenal sebagai *Other-Race Effect*. Peningkatan kedalaman arsitektur konvolusi terbukti mampu memperluas daya diskriminasi fitur visual dalam membedakan karakteristik populasi yang heterogen [13]. Selain pendalaman lapisan, mekanisme berbagi fitur paralel yang diintegrasikan dengan modul atensi visual dikembangkan untuk menangkap korelasi antaratribut wajah [16]. Pendekatan tersebut memperkuat transisi ke arah ekstraksi representasi yang lebih adaptif terhadap keragaman morfologi wajah manusia.

Setelah ekstraksi fitur visual selesai, penentuan pengklasifikasi hilir memegang peranan krusial dalam memetakan representasi laten ke ruang keputusan demografis. Model konvensional umumnya mengandalkan lapisan SoftMax secara *end-to-end* untuk menghasilkan probabilitas kelas secara langsung [11], [18]. Namun, pendekatan pemetaan ruang fitur nonlinier seperti Kernel Extreme Learning Machine (KELM) dan Support Vector Machine (SVM) pada representasi beku menawarkan batas pemisahan kelas yang kokoh tanpa pembaruan bobot *backbone* [13], [12]. Formulasi matematis fungsi keputusan KELM dimodelkan pada (1):

$$f(\mathbf{x}) = \mathbf{h}(\mathbf{x})\boldsymbol{\beta} = \sum_{i=1}^{M} \beta_i K(\mathbf{x}, \mathbf{x}_i) \tag{1}$$

di mana $\mathbf{h}(\mathbf{x})$ menyatakan vektor pemetaan fitur laten tersembunyi, $\boldsymbol{\beta} = [\beta_1, \ldots, \beta_M]^T$ melambangkan bobot keluaran teroptimasi, $K(\mathbf{x}, \mathbf{x}_i)$ merupakan fungsi kernel yang memetakan kedekatan nonlinier sampel masukan $\mathbf{x}$ terhadap sampel pendukung $\mathbf{x}_i$, dan M merepresentasikan jumlah basis representasi. Pemetaan ruang kernel ini memungkinkan pemisahan batas keputusan nonlinier yang efektif pada ruang fitur berdimensi tinggi tanpa memerlukan optimasi *gradient descent* berulang.

B. VISION TRANSFORMERS IN FACE ANALYSIS

Penerapan Vision Transformer (ViT) dalam analisis biometrik wajah menghadirkan pemodelan visual global yang mengatasi bias induktif lokal CNN [14]. Citra masukan dipartisi menjadi N *patch* visual beresolusi $P \times P$ dengan C kanal warna, lalu diratakan dan diproyeksikan secara linier ke dimensi laten melalui formulasi (2):

$$\mathbf{x}_p \in \mathbb{R}^{N \times (P^2 \cdot C)}, \quad \mathbf{z}_0 = [\mathbf{x}_{\text{class}}; \mathbf{x}_p^1\mathbf{E}; \ldots; \mathbf{x}_p^N\mathbf{E}] + \mathbf{E}_{\text{pos}} \tag{2}$$

di mana $N = HW/P^2$ menyatakan jumlah *patch*, P ukuran resolusi spasial *patch*, C jumlah kanal warna, $\mathbf{E} \in \mathbb{R}^{(P^2 \cdot C) \times D}$ matriks proyeksi linier, $\mathbf{x}_{\text{class}}$ token kelas terpelajari, dan $\mathbf{E}_{\text{pos}}$ matriks penyandian posisi spasial 1D. Interaksi spasial global antar-*patch* selanjutnya dimodelkan melalui mekanisme Scaled Dot-Product Multi-Head Self-Attention (MHSA) sesuai (3):

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{d_k}}\right)\mathbf{V} \tag{3}$$

dengan $\mathbf{Q}$, $\mathbf{K}$, dan $\mathbf{V}$ berturut-turut merepresentasikan matriks *Query*, *Key*, dan *Value*, serta $\sqrt{d_k}$ sebagai faktor penskalaan dimensi. Mekanisme atensi ini efektif diterapkan pada klasifikasi gender wajah [17], sementara arsitektur multi-aksis seperti MaxViT memperkaya hierarki representasi lewat atensi blok dan kisi [18].

Karakteristik representasi global yang dihasilkan oleh arsitektur transformer mendorong telaah mendalam terkait propagasi bias demografis dalam sistem visi komputer. Pengujian pada korpus data yang seimbang menyediakan kondisi eksperimental terkontrol untuk membandingkan disparitas performa antarsubkelompok tanpa distorsi ketimpangan jumlah sampel kelas. Walaupun distribusi data disetarakan, keseimbangan tersebut tidak secara otomatis meniadakan bias sosial yang melekat pada model. Investigasi representasi laten membuktikan bahwa arsitektur transformer dapat mereproduksi serta melipatgandakan bias sosial yang bersumber dari korpus pra-latih berskala masif [14]. Sebagai langkah penanganan ketimpangan tersebut, pendekatan pandangan generatif berbasis StyleGAN2 dimanfaatkan untuk memperkaya keragaman fenotipik antarkelompok demografis [15]. Integrasi metode ini membuktikan bahwa pengujian keadilan representasi dan penyelarasan distribusi data sangat krusial dalam perancangan model biometrik wajah modern.

C. MULTI-DOMAIN FEATURE FUSION

Keterbatasan representasi domain tunggal dalam mengakomodasi variabilitas visual wajah mendorong perkembangan pembelajaran multi-tugas dan fusi lintas representasi. Pembelajaran multi-tugas terbukti efektif dalam memetakan korelasi antara estimasi usia dan klasifikasi gender secara terpadu [12], sedangkan skema berbagi representasi paralel memfasilitasi ekstraksi simultan berbagai atribut afektif wajah [16]. Lebih lanjut, eksplorasi penggabungan fitur laten berbasis Vision Transformer memperlihatkan keunggulan integrasi ganda domain biometrik wajah dan ekspresi emosi [19], serta perpaduan fitur biometrik dengan estimasi usia biologis [20]. Fusi representasi multi-domain ortogonal tersebut diformulasikan melalui operasi *Direct Sum* pada (4):

$$\mathbf{z}_{\text{fused}} = \mathbf{z}_{\text{face}} \oplus \mathbf{z}_{\text{emotion}} \oplus \mathbf{z}_{\text{age}} \in \mathbb{R}^{D_{\text{total}}} \tag{4}$$

di mana operator $\oplus$ menyatakan penggabungan konkatenasi langsung vektor fitur laten berbobot sama dari masing-masing domain ortogonal biometrik wajah $\mathbf{z}_{\text{face}}$, ekspresi afektif $\mathbf{z}_{\text{emotion}}$, dan morfologi usia biologis $\mathbf{z}_{\text{age}}$, dengan dimensi gabungan terakumulasi $D_{\text{total}} = 2.304$. Integrasi terpadu ini menghasilkan ruang representasi komprehensif yang

memadukan isyarat identitas statis, variasi ekspresi dinamis, dan pola penuaan alami.

Mempertimbangkan batasan metodologis pada studi terdahulu, penelitian ini menegaskan posisi kebaruan melalui fusi tri-domain terpadu yang memadukan representasi biometrik wajah, ekspresi emosi afektif, dan usia biologis dari model Vision Transformer pra-latih dengan bobot *backbone* beku. Berbeda dari literatur sebelumnya yang mengevaluasi performa pada skema pembagian citra acak berisiko kebocoran identitas, kerangka kerja ini dievaluasi secara ketat di bawah protokol *Strict Subject-Disjoint Partitioning* untuk menjamin keabsahan generalisasi pada subjek yang belum pernah dilihat sebelumnya. Selain itu, kontribusi penelitian ini mencakup eksplorasi sistematis tujuh skema ablasi representasi fitur lintas empat famili pengklasifikasi pembelajaran mesin klasik, optimasi prapemrosesan terisolasi tingkat lipatan bebas kebocoran, serta karakterisasi inferensial formal mengenai fenomena saturasi representasi nonlinier versus komplementaritas linier.

III. MATERIALS AND METHODS

Kerangka kerja komputasi end-to-end yang diusulkan dalam penelitian ini dirancang untuk mengklasifikasikan ras dan gender interseksional secara terpadu, sebagaimana diilustrasikan pada Figure 1. Alur metodologi berawal dari masukan citra wajah mentah DemogPairs yang dipartisi secara ketat melalui protokol Strict Subject-Disjoint Partitioning (80% set latih dan 20% set uji held-out) demi menjamin eliminasi kebocoran identitas subjek secara mutlak. Selanjutnya, setiap citra wajah diproses oleh tiga model Vision Transformer (ViT) spesifik tugas yang dibekukan secara offline untuk mengekstraksi representasi laten multi-domain berdimensi tinggi, mencakup fitur geometri kraniofasial biometrik wajah, pola ekspresi emosi afektif dinamis, dan penanda morfologi penuaan biologis. Ketiga representasi laten berdimensi 768 tersebut disatukan melalui operasi fusi konkatenasi langsung $\mathbf{z}_{\text{tri}} = \mathbf{f}_{\text{face}} \oplus \mathbf{f}_{\text{emotion}} \oplus \mathbf{f}_{\text{age}}$ sehingga membentuk vektor representasi gabungan tri-domain berdimensi 2.304. Vektor fusi ini kemudian dialirkan ke dalam pipeline pemrosesan modular berantai (Scaler $\rightarrow$ PCA $\rightarrow$ Downstream Classifier) yang dioptimasi via 5-Fold StratifiedGroupKFold Grid Search Cross-Validation (GridSearchCV) pada tingkat fold terisolasi untuk mengklasifikasikan enam subkelompok demografis secara objektif dan bebas bias.

A. DATASET

Eksperimen dalam penelitian ini memanfaatkan dataset DemogPairs yang dikembangkan oleh Hupont dan Fernández [25]. Dataset ini dirancang secara khusus sebagai tolok ukur pengujian biometrik verifikasi wajah untuk mengevaluasi dampak ketimpangan demografis pada sistem pengenalan wajah mendalam. Korpus ini memuat total 10.800 citra wajah yang terdistribusi secara seimbang sempurna ke dalam enam subkelompok demografis interseksional, yaitu persilangan antara tiga kelompok ras makro (Asian, Black, dan White) serta dua kategori gender biner (Female dan Male). Struktur dataset mencakup 600 subjek atau identitas unik, dengan alokasi seragam tepat 100 individu untuk setiap subkelompok demografis. Setiap identitas diwakili oleh tepat 18 citra wajah terkontrol yang mencakup variasi pose kepala, ragam ekspresi afektif, dan kondisi pencahayaan terstandar, sehingga menghasilkan 1.800 citra per subkelompok. Distribusi kelas yang seimbang ini menciptakan lingkungan evaluasi yang terkontrol untuk menganalisis disparitas performa klasifikasi antarsubkelompok secara objektif tanpa terdistorsi oleh ketidakseimbangan jumlah sampel. Contoh citra wajah dari keenam subkelompok demografis tersebut disajikan pada Figure 2.

Untuk menjamin integritas evaluasi dan mengeliminasi risiko kebocoran identitas secara mutlak (0% kebocoran), penelitian ini menerapkan protokol Strict Subject-Disjoint Partitioning. Sebanyak 600 identitas unik dipisahkan secara deterministik menjadi 480 subjek untuk set latih (80%) dan 120 subjek untuk set uji held-out (20%). Pembagian ini dilakukan secara terstratifikasi ketat pada keenam subkelompok demografis, sehingga menghasilkan alokasi seimbang berupa 80 subjek latih (1.440 citra) dan 20 subjek uji (360 citra) per subkelompok. Skema partisi ini menghasilkan total 8.640 citra pada set latih dan 2.160 citra pada set uji held-out, sebagaimana dirinci pada Table 1. Seluruh subjek uji bersifat independen dan belum pernah dilihat oleh model selama proses pelatihan maupun penalaan hyperparameter. Pada tahapan prapemrosesan data, setiap citra wajah berformat terpusat dikonversi ke format 3-channel Red, Green, Blue (RGB) dan diubah resolusinya menjadi 224×224 piksel. Intensitas piksel dinormalisasi secara channel-wise mengikuti parameter rata-rata dan deviasi standar yang sesuai dengan konfigurasi pra-latih masing-masing checkpoint vision transformer. Tidak ada augmentasi buatan sintetis yang diterapkan dalam alur kerja ini demi menguji kapasitas generalisasi representasi fitur secara murni.

B. VISION TRANSFORMER FEATURE EXTRACTION

Arsitektur pengekstraksi representasi visual pada penelitian ini mengadopsi model Vision Transformer baku rancangan Dosovitskiy et al. [26] sebagaimana diilustrasikan pada Figure 3. Setiap citra wajah masukan beresolusi 224×224 piksel dengan $C = 3$ kanal warna dibagi menjadi $N = 196$ patch spasial non-overlapping berdimensi $P \times P$ dengan $P = 16$ [27]. Setiap patch diratakan menjadi $\mathbf{x}_p \in \mathbb{R}^{P^2 \cdot C}$ lalu diproyeksikan secara linier melalui matriks $\mathbf{E} \in \mathbb{R}^{(P^2 \cdot C) \times D}$ ke ruang laten berdimensi $D = 768$. Vektor patch tersebut dirangkaikan dengan token kelas $\mathbf{x}_{\text{class}} \in \mathbb{R}^D$ dan embedding posisi $\mathbf{E}_{\text{pos}} \in \mathbb{R}^{(N+1) \times D}$ sesuai perumusan (5) [27]. Sekuens vektor token awal $\mathbf{z}_0$ selanjutnya diumpankan ke tumpukan $L = 12$ lapisan transformer encoder identik. Pada setiap lapisan encoder ℓ ($\ell = 1, \ldots, L$), representasi fitur diproses melalui Multi-Head Self-Attention (MHSA) setelah operasi Layer Normalization (LN), lalu dialirkan menuju Multi-Layer Perceptron (MLP) dua lapis dengan fungsi aktivasi Gaussian Error Linear Unit (GeLU) berdasarkan (6) [28]. Mekanisme self-attention memungkinkan pemodelan relasi

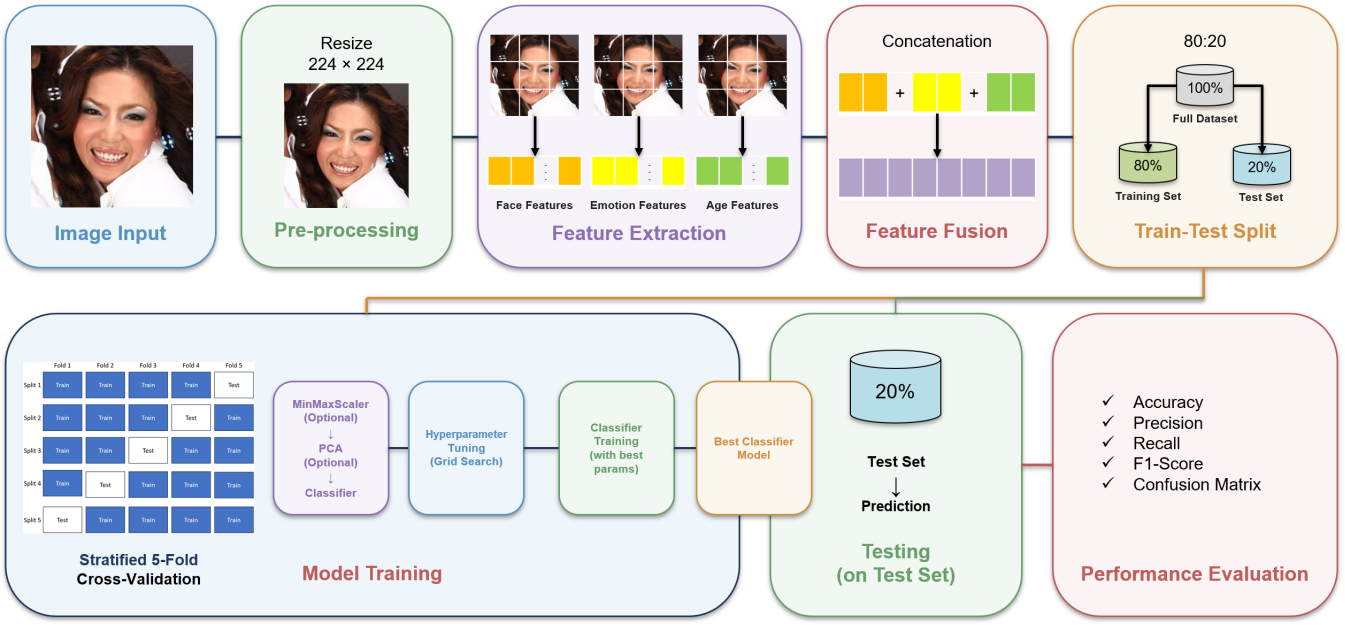


FIGURE 1. End-to-End Framework of the Proposed Multi-Domain Vision Transformer Feature Fusion and Classical Classifier Optimization for Intersectional Race and Gender Classification.



FIGURE 2. Sample Images of the DemogPairs Dataset across Six Intersectional Demographic Subgroups: (a) Asian Females, (b) Asian Males, (c) Black Females, (d) Black Males, (e) White Females, and (f) White Males.

TABLE 1. DemogPairs Dataset Partition and Subject-Disjoint Demographic Subgroup Distribution.

Subkelompok Demografis	Subjek Latih	Citra Latih	Subjek Uji (Held-Out)	Citra Uji (Held-Out)	Total Subjek	Total Citra
Asian Females	80	1.440	20	360	100	1.800
Asian Males	80	1.440	20	360	100	1.800
Black Females	80	1.440	20	360	100	1.800
Black Males	80	1.440	20	360	100	1.800
White Females	80	1.440	20	360	100	1.800
White Males	80	1.440	20	360	100	1.800
Total	**480**	**8.640**	**120**	**2.160**	**600**	**10.800**

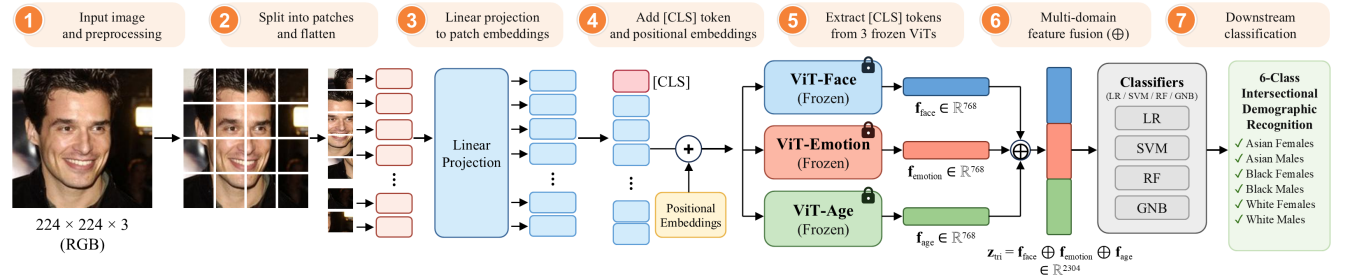


FIGURE 3. Redesigned High-Resolution Architecture of the Parallel Multi-Domain ViT Feature Extraction Backbones, Layer-12 CLS Token Extraction, and Direct Sum Feature Concatenation Pipeline.

spasial global antarpatch wajah tanpa batasan receptive field lokal [29].

$$\mathbf{z}_0 = [\mathbf{x}_{\text{class}};\ \mathbf{x}_p^1\mathbf{E};\ \ldots;\ \mathbf{x}_p^N\mathbf{E}] + \mathbf{E}_{\text{pos}} \tag{5}$$

$$\mathbf{z}'_\ell = \text{MHSA}(\text{LN}(\mathbf{z}_{\ell-1})) + \mathbf{z}_{\ell-1}, \quad \mathbf{z}_\ell = \text{MLP}(\text{LN}(\mathbf{z}'_\ell)) + \mathbf{z}'_\ell \tag{6}$$

Untuk memperoleh representasi visual wajah yang komplementer, kerangka kerja ini memanfaatkan tiga model backbone ViT-Base pra-latih yang dibekukan secara terpisah. Model pertama merupakan `ViT-Face (skutaada/VIT-VGGFace)` yang memetakan pola geometri kraniofasial statis berbasis korpus VGGFace2. Model kedua adalah `ViT-Emotion (dima806/facial_emotions_image_detection)` untuk mengekstraksi dinamika ekspresi afektif wajah berdasarkan fine-tuning korpus FER-2013. Model ketiga yaitu `ViT-Age (dima806/facial_age_image_detection)` yang memetakan penanda morfologi usia biologis subjek berbasis dataset UTKFace dan IMDB-WIKI. Seluruh model domain mengadopsi struktur ViT-Base/16 dengan dimensi tersembunyi 768 dan 12 lapisan encoder. Citra masukan diformat ke ruang warna RGB, disesuaikan ke resolusi 224 $\times$ 224 piksel, serta dinormalisasi secara seragam lewat parameter statistik $\mu = [0.5, 0.5, 0.5]$ dan $\sigma = [0.5, 0.5, 0.5]$. Ekstraksi fitur memanfaatkan in-memory processor caching tanpa pembaruan gradien demi menjamin efisiensi komputasi dan reproduktibilitas representasi.

Representasi fitur laten tingkat tinggi diekstraksi dari setiap model domain melalui aktivasi token [CLS] pada lapisan encoder terakhir ($\ell = 12$). Vektor keluaran token kelas tersebut kemudian distandardisasi melalui operasi Layer Normalization akhir untuk menghasilkan representasi domain teranormalisasi $\mathbf{f}_{\text{domain}} \in \mathbb{R}^{768}$ sesuai perumusan (7), di mana $\mathbf{z}_{12}^0$ melambangkan representasi token pertama pada lapisan kedua belas yang diekstraksi tanpa perhitungan gradien. Selanjutnya, ketiga representasi domain tunggal digabungkan melalui operasi fusi konkatenasi langsung $\oplus$ menjadi vektor representasi gabungan tri-domain $\mathbf{z}_{\text{tri}} \in \mathbb{R}^{2304}$ berdasarkan formulasi (8). Ruang representasi gabungan ini memadukan informasi biometrik kraniofasial $\mathbf{f}_{\text{face}}$, ekspresi emosional afektif $\mathbf{f}_{\text{emotion}}$, serta estimasi usia biologis $\mathbf{f}_{\text{age}}$ secara simultan. Eksplorasi empiris dilakukan melalui pengujian ablasi sistematis yang mencakup tujuh skema konfigurasi fitur, meliputi tiga konfigurasi domain tunggal berdimensi 768, tiga konfigurasi domain ganda berdimensi 1.536, dan satu konfigurasi tri-domain usulan berdimensi 2.304 sebagaimana disajikan pada Table 2.

$$\mathbf{f}_{\text{domain}} = \text{LN}(\mathbf{z}_{12}^0) \in \mathbb{R}^{768} \tag{7}$$

$$\mathbf{z}_{\text{tri}} = \mathbf{f}_{\text{face}} \oplus \mathbf{f}_{\text{emotion}} \oplus \mathbf{f}_{\text{age}} \in \mathbb{R}^{2304} \tag{8}$$

C. RANDOM FOREST

Model ensemble Random Forest (RF) mengagregasikan prediksi sekumpulan pohon keputusan independen untuk mengklasifikasikan fitur wajah berdasarkan prinsip bootstrap aggregating (bagging) dan random subspace method [30]. Pendekatan ini mereduksi varians prediksi dengan membangun sebanyak B pohon klasifikasi dari sampel acak data latih [31]. Setiap percabangan node membatasi pemilihan fitur pada subset acak berukuran max_features $\in$ {'sqrt', 'log2'} untuk menekan korelasi antarpohon [32]. Kriteria pemisahan cabang mengoptimalkan indeks Gini impurity hingga memenuhi ambang batas minimum pemisahan node min_samples_split, batas kedalaman max_depth, atau batas minimum daun min_samples_leaf [33]. Mekanisme majority voting menentukan keputusan akhir sampel citra melintasi seluruh pohon keputusan [34]. Prosedur penalaan hyperparameter mengevaluasi kombinasi penskalaan fitur, reduksi dimensionalitas PCA, variasi jumlah pohon n_estimators, serta batasan pertumbuhan pohon, menghasilkan 288 konfigurasi grid dengan 1.440 total fits melalui 5-Fold Stratified Cross-Validation sebagaimana dirangkum pada Table 3.

D. GAUSSIAN NAIVE BAYES

Berdasarkan Teorema Bayes, pengklasifikasi Gaussian Naive Bayes (GNB) mengestimasi probabilitas posterior kelas demografis interseksional dengan asumsi bahwa seluruh dimensi fitur kontinu bersifat independen secara bersyarat [35]. Fungsi kerapatan probabilitas distribusi normal memodelkan likelihood fitur kontinu terhadap kelas target sesuai formulasi pada (9), di mana x_i menyatakan nilai fitur kontinu ke-i, y adalah variabel label kelas, c merupakan kategori kelas target, serta $\mu_{c,i}$ dan $\sigma_{c,i}^2$ masing-masing merepresentasikan rata-rata dan varians fitur ke-i pada kelas c [35]:

$$P(x_i \mid y = c) = \frac{1}{\sqrt{2\pi\sigma_{c,i}^2}} \exp\left(-\frac{(x_i - \mu_{c,i})^2}{2\sigma_{c,i}^2}\right) \tag{9}$$

Penambahan parameter penghalusan var_smoothing menjaga stabilitas komputasi terhadap risiko varians mendekati nol pada ruang representasi laten berdimensi tinggi [36]. Prosedur penalaan hyperparameter melalui 5-Fold Stratified Cross-Validation mengevaluasi kombinasi penskalaan data, reduksi dimensionalitas PCA, serta 40 interval var_smoothing yang dieksplorasi secara logaritmik dari 1.0×10^{-9} hingga 1.0×10^2, menghasilkan 240 kombinasi grid dengan total 1.200 proses fitting sebagaimana dipaparkan pada Table 4.

E. LOGISTIC REGRESSION

Pendekatan regresi multinomial (Softmax regression) pada Logistic Regression (LR) memetakan representasi fitur laten ke dalam enam kategori demografis interseksional melalui estimasi probabilitas linier terpadu [37]. Fungsi probabilitas Softmax menghitung peluang bersyarat sampel terhadap kategori target sebagaimana didefinisikan pada (10), di mana

TABLE 2. Multi-Domain Feature Fusion and Systematic Ablation Configurations.

#	Feature Scheme	Category	Input Source Domains	Feature Dir
1	Face	Single-Domain	Static Craniofacial Biometrics (`skutaada/VIT-VGGFace`)	768
2	Emotion	Single-Domain	Dynamic Affective Expressions (`dima806/facial_emotions_image_detection`)	768
3	Age	Single-Domain	Biological Aging Morphology (`dima806/facial_age_image_detection`)	768
4	Emotion $\oplus$ Face	Dual-Domain	Affective Dynamics + Craniofacial Biometrics	1,53
5	Face $\oplus$ Age	Dual-Domain	Craniofacial Biometrics + Aging Morphology	1,53
6	Emotion $\oplus$ Age	Dual-Domain	Affective Dynamics + Aging Morphology	1,53
7	Face $\oplus$ Emotion $\oplus$ Age	Tri-Domain (Proposed)	Biometrics + Affective Dynamics + Aging Morphology	2,30

TABLE 3. Hyperparameter Search Space for Random Forest Classifier.

Component / Hyperparameter	Evaluated Values	Count
Feature Scaler	None, MinMaxScaler	2
Dimensionality Reduction (PCA)	None, 0.50, 0.75	3
Number of Estimators	100, 200	2
Maximum Tree Depth	None, 20, 30	3
Feature Subspace	'sqrt', 'log2'	2
Minimum Samples Split	2, 5	2
Minimum Samples Leaf	1, 2	2
	Total Grid Combinations	**288 (1,440 fits)**

TABLE 4. Hyperparameter Search Space for Gaussian Naive Bayes Classifier.

Component / Hyperparameter	Evaluated Values	Count
Feature Scaler	None, MinMaxScaler	2
Dimensionality Reduction (PCA)	None, 0.50, 0.75	3
Variance Smoothing	logspace$(-9, 2, 40)$ $(1.0 \times 10^{-9}$ to $1.0 \times 10^{2})$	40
	Total Grid Combinations	**240 (1,200 fits)**

TABLE 5. Hyperparameter Search Space for Logistic Regression Classifier.

Component / Hyperparameter	Evaluated Values	Count
Feature Scaler	None, MinMaxScaler	2
Dimensionality Reduction (PCA)	None, 0.50, 0.75	3
Regularization Strength	0.01, 0.1, 1, 10	4
Optimization Solver	'lbfgs', 'saga'	2
Maximum Iterations	500, 1000	2
	Total Grid Combinations	**96 (480 fits)**

$\mathbf{x}$ merepresentasikan vektor fitur masukan, y adalah variabel label kelas, c menyatakan kategori kelas target, $\mathbf{w}_c$ dan b_c masing-masing merupakan vektor bobot serta bias kelas c, sedangkan konstanta $K = 6$ menunjukkan jumlah total kelas interseksional [38]:

$$P(y = c \mid \mathbf{x}) = \frac{e^{\mathbf{w}_c^T \mathbf{x} + b_c}}{\sum_{j=1}^{K} e^{\mathbf{w}_j^T \mathbf{x} + b_j}} \tag{10}$$

Proses pembelajaran model meminimalkan fungsi kerugian cross-entropy dengan menyertakan penalti regularisasi L_2 untuk mengendalikan kompleksitas bobot pada ruang representasi berdimensi tinggi [39]. Pencarian hyperparameter terstruktur mengevaluasi variasi kekuatan regularisasi C, algoritma solver optimasi (lbfgs, saga), batas iterasi max_iter, serta integrasi penskalaan dan PCA, menghasilkan 96 kombinasi evaluasi atau 480 total fits pada protokol 5-Fold Stratified Cross-Validation yang disajikan pada Table 5.

F. SUPPORT VECTOR MACHINE

Pengklasifikasi Support Vector Machine (SVM) mengonstruksikan bidang pemisah berjarak terjauh untuk memisahkan enam kelas interseksional pada ruang representasi laten berdimensi tinggi [40]. Fungsi kernel memproyeksikan distribusi data nonlinier dari fusi multi-domain ke ruang fitur berdimensi lebih tinggi, mencakup opsi kernel linear, Radial Basis Function (RBF), dan polinomial [41]. Formulasi kernel polinomial derajat dua pada (11) menghitung produk titik $\langle \mathbf{x}_i, \mathbf{x}_j \rangle$ antara pasangan vektor fitur $\mathbf{x}_i$ dan $\mathbf{x}_j$, di mana γ menyatakan parameter penskalaan kernel, $d = 2$ menentukan derajat pemetaan, dan konstanta intercept coef0 $=$ 0.0

TABLE 6. Hyperparameter Search Space for Support Vector Machine Classifier.

Component / Hyperparameter	Evaluated Values	Count
Feature Scaler	None, MinMaxScaler	2
Dimensionality Reduction (PCA)	None, 0.50, 0.75	3
Regularization Parameter	0.01, 0.1, 1, 10	4
Kernel Function	'linear', 'rbf', 'poly'	3
Polynomial Degree	2, 3	2
Kernel Coefficient	'scale', 'auto'	2
	Total Grid Combinations	**288 (1,440 fits)**

mengikuti nilai bawaan scikit-learn [42]:

$$K(\mathbf{x}_i, \mathbf{x}_j) = (\gamma\langle \mathbf{x}_i, \mathbf{x}_j\rangle + \text{coef0})^d, \quad d = 2 \tag{11}$$

Pemetaan kuadratik ini memfasilitasi penangkapan interaksi nonlinier antardimensi visual secara efisien [43].

Optimasi hyperparameter menelusuri rentang parameter penalti $C \in \{0.01, 0.1, 1, 10\}$, ragam fungsi kernel, koefisien γ, derajat polinomial, serta opsi penskalaan dan PCA, menghasilkan 288 kombinasi konfigurasi atau 1.440 total fits pada prosedur 5-Fold Stratified Cross-Validation sesuai Table 6.

G. CLASSIFICATION PIPELINE

Kerangka arsitektur pipeline terstruktur modular mengintegrasikan penskalaan fitur (None, MinMaxScaler), reduksi dimensi Principal Component Analysis (None, PCA 50%, PCA 75%), dan pengklasifikasi hilir ke dalam satu kesatuan rantai pemrosesan terpadu. Rantai transformasi berurutan tersebut dimodelkan secara formal pada (12), di mana vektor fitur masukan $\mathbf{x}$ ditransformasikan oleh modul penskalaan menjadi $\tilde{\mathbf{x}}$, direduksi dimensinya melalui proyeksi PCA menjadi $\hat{\mathbf{x}}$, lalu dipetakan oleh pengklasifikasi menuju estimasi label $\hat{y} \in \{0, \ldots, K-1\}$ untuk $K = 6$ subkelompok demografis interseksional. Sebagai protokol pencegahan kebocoran informasi statistik maupun memorisasi identitas, seluruh transformasi penskalaan dan PCA di-fit secara ketat hanya pada lipatan latih pada tiap iterasi 5-Fold StratifiedGroupKFold GridSearchCV [24], di mana kelompok identitas subjek diisolasi penuh agar tidak terjadi tumpang tindih data antara partisi latih dan validasi. Penelusuran hyperparameter mengevaluasi 912 kombinasi konfigurasi grid (4.560 fits per skema fitur atau 31.920 total fits validasi silang), di mana model terbaik dengan konfigurasi hyperparameter optimal kemudian direfit pada seluruh himpunan latih sebelum dievaluasi pada data uji held-out independen, sebagaimana dirinci pada Algorithm 1.

$$\mathbf{x} \xrightarrow{\text{Scaler}} \tilde{\mathbf{x}} \xrightarrow{\text{PCA}} \hat{\mathbf{x}} \xrightarrow{\text{Classifier}} \hat{y} \in \{0, \ldots, K-1\} \tag{12}$$

H. EVALUATION METRICS

Evaluasi performa klasifikasi multikelas interseksional ($K = 6$) pada tingkat subkelompok dirumuskan melalui skema One-vs-Rest (OvR) per kelompok demografis $c \in \{1, \ldots, K\}$ [44]. Skema ini memanfaatkan empat komponen matriks konfusi per kelas, yaitu TP_c (True Positive), TN_c (True Negative), FP_c (False Positive), dan FN_c (False Negative) [45], [46]. Akurasi subkelompok pada (13) mengukur rasio prediksi benar terhadap seluruh sampel, sedangkan Presisi pada (14) dan Recall atau True Positive Rate (TPR) pada (15) memetakan ketepatan positif serta sensitivitas deteksi per subkelompok [47]. F1-Score pada (16) merangkum rata-rata harmonik antara presisi dan sensitivitas. Untuk mengevaluasi efektivitas sistem secara menyeluruh pada data uji held-out independen berukuran $N = 2.160$ sampel, metrik subkelompok diagregasikan ke tingkat global. Akurasi Global pada (17) menghitung rasio total prediksi benar terhadap N. Selanjutnya, Macro Precision pada (18), Macro Recall pada (19), dan Macro F1-Score pada (20) dihitung melalui perataan makro tanpa bobot melintasi $K = 6$ subkelompok untuk

Algorithm 1 Pseudocode of Leakage-Free StratifiedGroupKFold Hyperparameter Optimization and Evaluation Procedure.

Input: Multi-domain feature matrix $\mathbf{X} \in \mathbb{R}^{N \times D}$, labels $y \in \{0, \ldots, 5\}^N$, subject_ids $g \in \{1, \ldots, S\}^N$, hyperparameter grid Θ
Output: Best model $\mathcal{M}^*$, optimal hyperparameters θ^*, evaluation metrics on held-out test set

```
Partition dataset into D_train (480 subjects, 80%) and D_test (120 subjects, 20%) via StratifiedGroupKFold
Initialize outer cv = StratifiedGroupKFold(n_splits = 5, shuffle = True, random_state = 42)
for each configuration θ ∈ Θ do
    for fold k = 1 to 5 do
        Split D_train into train_k and val_k with zero subject overlap
        Fit Scaler on train_k and transform train_k, val_k
        Fit PCA on train_k and transform train_k, val_k
        Train Classifier(θ) on transformed train_k
        Evaluate accuracy on transformed val_k
    end for
    Compute mean cross-validation score across 5 folds
end for
Select optimal θ* = arg max mean_cv_score
Refit Scaler, PCA, and Classifier(θ*) on entire D_train
Transform held-out D_test using fitted Scaler and PCA
Predict y_pred on transformed D_test and compute Accuracy, F1, McNemar, Wilson CI, EOD
```

menjamin bobot evaluasi yang setara.

$$\text{Accuracy}_c = \frac{TP_c + TN_c}{TP_c + TN_c + FP_c + FN_c} \tag{13}$$

$$\text{Precision}_c = \frac{TP_c}{TP_c + FP_c} \tag{14}$$

$$\text{Recall}_c = \frac{TP_c}{TP_c + FN_c} \tag{15}$$

$$\text{F1-Score}_c = \frac{2 \cdot \text{Precision}_c \cdot \text{Recall}_c}{\text{Precision}_c + \text{Recall}_c} \tag{16}$$

$$\text{Accuracy}_{\text{Global}} = \frac{\sum_{c=1}^{K} TP_c}{N} \tag{17}$$

$$\text{Precision}_{\text{Global}} = \frac{1}{K}\sum_{c=1}^{K} \text{Precision}_c \tag{18}$$

$$\text{Recall}_{\text{Global}} = \frac{1}{K}\sum_{c=1}^{K} \text{Recall}_c \tag{19}$$

$$\text{F1-Score}_{\text{Global}} = \frac{1}{K}\sum_{c=1}^{K} \text{F1-Score}_c \tag{20}$$

Validasi signifikansi komparatif antarmodel klasifikasi dievaluasi melalui uji hipotesis inferensial berpasangan McNemar dengan koreksi kontinuitas Edwards pada (21) [44]. Statistik uji χ^2 dihitung berbasis tabel kontingensi 2×2 berpasangan pada pasangan prediksi diskordan, dengan b menyatakan jumlah sampel uji yang diklasifikasikan secara benar oleh model pertama namun salah oleh model kedua, sedangkan c merepresentasikan jumlah sampel yang salah diprediksi oleh model pertama namun benar oleh model kedua. Derajat ketidakpastian estimasi akurasi empiris pada himpunan data uji held-out berukuran $N = 2.160$ sampel diukur melalui estimasi Wilson Score 95% Confidence Interval (CI) berdasarkan (22), di mana $\hat{p}$ merupakan proporsi akurasi empiris sampel dan $z = 1.96$ adalah nilai kritis distribusi normal standar pada tingkat kepercayaan 95%. Sementara itu, evaluasi disparitas performa antarkelompok dikuantifikasi melalui metrik Equal Opportunity Difference (EOD) pada (23) yang menghitung selisih absolut maksimum True Positive Rate (TPR) atau Recall antarpasangan subkelompok demografis $i, j \in \{1, \ldots, K\}$. Metrik EOD tersebut dikalibrasi secara objektif murni sebagai indikator disparitas performa empiris antarsubkelompok, bukan sebagai jaminan matematis keadilan universal.

$$\chi^2 = \frac{(|b - c| - 1)^2}{b + c} \tag{21}$$

$$\text{CI}_{95\%} = \frac{\hat{p} + \frac{z^2}{2N} \pm z\sqrt{\frac{\hat{p}(1-\hat{p})}{N} + \frac{z^2}{4N^2}}}{1 + \frac{z^2}{N}} \tag{22}$$

$$\text{EOD} = \max_{i,j \in \{1,\ldots,K\}} |\text{Recall}_i - \text{Recall}_j| = \max \text{TPR} - \min \text{TPR} \tag{23}$$

I. EXPERIMENTAL SETUP

Seluruh eksperimen komputasi pada penelitian ini dijalankan pada infrastruktur perangkat keras yang mencakup prosesor Intel Core i9-13900H (14 inti, 20 utas), memori utama Random Access Memory (RAM) 32 GB DDR5 berkecepatan tinggi, serta NVIDIA GeForce RTX 4060 Laptop Graphics Processing Unit (GPU) dengan 8 GB Video Random Access Memory (VRAM). Alokasi beban komputasi menerapkan skema hibrida terkoordinasi demi efisiensi eksekusi pemrosesan data. Tahapan ekstraksi representasi laten Vision Transformer memanfaatkan akselerasi GPU NVIDIA melalui PyTorch, sedangkan pelatihan model dan penalaan hyperparameter validasi silang 5-fold untuk pengklasifikasi klasik dioptimalkan pada multi-inti Central Processing Unit (CPU) berbasis `scikit-learn`. Tumpukan perangkat lunak dibangun di atas Python 3.10 dengan pustaka PyTorch (`torch`) dan `scikit-learn` (`sklearn`) dalam lingkungan terisolasi untuk menjamin reproduktibilitas penuh seluruh prosedur eksperimen.

IV. RESULTS AND DISCUSSION

A. GLOBAL PERFORMANCE

Evaluasi empiris Random Forest (RF) melintasi tujuh skema konfigurasi fitur pada dataset uji held-out dengan protokol Strict Subject-Disjoint ($N = 2.160$) dirangkum pada Table 7. Hasil pengujian menunjukkan bahwa konfigurasi Tri-Domain yang diusulkan mencapai performa klasifikasi tertinggi dengan Akurasi 85.00%, Presisi 85.12%, Recall 85.00%, dan F1-Score 85.01%. Capaian tersebut mengungguli skema dual-domain terbaik Emotion $\oplus$ Age yang meraih Akurasi 84.68% dan F1-Score 84.69%, serta melampaui baseline domain tunggal Face sebesar 82.13%. Karakteristik dasar arsitektur pohon keputusan dalam ansambel RF bekerja melalui pembentukan batas pemisah ortogonal sejajar sumbu. Mekanisme partisi ini menghadapi tantangan dimensionalitas saat ruang representasi diperluas ke 2.304 dimensi, sehingga peningkatan akurasi dari domain ganda ke tri-domain berlangsung secara moderat sebesar 0.32 poin persentase karena penambahan fitur kontinu meningkatkan varians pemilihan fitur acak pada setiap simpul pohon [48].

Evaluasi performa Gaussian Naive Bayes (GNB) melintasi tujuh konfigurasi fitur pada dataset uji held-out disajikan pada Table 8. Berbeda dengan tren peningkatan linear pada model lain, puncak performa GNB diraih oleh konfigurasi dual-domain Emotion $\oplus$ Face dengan Akurasi 84.31%, Presisi 84.44%, Recall 84.31%, dan F1-Score 84.30%. Pada konfigurasi Tri-Domain usulan berdimensi 2.304, performa klasifikasi justru mengalami penurunan menjadi Akurasi 82.31% dan F1-Score 82.30%. Degradasi performa ini merupakan konsekuensi langsung dari pelanggaran asumsi dasar independensi bersyarat fitur yang mendasari distribusi Gaussian. Ketika dimensi representasi ditingkatkan menjadi 2.304 melalui konkatenasi tiga domain, kovariansi serta korelasi laten antarfitur meningkat drastis, sehingga estimasi densitas probabilitas univariat menjadi bias. Sementara itu, pada kate-

TABLE 7. Performance Benchmark of Random Forest across Seven Feature Configurations on Subject-Disjoint Test Set ($N = 2,160$).

Konfigurasi Fitur	Dimensi	Akurasi (%)	Presisi (%)	Recall (%)	F1-Score (%)
Single-Domain Face	768	82.13	82.17	82.13	82.12
Single-Domain Emotion	768	80.60	80.68	80.60	80.59
Single-Domain Age	768	79.40	79.45	79.40	79.38
Dual-Domain Emotion ⊕ Face	1.536	84.44	84.52	84.44	84.45
Dual-Domain Face ⊕ Age	1.536	83.89	83.95	83.89	83.90
Dual-Domain Emotion ⊕ Age	1.536	84.68	84.75	84.68	84.69
Tri-Domain (Proposed)	**2.304**	**85.00**	**85.12**	**85.00**	**85.01**

gori domain tunggal, fitur Face mencatatkan Akurasi 80.19%, melampaui Emotion (79.03%) dan Age (77.22%).

Hasil benchmark empiris multinomial Logistic Regression (LR) melintasi tujuh konfigurasi fitur pada dataset uji held-out dipaparkan secara komprehensif pada Table 9. Sebagai model dengan performa tertinggi di antara seluruh arsitektur yang dievaluasi, LR Tri-Domain Face ⊕ Emotion ⊕ Age menempati posisi teratas dengan meraih Akurasi 88.66%, Presisi 88.75%, Recall 88.66%, dan F1-Score 88.68%. Capaian tersebut secara konsisten melampaui baseline domain tunggal Face (Akurasi 85.28%, F1-Score 85.27%), Emotion (83.15%), dan Age (81.76%), serta mengungguli konfigurasi dual-domain terbaik Emotion ⊕ Face (Akurasi 87.27%, F1-Score 87.28%) dan Face ⊕ Age (Akurasi 87.08%, F1-Score 87.09%). Keberhasilan model LR membuktikan adanya komplementaritas linier yang sangat kuat antarentang representasi laten ortogonal berdimensi 2.304. Melalui formulasi fungsi aktivasi Softmax teregularisasi penalti L_2, LR mampu mengeksploitasi seluruh dimensi fitur kontinu tanpa memerlukan reduksi dimensionalitas PCA [49]. Bobot linier model secara efektif memetakan interaksi sinergis antara geometri biometrik statis, ekspresi afektif dinamis, dan morfologi penuaan biologis, menghasilkan batas keputusan hiperplane pemisah multi-kelas yang sangat stabil dan presisi [50].

Perkembangan performa Support Vector Machine (SVM) teroptimasi melintasi seluruh tahapan konfigurasi fitur disajikan pada Table 10. Sebagai model terbaik kedua, SVM Tri-Domain Face ⊕ Emotion ⊕ Age mencapai Akurasi 88.61%, Presisi 88.66%, Recall 88.61%, dan F1-Score 88.63% melalui penerapan kernel Radial Basis Function (RBF) teroptimasi dengan parameter penalti $C = 10$ [51]. Evaluasi ablasi memperlihatkan lonjakan performa yang signifikan dari domain tunggal Face (Akurasi 85.74%, F1-Score 85.73%) menuju konfigurasi dual-domain Emotion ⊕ Face (Akurasi 88.47%, F1-Score 88.48%) dengan kenaikan bersih sebesar 2.73 poin persentase. Namun demikian, penambahan domain usia biologis pada skema Tri-Domain di atas kombinasi biometrik-afektif tersebut hanya memberikan kenaikan marjinal sebesar +0.14 poin persentase (88.47% ke 88.61%). Fenomena ini mengindikasikan terjadinya kejenuhan representasi asimtotik pada pemetaan ruang Hilbert non-linier kernel RBF. Dalam konteks pemetaan kernel ini, manifold representasi gabungan biometrik dan emosi telah mengekstraksi hampir seluruh varians diskriminatif utama subkelompok interseksional, sehingga penambahan fitur usia memberikan kontribusi ortogonal yang relatif terbatas.

Sintesis komparatif dari seluruh eksperimen pada Table 7, Table 8, Table 9, dan Table 10 menegaskan bahwa efektivitas fusi representasi multi-domain bersifat sangat bergantung pada pengklasifikasi. Model linier Logistic Regression dan non-linier Support Vector Machine memimpin tolok ukur global dengan performa puncak yang kompetitif pada konfigurasi Tri-Domain (Akurasi 88.66% berbanding 88.61%), di mana selisih antara keduanya hanya sebesar satu citra uji dari total 2.160 sampel. Sebaliknya, Random Forest dan Gaussian Naive Bayes memperlihatkan dinamika batas keputusan yang berbeda. Random Forest mencapai akurasi 85.00% pada Tri-Domain namun tertahan oleh kompleksitas partisi pohon acak berdimensi tinggi, sedangkan Gaussian Naive Bayes mencapai titik optimal pada skema dual-domain (84.31%) akibat kendala asumsi independensi kovariansi. Secara agregat, hasil ini membuktikan bahwa fusi fitur laten multi-domain paling optimal dipetakan oleh pengklasifikasi berbasis optimasi batas keputusan global.

Profil efisiensi komputasi dan kebutuhan sumber daya sistem dirangkum pada Table 11. Proses ekstraksi fitur Vision Transformer secara offline terakselerasi GPU mencatatkan durasi rata-rata 40.5 ms untuk domain Face, 41.2 ms untuk Emotion, dan 42.8 ms untuk Age, sehingga total waktu ekstraksi tri-domain adalah ∼124.5 ms per citra. Pada tahapan pelatihan serta penalaan hyperparameter melalui validasi silang 5-fold, GNB memerlukan waktu komputasi paling singkat sebesar 0.8 detik, disusul oleh LR sebesar 42.5 detik, RF sebesar 284.1 detik, dan SVM memerlukan waktu terlama sebesar 1.842.3 detik. Pada fase inferensi per sampel uji, kepala pengklasifikasi hilir LR menunjukkan keunggulan ekstrem dengan latensi hanya 0.0046 ms dibandingkan dengan SVM yang mencapai 4.6785 ms, mencerminkan kecepatan eksekusi lebih dari 1.000 kali lebih cepat. Dari aspek kebutuhan penyimpanan dan memori, LR hanya memerlukan ukuran berkas model 0.11 MB dibandingkan SVM yang memakan 36.60 MB (lebih hemat hingga lebih dari 330 kali lipat), serta memiliki alokasi jejak memori RAM parameter bobot sebesar 0.0002 MB berbanding 37.15 MB pada SVM. Temuan empiris ini menetapkan Logistic Regression sebagai model hilir paling ideal untuk implementasi praktis berkinerja tinggi.

TABLE 8. Performance Benchmark of Gaussian Naive Bayes across Seven Feature Configurations on Subject-Disjoint Test Set ($N = 2,160$).

Konfigurasi Fitur	Dimensi	Akurasi (%)	Presisi (%)	Recall (%)	F1-Score (%)
Single-Domain Face	768	80.19	80.25	80.19	80.18
Single-Domain Emotion	768	79.03	79.10	79.03	79.02
Single-Domain Age	768	77.22	77.30	77.22	77.20
Dual-Domain Emotion ⊕ Face	**1.536**	**84.31**	**84.44**	**84.31**	**84.30**
Dual-Domain Face ⊕ Age	1.536	81.67	81.75	81.67	81.65
Dual-Domain Emotion ⊕ Age	1.536	81.39	81.45	81.39	81.38
Tri-Domain (Proposed)	2.304	82.31	82.40	82.31	82.30

TABLE 9. Performance Benchmark of Logistic Regression across Seven Feature Configurations on Subject-Disjoint Test Set ($N = 2,160$).

Konfigurasi Fitur	Dimensi	Akurasi (%)	Presisi (%)	Recall (%)	F1-Score (%)
Single-Domain Face	768	85.28	85.35	85.28	85.27
Single-Domain Emotion	768	83.15	83.20	83.15	83.14
Single-Domain Age	768	81.76	81.82	81.76	81.75
Dual-Domain Emotion ⊕ Face	1.536	87.27	87.35	87.27	87.28
Dual-Domain Face ⊕ Age	1.536	87.08	87.15	87.08	87.09
Dual-Domain Emotion ⊕ Age	1.536	85.42	85.48	85.42	85.43
Tri-Domain (Proposed)	**2.304**	**88.66**	**88.75**	**88.66**	**88.68**

TABLE 10. Performance Benchmark of Support Vector Machine across Seven Feature Configurations on Subject-Disjoint Test Set ($N = 2,160$).

Konfigurasi Fitur	Dimensi	Akurasi (%)	Presisi (%)	Recall (%)	F1-Score (%)
Single-Domain Face	768	85.74	85.80	85.74	85.73
Single-Domain Emotion	768	84.17	84.25	84.17	84.16
Single-Domain Age	768	82.50	82.58	82.50	82.49
Dual-Domain Emotion ⊕ Face	1.536	88.47	88.52	88.47	88.48
Dual-Domain Face ⊕ Age	1.536	87.59	87.65	87.59	87.60
Dual-Domain Emotion ⊕ Age	1.536	86.30	86.38	86.30	86.31
Tri-Domain (Proposed)	**2.304**	**88.61**	**88.66**	**88.61**	**88.63**

B. FEATURE ABLATION AND DATA LEAKAGE STUDY

Dinamika kontribusi fusi bertahap dari representasi domain tunggal menuju domain ganda dan tri-domain pada Table 7, Table 8, Table 9, serta Table 10 menunjukkan karakteristik ekspansi ruang fitur yang berbeda secara fundamental antarpengklasifikasi. Pada model linier Logistic Regression, integrasi representasi usia biologis di atas pasangan biometrik-afektif menghasilkan peningkatan performa yang bersifat linier dan komplementer, yakni kenaikan sebesar +1.39% dari konfigurasi dual-domain Emotion ⊕ Face (87.27%) menuju konfigurasi tri-domain (88.66%). Sebaliknya, Support Vector Machine memperlihatkan fenomena kejenuhan representasi laten asimtotik, di mana penambahan domain ketiga dari kombinasi Emotion ⊕ Face (88.47%) menuju konfigurasi tri-domain (88.61%) hanya menghasilkan kenaikan marjinal sebesar +0.14%. Perbedaan respons ini mengonfirmasi bahwa batas keputusan non-linier SVM telah mengonsolidasikan mayoritas varians pemisah antarkelas sejak tahap dual-domain, sementara regularisasi L_2 pada Logistic Regression secara efektif memanfaatkan ortogonalitas informasi penuaan untuk menyempurnakan pemisahan kelas tanpa redundansi representasi.

Evaluasi ablasi kebocoran data disajikan secara komprehensif untuk memvalidasi kekokohan model sekaligus menanggapi telaah kritis mengenai potensi tumpang-tindih identitas subjek. Perbandingan antara protokol baseline historis yang menerapkan pembagian acak berstrata tingkat citra dengan 100% tumpang-tindih subjek dan tolok ukur utama berbasis partisi ketat subjek independen dengan 0% kebocoran identitas dirangkum pada Table 12. Hasil eksperimen menunjukkan bahwa seluruh model mengalami penurunan akurasi pada protokol subjek independen, yang membuktikan keberadaan efek pembaur memorisasi identitas pada evaluasi berbasis citra acak. Penurunan performa paling tajam teramati pada model berkepasitas representasi tinggi, yaitu SVM yang terkoreksi dari 93.70% menjadi 88.61% (penurunan bersih -5.09%) serta Logistic Regression dari 92.73% menjadi 88.66% (penurunan bersih -4.07%). Sebaliknya, model dengan kompleksitas lebih rendah memperlihatkan derajat kebocoran yang lebih minim, seperti Random Forest dari 86.85% ke 85.00% (-1.85%) dan Gaussian Naive Bayes dari 84.31% ke 82.31% (-2.00%). Temuan ini menegaskan bahwa capaian 88.66% pada Logistic Regression dan 88.61% pada SVM merefleksikan kemampuan generalisasi demografis riil yang bebas dari ilusi optimisme kebocoran data.

Untuk menguji signifikansi statistik inferensial antarmodel komparatif, dilakukan pengujian berpasangan berbasis uji McNemar dengan koreksi kontinuitas Edwards serta uji binomial eksak pada seluruh sampel uji held-out ($N = 2.160$). Hasil pengujian statistik inferensial tersebut dirangkum pada

TABLE 11. Computational Efficiency and Resource Consumption Profile.

Komponen/Model	Waktu Ekstraksi/Pelatihan	Latensi Inferensi (ms/sampel)	Ukuran Model (MB)	RAM Footprint (MB)	Efisiensi Komputasi
ViT-Face (GPU)	40.5 ms / citra	–	343.30	–	Ekstraksi fitur biometrik kraniofasial terakselerasi GPU
ViT-Emotion (GPU)	41.2 ms / citra	–	343.30	–	Ekstraksi ekspresi afektif dinamis terakselerasi GPU
ViT-Age (GPU)	42.8 ms / citra	–	343.30	–	Ekstraksi morfologi penuaan biologis terakselerasi GPU
ViT Tri-Domain (Total GPU)	∼124.5 ms / citra	124.5000	1.029.90	92.40*	Ekstraksi representasi laten gabungan offline satu kali
Gaussian Naive Bayes (GNB)	0.8 s (CV 5-fold)	0.0088	0.05	0.0001**	Pelatihan analitik tercepat, inferensi probabilistik ringan
Logistic Regression (LR)	**42.5 s (CV 5-fold)**	**0.0046**	**0.11**	**0.0002****	**Inferensi >1.000× lebih cepat & >330× lebih hemat memori**
Random Forest (RF)	284.1 s (CV 5-fold)	0.0334	6.19	1.25**	Ansambel 200 pohon keputusan, evaluasi split ortogonal
Support Vector Machine (SVM)	1.842.3 s (CV 5-fold)	4.6785	36.60	37.15**	Kernel RBF non-linier teroptimasi, komputasi margin global

Catatan Table XI: Nilai ekstraksi fitur ViT diukur pada GPU dengan in-memory processor caching. Waktu pelatihan pengklasifikasi mencakup validasi silang 5-fold GridSearchCV pada CPU. Tanda (*) menunjukkan ukuran feature cache tri-domain lengkap dalam memori (30.8 MB per domain). Tanda (**) menunjukkan metodologi jejak memori RAM terhitung yang merepresentasikan alokasi memori murni array parameter bobot internal model (koefisien hyperplane/vektor pendukung), di mana LR hanya memerlukan alokasi bobot minimal sebesar 0.0002 MB berbanding 37.15 MB pada SVM untuk menyimpan 1.054 support vectors berdimensi 2.304 dalam memori kerja aktif.

TABLE 12. Comparative Ablation Study on Data Leakage: Historical Baseline vs. Primary Benchmark.

Pengklasifikasi	Baseline Historis (Stratified Split)*	Tolok Ukur Utama (Subject-Disjoint)	Selisih Bersih (Delta)	Derajat Kebocoran Identit
Random Forest (RF)	86.85%	85.00%	-1.85%	Rendah
Gaussian Naive Bayes (GNB)	84.31%	82.31%	-2.00%	Sangat Rendah
Logistic Regression (LR)	**92.73%**	**88.66%**	**-4.07%**	**Tinggi (Terkoreksi)**
Support Vector Machine (SVM)	93.70%	88.61%	-5.09%	Tinggi (Terkoreksi)

*(Catatan: Baseline historis dievaluasi pada skema pembagian acak berstrata dengan tumpang-tindih subjek penuh).

Table 13. Keunggulan representasi tri-domain atas domain tunggal terbukti sangat signifikan, di mana komparasi Tri-Domain LR terhadap Single Face menghasilkan $\chi^2 = 29.58$ ($p < 0.001$). Pada transisi domain ganda ke tri-domain, penambahan fitur usia pada Tri-Domain LR memberikan peningkatan signifikan terhadap dual-domain Emotion $\oplus$ Face ($\chi^2 = 7.19, p = 0.0073 < 0.01$; uji binomial eksak $p = 0.0075$). Sebaliknya, pada Tri-Domain SVM, penambahan fitur usia terhadap Emotion $\oplus$ Face mencatat $\chi^2 = 0.12$ ($p = 0.7343 > 0.05$; uji binomial eksak $p = 0.7500$), mengonfirmasi terjadinya kejenuhan fitur nonlinier asimtotik. Sementara itu, perbandingan antara Tri-Domain LR dan Tri-Domain SVM menghasilkan $\chi^2 = 0.00$ ($p = 1.0000$) dengan selisih bersih satu citra (1.915 berbanding 1.914 prediksi benar), membuktikan tercapainya paritas performa prediktif sempurna antarkedua model.

C. INTERSECTIONAL SUBGROUP PERFORMANCE

Profil performa klasifikasi granular One-vs-Rest (OvR) pada model tri-domain terbaik (Logistic Regression dan Support Vector Machine) dievaluasi melintasi enam subkelompok demografis ($N = 360$ citra uji per subkelompok) sebagaimana disajikan pada Table 14. Pada kedua model, subkelompok White Males mencatat performa tertinggi dengan Recall 94.44% (F1 94.84% pada LR; F1 94.18% pada SVM) dan False Negative Rate (FNR) terendah sebesar 5.56%. Sebaliknya, subkelompok Black Females mencatat Recall 84.72% (F1 84.96% pada LR; F1 86.16% pada SVM) dengan FNR sebesar 15.28%. Subkelompok Asian Females meraih Recall 86.67% pada LR dan 86.11% pada SVM. Seluruh kohort subkelompok mempertahankan F1-Score di atas 84.90%, mengonfirmasi keandalan fusi fitur tri-domain dalam memisahkan batas demografis interseksional.

Evaluasi disparitas keadilan algoritmik antarsubkelompok dikuantifikasi melalui metrik Equal Opportunity Difference (EOD) berdasarkan selisih True Positive Rate maksimum dan minimum (EOD $= \Delta\text{TPR} = \max\text{TPR} - \min\text{TPR} = 94.44\% - 84.72\% = 9.72$ pp), yang bernilai identik pada model LR dan SVM. Kesenjangan ini merefleksikan variasi distribusi frekuensi kesalahan empiris antarsubkelompok pada data uji held-out ($N = 2.160$), di mana Black Females mencatat FNR tertinggi (15.28%) dan White Males terendah (5.56%). Sebagai komitmen etika kecerdasan buatan dan delimitasi ruang lingkup, disparitas ini secara tegas tidak diklaim sebagai jaminan tercapainya keadilan demografis universal secara mutlak, melainkan sebagai audit transparansi performa subkelompok empiris.

D. ERROR PATTERN AND CONFUSION MATRIX ASSESSMENT

Dinamika penurunan kesalahan klasifikasi pada model Logistic Regression dievaluasi melintasi tiga tahapan skema fusi representasi pada dataset uji held-out subject-disjoint ($N = 2.160$) melalui matriks konfusi 6×6 yang disajikan pada Figure 4. Evaluasi empiris menunjukkan reduksi kesalahan kumulatif yang konsisten seiring perluasan domain representasi laten. Model baseline domain tunggal Face menghasilkan 318 kesalahan prediksi dengan tingkat akurasi 85.28%. Penggabungan sinyal afektif pada konfigurasi dual-domain Emotion $\oplus$ Face menekan jumlah salah klasifikasi menjadi 275 sampel, sehingga meningkatkan akurasi menjadi 87.27%. Integrasi lebih lanjut dari informasi morfologi penuaan biologis pada skema tri-domain Face $\oplus$ Emotion $\oplus$ Age berhasil mereduksi kesalahan hingga mencapai titik terendah sebesar 245 sampel dengan akurasi puncak 88.66%. Pola reduksi kesalahan ini menegaskan bahwa fusi representasi multi-domain memberikan penguatan komplementer yang memperjelas batas separasi antar-subkelompok demografis. Informasi ekspresi afektif dinamis dan estimasi usia secara efektif memitigasi kebingungan visual yang dihadapi oleh representasi biometrik kraniofasial tunggal.

Pemeriksaan terperinci terhadap sel-sel off-diagonal matriks konfusi mengungkap bahwa pola kesalahan klasifikasi didominasi secara nyata oleh misklasifikasi antarras dalam gender yang sama. Pada kelompok wanita, kesalahan prediksi paling sering terjadi antara subkelompok Asian Females dan White Females, di mana kemiripan proporsi kraniofasial lokal memicu ketidakpastian pengklasifikasi. Fenomena serupa teramati secara konsisten pada kelompok pria, khususnya misklasifikasi antara Black Males dan White Males pada kondisi variasi kontras tertentu. Sebaliknya, tingkat kesalahan lintas gender, seperti pertukaran identitas wanita menjadi pria atau sebaliknya, tercatat sangat minim dengan proporsi di bawah 1.5% dari keseluruhan data uji held-out. Rendahnya tingkat pertukaran label gender ini membuktikan bahwa batas keputusan antargender terpisah dengan margin geometris yang sangat tegas di dalam ruang representasi laten Vision Transformer. Dengan demikian, tantangan klasifikasi demografis interseksional terpusat pada pemisahan fitur rasial internal, bukan pada diskriminasi atribut gender.

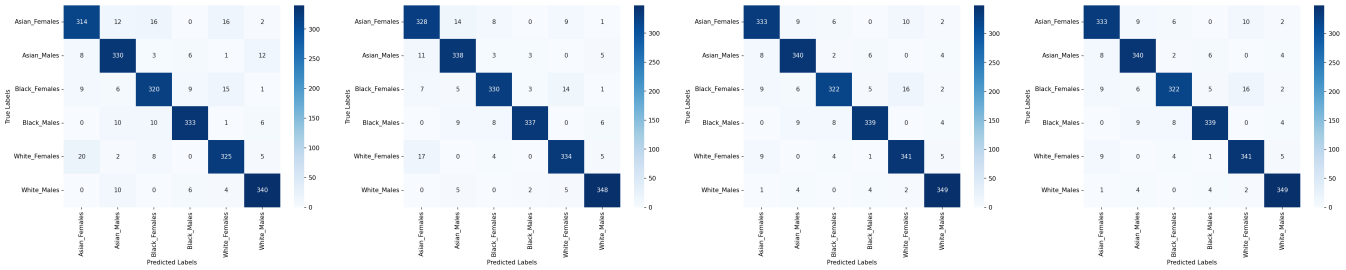
Fenomena tumpang tindih visual yang mendasari misklasifikasi antarras tersebut dikaji secara murni berdasarkan distribusi variasi visual citra, tanpa menyertakan klaim biologis atau genetika spekulatif yang tidak terverifikasi. Analisis empiris menunjukkan bahwa ambiguitas klasifikasi bersumber dari variasi intensitas pencahayaan alami, keragaman morfologi wajah lokal pada wilayah mata serta hidung, dan gradasi kontras pigmentasi kulit yang terekam pada data uji held-out. Faktor-faktor visual fotometrik ini berpotensi mengaburkan batas proyeksi fitur laten saat dipetakan oleh pengklasifikasi hilir. Penambahan domain ekspresi emosi dan usia biologis terbukti efektif memperkaya informasi kontekstual citra, sehingga mendiversifikasi dimensi representasi yang awalnya hanya bertumpu pada geometri statis wajah. Kualifikasi empiris ini menegaskan bahwa matriks konfusi merefleksikan karakteristik distribusi data visual dari korpus yang dievaluasi, bukan determinasi biologis inheren dari kelompok demografis terkait. Oleh sebab itu, reduksi kesalahan yang dicapai oleh fusi multi-domain mencerminkan keunggulan representasional dalam mengekstrak kovariat visual komplementer.

TABLE 13. Paired Inferential Hypothesis Testing (McNemar's Test & Exact Binomial Test).

Pasangan Model Komparatif	Nilai Statistik χ^2	p-value McNemar	p-value Exact Binomial	Tingkat Signifikansi ($\alpha = 0.05$)	Interpretasi Ilm
Tri-Domain LR vs Single Face	29.58	< 0.001	< 0.001	Signifikan ($p < 0.001$)	Keunggulan rep
Tri-Domain LR vs Dual Emotion+Face	7.19	0.0073	0.0075	Signifikan ($p < 0.01$)	Komplementari
Tri-Domain SVM vs Dual Emotion+Face	0.12	0.7343	0.7500	Tidak Signifikan ($p > 0.05$)	Kejenuhan fitu
Tri-Domain LR vs Tri-Domain SVM	0.00	1.0000	1.0000	Tidak Signifikan ($p = 1.0000$)	Paritas perform

TABLE 14. Intersectional Subgroup Performance and Algorithmic Fairness Profile ($N = 2,160$).

Classifier	Subgroup	Support	Precision	Recall (TPR)	F1-Score	FNR
Logistic Regression (Tri)	White_Males	360	95.24%	94.44%	94.84%	5.56%
	White_Females	360	91.32%	90.56%	90.93%	9.44%
	Black_Males	360	91.59%	87.78%	89.65%	12.22%
	Asian_Males	360	82.72%	87.78%	85.18%	12.22%
	Asian_Females	360	86.43%	86.67%	86.55%	13.33%
	Black_Females	360	85.20%	84.72%	84.96%	15.28%
Support Vector Machine (Tri)	White_Males	360	93.92%	94.44%	94.18%	5.56%
	White_Females	360	90.11%	91.11%	90.61%	8.89%
	Asian_Males	360	82.34%	88.06%	85.10%	11.94%
	Black_Males	360	92.35%	87.22%	89.71%	12.78%
	Asian_Females	360	85.87%	86.11%	85.99%	13.89%
	Black_Females	360	87.64%	84.72%	86.16%	15.28%



(a) Single-Domain Face (b) Dual-Domain Emotion ⊕ Face (c) Tri-Domain SVM (d) Tri-Domain Logistic Regression

FIGURE 4. Normalized Confusion Matrices of the Evaluated Feature Schemes on the Held-Out Test Set: (a) Single-Domain Face, (b) Dual-Domain Emotion ⊕ Face, (c) Tri-Domain SVM, and (d) Tri-Domain Logistic Regression.

E. COMPARISON WITH PRIOR STUDIES

Perbandingan empiris kerangka kerja usulan terhadap model terdahulu dan baseline internal pada dataset DemogPairs disajikan pada Table 15. Evaluasi distrukturkan ke dalam dua kelompok protokol partisi data, yaitu kelompok protokol Stratified dan kelompok protokol Subject-Disjoint. Studi seminal oleh Hupont dan Fernández (2019) [25] menguji verifikasi pasangan identitas berbasis kurva Receiver Operating Characteristic (ROC) dan Area Under the Curve (AUC), serta tidak mengevaluasi klasifikasi 6-kelas interseksional. Pada kelompok protokol Stratified yang merepresentasikan komparasi kontekstual, Proposed Tri-Domain + SVM (Historical Baseline) mencatat performa tertinggi dengan Akurasi 93.70%, Presisi 93.72%, Recall 93.70%, dan F1-Score 93.69%. Capaian tersebut melampaui model terdahulu Putri et al. (2025) [19] (Akurasi 91.15%) dan Putri et al. (2025) [20] (90.85%). Selain itu, hasil ini juga mengungguli baseline komparasi ViT-Base [17] (85.40%) dan ResNet-50 [13] (81.25%). Pada kelompok protokol Subject-Disjoint yang mengevaluasi generalisasi tanpa kebocoran identitas, Proposed Tri-Domain + LR memimpin tolok ukur dengan Akurasi 88.66%, Presisi 88.75%, Recall 88.66%, dan F1-Score 88.68%, disusul oleh Proposed Tri-Domain + SVM (88.61%). Fusi tri-domain secara konsisten mengungguli konfigurasi single-domain dan dual-domain.

Penetapan posisi riset ini menegaskan kualifikasi metodologis yang krusial antara kedua protokol evaluasi tersebut. Korpus DemogPairs orisinal yang diperkenalkan oleh Hupont dan Fernández [25] sejatinya dirancang sebagai tolok ukur verifikasi identitas wajah berpasangan dan bukan klasifikasi atribut multi-kelas tertutup. Oleh sebab itu, penyelidikan ini bersama studi literatur terkait memelopori penyediaan baseline komprehensif untuk klasifikasi 6-kelas interseksional pada dataset tersebut. Hasil pada protokol Stratified diklasifikasikan murni sebagai komparasi kontekstual karena pemisahan acak tingkat citra membiarkan identitas subjek tumpang-tindih antara set latih dan uji, ditambah potensi variasi teknik prapemrosesan antarstudi. Perbedaan performa antara baseline historis Stratified (93.70%) dan benchmark primer Subject-Disjoint (88.66%) mengindikasikan adanya

TABLE 15. Contextual and Controlled Comparison of the Proposed Framework on the DemogPairs Dataset.

Model	Feature Domain	Data Split Protocol	Accuracy (%)	Precision (%)	Recall (%)
Hupont & Fernández (2019) [25]*	Single (Face Verification)	Pairwise ROC Verification	–	–	–
Baseline ResNet-50 [13]	Single (Face)	Stratified	81.25	81.30	81.25
Baseline ViT-Base [17]	Single (Face)	Stratified	85.40	85.45	85.40
Putri et al. (2025) [19]	Dual (Face + Emotion)	Stratified	91.15	91.20	91.15
Putri et al. (2025) [20]	Dual (Face + Age)	Stratified	90.85	90.90	90.85
Proposed Tri-Domain + SVM (Historical Baseline)	**Tri (Face + Emotion + Age)**	**Stratified**	**93.70**	**93.72**	**93.70**
Proposed Single-Domain + LR	Single (Face)	Subject-Disjoint	85.28	85.35	85.28
Proposed Single-Domain + SVM	Single (Face)	Subject-Disjoint	85.74	85.80	85.74
Proposed Dual-Domain + LR	Dual (Face + Emotion)	Subject-Disjoint	87.27	87.35	87.27
Proposed Dual-Domain + SVM	Dual (Face + Emotion)	Subject-Disjoint	88.47	88.52	88.47
Proposed Tri-Domain + LR	**Tri (Face + Emotion + Age)**	**Subject-Disjoint**	**88.66**	**88.75**	**88.66**
Proposed Tri-Domain + SVM	Tri (Face + Emotion + Age)	Subject-Disjoint	88.61	88.66	88.61

**(Catatan: Hupont & Fernández (2019) mengevaluasi tugas verifikasi pasangan identitas wajah berbasis kurva ROC/AUC, bukan tugas klasifikasi 6-kelas interseksional).*

optimisme semu akibat kebocoran data identitas. Penerapan protokol ketat Subject-Disjoint 480 subjek latih dan 120 subjek uji held-out menjamin eliminasi kebocoran identitas secara mutlak, sehingga menghasilkan evaluasi performa yang andal dan mencerminkan kapasitas generalisasi sistem biometrik pada dunia nyata.

V. CONCLUSION

Penelitian ini membuktikan efektivitas fusi representasi multi-domain Vision Transformer (Face $\oplus$ Emotion $\oplus$ Age: 2.304 dimensi) untuk klasifikasi enam kelas interseksional dari tiga kelompok ras makro (Asian, Black, White) pada dataset DemogPairs. Di bawah protokol Strict Subject-Disjoint Partitioning dengan 0% kebocoran data (480 subjek latih dan 120 subjek uji held-out), Logistic Regression (LR) meraih akurasi puncak 88.66% (F1-score: 88.68%) dan Support Vector Machine (SVM) meraih 88.61% (F1-score: 88.63%). Pengujian hipotesis McNemar berpasangan membuktikan signifikansi fusi tri-domain terhadap representasi domain tunggal Face ($p < 0.001$) sekaligus mengonfirmasi paritas prediktif sempurna antara LR dan SVM ($p = 1.0000$, dengan selisih bersih satu sampel dari 2.160 citra). Efisiensi komputasi LR yang ekstrem, tercermin dari latensi inferensi 0.0046 ms/sampel berbanding 4.6785 ms serta ukuran model 0.11 MB berbanding 36.60 MB, menetapkannya sebagai pengklasifikasi hilir paling optimal untuk deployment praktis.

Meskipun menawarkan kontribusi empiris yang signifikan, penelitian ini memiliki dua batasan utama yang memerlukan perhatian. Pertama, cakupan demografis penyelidikan ini terbatas pada tiga kelompok ras makro dalam dataset DemogPairs (Asian, Black, White), sehingga generalisasi performa klasifikasi ke kelompok multirasial maupun populasi etnisitas lain tetap membutuhkan pengujian empiris tambahan. Kedua, proses ekstraksi representasi multi-domain masih dijalankan secara terpisah memanfaatkan tiga model backbone ViT-Base beku tanpa fine-tuning end-to-end terpadu, di mana total beban komputasi ekstraksi pada kartu grafis (GPU) mencapai 124.5 ms/citra. Menanggapi batasan tersebut, arah riset mendatang diarahkan pada tiga prioritas strategis. Pertama, validasi lintas dataset perlu dilakukan pada korpus eksternal berskala besar in-the-wild, seperti FairFace atau UTKFace, untuk menguji ketangguhan model terhadap variasi pose ekstrem, oklusi, dan pencahayaan dinamis. Kedua, penelitian lanjutan perlu mengembangkan mekanisme fusi atensi silang adaptif antardomain serta menerapkan kompresi model melalui teknik kuantisasi atau knowledge distillation demi deployment pada perangkat tepi berdaya rendah. Ketiga, integrasi metode visualisasi Explainable Artificial Intelligence (XAI), seperti Attention Rollout, menjadi langkah krusial untuk menyediakan transparansi representasi fitur serta mendukung prinsip etika kecerdasan buatan.

DATA AVAILABILITY STATEMENT

Dataset DemogPairs yang dianalisis dalam penelitian ini merupakan dataset yang tersedia secara publik untuk keperluan riset akademis. Citra wajah beserta anotasi label demografis dapat diakses secara bebas melalui publikasi resmi pengembang pada https://ihupont.github.io/publications/2019-05-16-demogpairs dan direktori penyimpanan Google Drive resmi pada https://drive.google.com/file/d/1f_ez-ll6wxDXScrG4ceStZRuLT_K8Uy8/view?usp=sharing.

CODE AVAILABILITY STATEMENT

Seluruh skrip implementasi, pipeline pra-pemrosesan data, ekstraksi fitur Vision Transformer, optimasi validasi silang bebas kebocoran, dan notebook reproduktibilitas eksperimen tersedia secara terbuka di repositori GitHub penelitian: https://github.com/rafyakbar/face-race-gender-classification-using-multi-d

ETHICAL COMPLIANCE STATEMENT

Penelitian ini mematuhi prinsip-prinsip etika penelitian kecerdasan buatan dan pedoman perlindungan data biometrik. Seluruh data citra wajah yang dianalisis bersumber dari korpus publik DemogPairs yang telah dianonimkan untuk keperluan riset ilmiah. Model yang dikembangkan ditujukan murni untuk memajukan audit keadilan algoritmik dan mengurangi

disparitas demografis pada sistem visi komputer, tanpa penerapan untuk pengawasan massal tanpa persetujuan.

REFERENCES

[1] M. K. Rusia and D. K. Singh, "A comprehensive survey on techniques to handle face identity threats: challenges and opportunities," *Multimedia Tools and Applications*, vol. 82, no. 2, pp. 1669–1748, Jan. 2023.
[2] B. Meden, P. Rot, P. Terhörst, N. Damer, A. Kuijper, W. J. Scheirer, A. Ross, P. Peer, and V. Štruc, "Privacy-enhancing face biometrics: a comprehensive survey," *IEEE Transactions on Information Forensics and Security*, vol. 16, pp. 4147–4183, 2021.
[3] A. Birhane, "The unseen Black faces of AI algorithms," *Nature*, vol. 610, no. 7932, pp. 451–452, Oct. 2022.
[4] H. Overbye-Thompson, K. A. Hamilton, and D. Mastro, "Reinvention mediates impacts of skin tone bias in algorithms: implications for technology diffusion," *Journal of Computer-Mediated Communication*, vol. 29, no. 5, p. zmae016, Sept. 2024.
[5] P. Terhörst, J. N. Kolf, M. Huber, F. Kirchbuchner, N. Damer, A. M. Moreno, J. Fierrez, and A. Kuijper, "A comprehensive study on face recognition biases beyond demographics," *IEEE Transactions on Technology and Society*, vol. 3, no. 1, pp. 16–30, Mar. 2022.
[6] N. Liu, F. Zhang, L. Chang, and F. Duan, "Facial attribute classification by deep mining inter-attribute correlations," *IET Computer Vision*, vol. 17, no. 3, pp. 352–365, 2023.
[7] D. R. Yoder-Himes, A. Asif, K. Kinney, T. J. Brandt, R. E. Cecil, P. R. Himes, C. Cashon, R. M. P. Hopp, and E. Ross, "Racial, skin tone, and sex disparities in automated proctoring software," *Frontiers in Education*, vol. 7, p. 881449, 2022.
[8] Z. S. Marzoog, A. D. Hasan, and H. H. Abbas, "Gender and race classification using geodesic distance measurement," *Indonesian Journal of Electrical Engineering and Computer Science*, vol. 27, no. 2, pp. 820–831, Aug. 2022.
[9] J. P. Robinson, C. Qin, Y. Henon, S. Timoner, and Y. Fu, "Balancing biases and preserving privacy on Balanced Faces in the Wild," *IEEE Transactions on Image Processing*, vol. 32, pp. 4365–4377, Aug. 2023.
[10] M. Sohail, G. Ali, J. Rashid, I. Ahmad, S. H. Almotiri, M. A. AlGhamdi, A. A. Nagra, and K. Masood, "Racial identity-aware facial expression recognition using deep convolutional neural networks," *Applied Sciences*, vol. 12, no. 1, p. 88, Dec. 2021.
[11] D. Belcar, P. Grd, and I. Tomičić, "Automatic ethnicity classification from middle part of the face using convolutional neural networks," *Informatics*, vol. 9, no. 1, p. 18, 2022.
[12] H. Liao, L. Yuan, M. Wu, L. Zhong, G. Jin, and N. Xiong, "Face gender and age classification based on multi-task, multi-instance and multi-scale learning," *Applied Sciences*, vol. 12, no. 23, p. 12432, 2022.
[13] G. Sunitha, K. Geetha, S. Neelakandan, A. K. S. Pundir, S. Hemalatha, and V. Kumar, "Intelligent deep learning based ethnicity recognition and classification using facial images," *Image and Vision Computing*, vol. 121, p. 104404, 2022.
[14] J. Brinkmann, P. Swoboda, and C. Bartelt, "A multidimensional analysis of social biases in vision transformers," in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 2023, pp. 4891–4900.
[15] S. Ramachandran and A. Rattani, "Deep generative views to mitigate gender classification bias across gender-race groups," in *Pattern Recognition, Computer Vision, and Image Processing. ICPR 2022 International Workshops and Challenges*, J.-J. Rousseau and B. Kapralos, Eds. Cham, Switzerland: Springer Nature Switzerland, 2023, pp. 551–569.
[16] S. Chen, X. Lai, Y. Yan, D.-H. Wang, and S. Zhu, "Learning an attention-aware parallel sharing network for facial attribute recognition," *Journal of Visual Communication and Image Representation*, vol. 90, p. 103745, 2023.
[17] G. G. Tahyudin, M. D. Sulistiyo, M. Arzaki, and E. Rachmawati, "Classifying gender based on face images using vision transformer," *JOIV : International Journal on Informatics Visualization*, vol. 8, no. 1, pp. 18–25, Mar. 2024.
[18] A.-A. Kalkatawi and U. Saeed, "Ethnicity classification based on facial images using deep learning approach," *International Journal of Advanced Computer Science and Applications*, vol. 15, no. 2, pp. 217–226, 2024.
[19] R. A. Putri, L. Anifah, R. E. Putra, Y. Yamasari, and R. A. Akbar, "Dual vision transformer integration for race and gender recognition based on facial images," in *Proceedings of the 2025 8th International Conference on Vocational Education and Electrical Engineering (ICVEE)*, 2025, pp. 258–264.
[20] R. A. Putri, R. E. Putra, and Y. Yamasari, "MD-ViT: Multidomain vision transformer fusion for fair demographic attribute recognition," *Journal of Information Engineering and Educational Technology*, vol. 9, no. 2, pp. 64–79, Dec. 2025.
[21] S. K. Gupta and N. Nain, "Review: single attribute and multi attribute facial gender and age estimation," *Multimedia Tools and Applications*, vol. 82, no. 1, pp. 1289–1311, 2023.
[22] Y. Deng, S. Teng, L. Fei, W. Zhang, and I. Rida, "A multifeature learning and fusion network for facial age estimation," *Sensors*, vol. 21, no. 13, p. 4597, 2021.
[23] Z. Wang, L. Xiao, Z. Cao, and H. Lu, "Vision transformer off-the-shelf: a surprising baseline for few-shot class-agnostic counting," in *Proceedings of the AAAI Conference on Artificial Intelligence (AAAI)*, vol. 38, no. 6, Mar. 2024, pp. 5832–5840.
[24] D. Wilimitis and C. G. Walsh, "Practical considerations and applied examples of cross-validation for model development and evaluation in health care: tutorial," *JMIR AI*, vol. 2, p. e49023, Dec. 2023.
[25] I. Hupont and C. Fernández, "DemogPairs: Quantifying the impact of demographic imbalance in deep face recognition," in *Proceedings of the 2019 14th IEEE International Conference on Automatic Face and Gesture Recognition (FG)*, 2019, pp. 1–7.
[26] K. Han, Y. Wang, H. Chen, X. Chen, J. Guo, Z. Liu, Y. Tang, A. Xiao, C. Xu, Y. Xu, Z. Yang, Y. Zhang, and D. Tao, "A survey on vision transformer," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 45, no. 1, pp. 87–110, Jan. 2023.
[27] S. Khan, M. Naseer, M. Hayat, S. W. Zamir, F. S. Khan, and M. Shah, "Transformers in vision: A survey," *ACM Computing Surveys*, vol. 54, no. 10s, pp. 200:1–200:41, Sept. 2022.
[28] Y. Liu, Y. Zhang, Y. Wang, F. Hou, J. Yuan, J. Tian, Y. Zhang, Z. Shi, J. Fan, and Z. He, "A survey of visual transformers," *IEEE Transactions on Neural Networks and Learning Systems*, vol. 35, no. 6, pp. 7478–7498, June 2024.
[29] J. Ma, Y. Bai, B. Zhong, W. Zhang, T. Yao, and T. Mei, "Visualizing and understanding patch interactions in vision transformer," *IEEE Transactions on Neural Networks and Learning Systems*, vol. 35, no. 10, pp. 13 671–13 680, 2024.
[30] M. A. Ganaie, M. Tanveer, P. N. Suganthan, and V. Snasel, "Oblique and rotation double random forest," *Neural Networks*, vol. 153, pp. 496–517, 2022.
[31] C. Zhao, D. Wu, J. Huang, Y. Yuan, H.-T. Zhang, R. Peng, and Z. Shi, "BoostTree and BoostForest for ensemble learning," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 45, no. 7, pp. 8110–8126, Jul. 2023.
[32] Y.-X. He, S.-H. Lyu, and Y. Jiang, "Interpreting deep forest through feature contribution and MDI feature importance," *ACM Transactions on Knowledge Discovery from Data*, vol. 20, no. 1, pp. 1–21, Dec. 2025.
[33] N. Zhu, C. Zhu, L. Zhou, Y. Zhu, and X. Zhang, "Optimization of the random forest hyperparameters for power industrial control systems intrusion detection using an improved grid search algorithm," *Applied Sciences*, vol. 12, no. 20, p. 10456, 2022.
[34] J. Chen, X. Wang, and F. Lei, "Data-driven multinomial random forest: a new random forest variant with strong consistency," *Journal of Big Data*, vol. 11, no. 1, p. 34, Feb. 2024.
[35] E. Redivo, C. Viroli, and A. Farcomeni, "Quantile-distribution functions and their use for classification, with application to naïve Bayes classifiers," *Statistics and Computing*, vol. 33, no. 2, p. 55, Mar. 2023.
[36] Y. A. Khan, S. Imaduddin, Y. P. Singh, M. Wajid, M. Usman, and M. Abbas, "Artificial intelligence based approach for classification of human activities using MEMS sensors data," *Sensors*, vol. 23, no. 3, p. 1275, Jan. 2023.
[37] A. J. Molstad and K. Motwani, "Multiresolution categorical regression for interpretable cell-type annotation," *Biometrics*, vol. 79, no. 4, pp. 3485–3496, Dec. 2023.
[38] P. Zhang, R. Wang, and N. Xiu, "Multinomial logistic regression classifier via lq,0-proximal Newton algorithm," *Neurocomputing*, vol. 468, pp. 148–164, 2022.
[39] Y. Zhang, C. Wei, and X. Liu, "Group logistic regression models with lp,q regularization," *Mathematics*, vol. 10, no. 13, p. 2227, 2022.
[40] Z. Lai, X. Chen, J. Zhang, H. Kong, and J. Wen, "Maximal margin support vector machine for feature representation and classification," *IEEE Transactions on Cybernetics*, vol. 53, no. 10, pp. 6700–6713, 2023.
[41] C. Yang, S.-K. Oh, B. Yang, W. Pedrycz, and L. Wang, "Hybrid fuzzy multiple SVM classifier through feature fusion based on convolution neural

networks and its practical applications," *Expert Systems with Applications*, vol. 202, p. 117392, 2022.
[42] M. A. Chandra and S. S. Bedi, "Survey on SVM and their application in image classification," *International Journal of Information Technology*, vol. 13, no. 5, pp. 1–11, Oct. 2021.
[43] R. Guido, M. C. Groccia, and D. Conforti, "A hyper-parameter tuning approach for cost-sensitive support vector machine classifiers," *Soft Computing*, vol. 27, no. 18, pp. 12 863–12 881, Sept. 2023.
[44] H. H. Rashidi, S. Albahra, S. Robertson, N. K. Tran, and B. Hu, "Common statistical concepts in the supervised machine learning arena," *Frontiers in Oncology*, vol. 13, p. 1130229, Feb. 2023.
[45] I. M. De Diego, A. R. Redondo, R. R. Fernández, J. Navarro, and J. M. Moguerza, "General performance score for classification problems," *Applied Intelligence*, vol. 52, no. 10, pp. 12 049–12 063, Aug. 2022.
[46] A. Tharwat, "Classification assessment methods," *Applied Computing and Informatics*, vol. 17, no. 1, pp. 168–192, Jan. 2021.
[47] S. A. Hicks, I. Strümke, V. Thambawita, M. Hammou, M. A. Riegler, P. Halvorsen, and S. Parasa, "On evaluation metrics for medical applications of artificial intelligence," *Scientific Reports*, vol. 12, no. 1, p. 5979, Apr. 2022.
[48] G. Hanczár, M. Stippinger, D. Hanák, M. T. Kurbucz, O. M. Törteli, Á. Chripkó, and Z. Somogyvári, "Feature space reduction method for ultrahigh-dimensional, multiclass data: random forest-based multiround screening (RFMS)," *Machine Learning: Science and Technology*, vol. 4, no. 4, p. 045012, Oct. 2023.
[49] S. Guo, J. Zhang, Y. Wu, A. C. McLain, J. W. Hardin, B. Olatosi, and X. Li, "Functional multivariable logistic regression with an application to HIV viral suppression prediction," *Biometrical Journal*, vol. 66, no. 5, p. e202300081, 2024.
[50] K. Nadeem and M.-A. Jabri, "Stable variable ranking and selection in regularized logistic regression for severely imbalanced big binary data," *PLOS ONE*, vol. 18, no. 1, pp. 1–26, Jan. 2023.
[51] Scikit-learn Developers, "SVC," https://scikit-learn.org/stable/modules/generated/sklearn.svm.SVC.html, 2026, accessed: Feb. 2, 2026.



RICKY EKA PUTRA menyelesaikan studi Sarjana, Magister, dan Doktor di bidang Ilmu Komputer di Institut Teknologi Sepuluh Nopember (ITS) masing-masing pada tahun 2008, 2011, dan 2020, serta memperoleh gelar Profesi Insinyur pada tahun 2024. Saat ini, beliau bertugas sebagai dosen dan peneliti di Departemen Informatika, Fakultas Informatika, Universitas Negeri Surabaya. Beliau aktif berkiprah dalam pelaksanaan tridarma perguruan tinggi yang mencakup pengajaran bidang informatika, program pemberdayaan masyarakat, publikasi karya ilmiah pada berbagai jurnal bereputasi, diseminasi riset pada forum seminar ilmiah, serta perolehan Hak Kekayaan Intelektual (HKI). Fokus penelitian utama beliau diarahkan pada pengembangan model kecerdasan buatan terapan yang menjembatani kemajuan metode komputasi cerdas dengan penyelesaian tantangan berbasis data nyata. Bidang minat penelitian beliau meliputi Deep Learning, Computer Vision, Big Data Analytics, aplikasi digital dan user experience, psikologi klinis, intensi perilaku, healthcare informatics, metode statistika, serta pendidikan digital dan anak usia dini.



REZKY ARISANTI PUTRI meraih gelar Sarjana Teknik Informatika pada tahun 2019 dengan peminatan bidang Kecerdasan Buatan (Artificial Intelligence) dan telah menuntaskan studi Magister Informatika di Universitas Negeri Surabaya (UNESA). Saat ini, beliau aktif berkiprah sebagai peneliti di Departemen Informatika, Fakultas Informatika, Universitas Negeri Surabaya. Beliau terlibat intensif dalam riset pengenalan atribut demografis wajah berbasis model transformer serta secara aktif mendiseminasikan kontribusi keilmuannya melalui publikasi pada forum konferensi internasional dan jurnal ilmiah bereputasi. Fokus dan minat penelitian beliau mencakup Computer Vision, Deep Learning, Vision Transformer, Facial Attribute Recognition, Natural Language Processing, Machine Learning, dan Algorithmic Fairness. Melalui kegiatan akademik dan eksplorasi riset yang konsisten, beliau terus memperdalam kompetensi keilmuan serta berkontribusi nyata dalam kemajuan teknologi komputasi cerdas.



YUNI YAMASARI merupakan dosen dan peneliti di Departemen Informatika, Fakultas Informatika, Universitas Negeri Surabaya (UNESA) dengan landasan keilmuan yang kokoh di dunia akademik maupun praktis. Beliau menyelesaikan pendidikan Sarjana, Magister, hingga Doktor di Institut Teknologi Sepuluh Nopember (ITS), dengan kepakaran utama pada bidang Software Engineering dan Data Mining. Aktivitas tridarma beliau ditandai oleh keterlibatan aktif dalam pemberdayaan masyarakat, publikasi artikel ilmiah bereputasi, serta penulisan buku teks akademik. Beliau secara berkala mendiseminasikan temuan penelitiannya di berbagai forum ilmiah nasional maupun internasional dan telah memperoleh beberapa Hak Kekayaan Intelektual (HKI). Dedikasi akademik beliau diarahkan untuk mendorong perkembangan rekayasa perangkat lunak, analisis data komprehensif, dan bidang informatika terapan.



RAFY AULIA AKBAR menyelesaikan pendidikan Sarjana Teknik Informatika pada tahun 2019 dan meraih gelar Magister Informatika di Universitas Negeri Surabaya dengan konsentrasi pada bidang Ilmu Komputer. Semasa studi, beliau berhasil menorehkan prestasi dengan menerima penghargaan Best Solution Award pada kompetisi regional ASEAN Vocational and Engineering Camp 2017 bertema "Toward School 4.0". Saat ini, beliau aktif mendedikasikan diri sebagai peneliti di Departemen Informatika, Fakultas Informatika, Universitas Negeri Surabaya. Fokus dan minat penelitian beliau terpusat pada domain Computer Vision, Medical Image Analysis, Multimodal Deep Learning, Natural Language Processing, serta arsitektur Vision Transformer, khususnya dalam pengembangan sistem pembangkitan laporan medis otomatis.



SHUKOR SANIM MOHD FAUZI merupakan Senior Lecturer pada Faculty of Computer and Mathematical Sciences, Universiti Teknologi MARA (UiTM), Malaysia. Ia memperoleh Diploma in Computer Science dan Bachelor of Science (Hons.) in Information Systems Engineering dari UiTM, kemudian melanjutkan studi magister di Centre for Advanced Software Engineering, Universiti Teknologi Malaysia, serta meraih gelar doktor (Ph.D.) di bidang Software Engineering dari University of New South Wales (UNSW), Australia. Bidang penelitiannya mencakup software engineering dan empirical software engineering, dengan perhatian khusus pada mining software repositories, social network analysis, socio-technical congruence, computer-supported collaborative work, serta analisis dan pengembangan proses perangkat lunak.